

**UNIVERSIDADE FEDERAL DE JUIZ DE FORA  
FACULDADE DE ENGENHARIA  
COORDENAÇÃO DO CURSO DE ENGENHARIA ELÉTRICA**

**Vinícius Franklin Pedroso Mansur de Azevedo**

**Estudo Experimental de Sinais EMG para Controle de Prótese Ativa usando  
Aprendizado de Máquina**

Juiz de Fora

2025

**Vinícius Franklin Pedroso Mansur de Azevedo**

**Estudo Experimental de Sinais EMG para Controle de Prótese Ativa usando  
Aprendizado de Máquina**

Monografia apresentada a Coordenação do Curso de Engenharia Elétrica da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de grau de bacharel em Engenharia Elétrica, habilitação em Sistemas Eletrônicos.

Orientador: Prof. Leandro Rodrigues Manso Silva, Dr. Eng.

Juiz de Fora

2025

Ficha catalográfica elaborada através do Modelo Latex do CDC da UFJF  
com os dados fornecidos pelo(a) autor(a)

de Azevedo, Vinícius Franklin Pedroso Mansur.

Estudo Experimental de Sinais EMG para Controle de Prótese Ativa  
usando Aprendizado de Máquina / Vinícius Franklin Pedroso Mansur de  
Azevedo. – 2025.

89 f. : il.

Orientador: Leandro Rodrigues Manso Silva, Dr. Eng.

Dissertação (Trabalho de Conclusão de Curso) – Universidade Federal  
de Juiz de Fora, Faculdade de Engenharia. Coordenação do Curso de  
Engenharia Elétrica , 2025.

**Vinícius Franklin Pedroso Mansur de Azevedo**

**Estudo Experimental de Sinais EMG para Controle de Prótese Ativa usando  
Aprendizado de Máquina**

Monografia apresentada a Coordenação do Curso de Engenharia Elétrica da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de grau de bacharel em Engenharia Elétrica, habilitação em Sistemas Eletrônicos.

Aprovada em 24 de março de 2025.

**BANCA EXAMINADORA**

---

Prof. Leandro Rodrigues Manso Silva, Dr. Eng. -  
Orientador  
Universidade Federal de Juiz de Fora

---

Prof. Exuperry Barros Costa  
Universidade Federal de Juiz de Fora

---

M.Sc. Victor Valadares de Moraes  
Universidade Federal de Juiz de Fora

## **AGRADECIMENTOS**

Primeiramente, gostaria de expressar minha profunda gratidão à minha família: minha mãe Tania, meu pai Márcio, minha irmã Ana Carolina, e todos os meus familiares, que sempre me proporcionaram uma base sólida e apoio incondicional. Graças a eles, foi possível alcançar a oportunidade de cursar uma faculdade desafiadora e seguir meus objetivos acadêmicos.

Agradeço também aos meus amigos, que encontrei ao longo deste percurso, pelo incentivo constante, pelo suporte nos momentos difíceis e pelas trocas de aprendizado que tornaram a jornada mais leve e significativa.

Gostaria de expressar minha sincera gratidão a todos os professores e profissionais da Universidade Federal de Juiz de Fora (UFJF) que, de alguma forma, contribuíram para meu crescimento pessoal, acadêmico e profissional.

Sou especialmente grato ao professor Leandro Manso, por sua orientação dedicada, paciência e disponibilidade para auxiliar no desenvolvimento deste projeto. Seu conhecimento e suas sugestões foram fundamentais para a realização deste trabalho.

Por fim, agradeço a todos que, de alguma forma, contribuíram direta ou indiretamente para a conclusão deste trabalho, seja oferecendo apoio, incentivo ou compartilhando conhecimento.

## LISTA DE ILUSTRAÇÕES

Esquema ilustrativo da organização das fibras musculares. Fonte: IESPE [28]. . . . .	14
Estrutura de um sarcômero. Fonte: Brasil Escola [27]. . . . .	15
Junção neuromuscular. Fonte: Professor David Explains (YouTube) [18]. . . . .	16
Bomba de sódio e potássio. Fonte: Professor David Explains (YouTube) [18]. . . . .	16
Potencial de membrana em função do tempo. Fonte: Professor David Explains (YouTube) [18]. . . . .	17
Configuração de aquisição diferencial do sinal EMG. Fonte: Autoria Própria . . . . .	19
Músculos do antebraço (camada superficial) — visão posterior. Fonte: <i>Atlas of Human Anatomy</i> [13] . . . . .	21
Músculos do antebraço (camada superficial) — visão anterior. Fonte: <i>Atlas of Human Anatomy</i> [13]. . . . .	22
Módulo EMG comercial. Fonte: smartkits.com.br. . . . .	26
Cabo P02 utilizado no módulo EMG. Fonte: Autoria própria. . . . .	27
Analogia entre a disposição dos eletrodos e uma linha de transmissão. Fonte: Autoria Própria . . . . .	30
Posicionamento dos eletrodos no músculo <i>Flexor Carpi Radialis</i> . Fonte: Autoria Própria .	31
Matriz comparativa dos sinais EMG no domínio do tempo (coluna esquerda) e da frequência (coluna direita) para as cinco variações de movimento analisadas — Configuração 1. Fonte: Autoria Própria. . . . .	34
Filtro IIR Butterworth — Resposta em magnitude e atraso de grupo. Fonte: Autoria Própria. . . . .	37
Matriz comparativa dos sinais EMG filtrados da Configuração 1: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria. . . . .	41
Palpação do ventre do músculo <i>Flexor Pollicis Longus</i> da mão direita. Fonte: Muscologo [15]. . . . .	43
Posicionamento dos eletrodos no músculo <i>Flexor Pollicis Longus</i> da mão direita. Fonte: Autoria Própria. . . . .	44
Matriz comparativa dos sinais EMG filtrados da Configuração 2: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria. . . . .	45
Posicionamento dos eletrodos no músculo <i>Flexor Digitorum Superficialis</i> da mão direita. Fonte: Autoria Própria. . . . .	48

Matriz comparativa dos sinais EMG filtrados da Configuração 3: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria. . . . .	49
Palpação do ventre do músculo <i>Extensor Digitorum</i> da mão direita. Fonte: Muscologo [15]. . . . .	50
Posicionamento dos eletrodos no músculo <i>Extensor Digitorum</i> da mão direita. Fonte: Autoria Própria. . . . .	51
Matriz comparativa dos sinais EMG filtrados da Configuração 4: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria. . . . .	52
Matriz comparativa dos resultados da clusterização não supervisionada para as quatro configurações de eletrodos analisadas. As classes obtidas (0 e 1) são sobrepostas ao sinal EMG filtrado com filtro IIR de fase zero, permitindo a avaliação visual da correspondência entre os rótulos gerados e os períodos de contração e relaxamento muscular. . . . .	65
Processo de aquisição dos sinais EMG. Fonte: [32]. . . . .	78
Amplificador de instrumentação INA128P. Fonte: Datasheet do fabricante. . . . .	79
Características do conversor analógico-digital do ESP32. Fonte: Espressif. . . . .	81
Topologia básica do filtro Sallen-Key. Fonte: Wikipedia. . . . .	82
Circuito de filtragem completo. Fonte: [31]. . . . .	82
Resposta em magnitude do filtro passa-faixa (simulação em Python). Fonte: autoria própria. . . . .	83
Resposta em fase do filtro passa-faixa (simulação em Python). Fonte: autoria própria. . . . .	83
Exemplo de circuito somador. Fonte: electronics.stackexchange.com. . . . .	84
Amplificador operacional MCP6002 utilizado como somador. Fonte: Datasheet. . . . .	85
Cabo P02. Fonte: eletrogate.com. . . . .	86
Conector Jack P02. Fonte: eletrogate.com. . . . .	86
Módulo adaptador P02. Fonte: eletrogate.com. . . . .	86
Esquemático do circuito. Fonte: autoria própria. . . . .	87
Projeto da PCB. Fonte: autoria própria. . . . .	88

## SUMÁRIO

<b>1</b>	<b>Introdução . . . . .</b>	<b>9</b>
1.1	Motivação . . . . .	9
1.2	Objetivos . . . . .	10
1.3	Divisão do Trabalho . . . . .	10
1.4	Códigos . . . . .	11
<b>2</b>	<b>Embasamento Biológico . . . . .</b>	<b>13</b>
2.1	Princípios da Contração Muscular . . . . .	13
2.2	Sinais Eletromiográficos . . . . .	17
2.3	Anatomia Muscular . . . . .	20
<b>3</b>	<b>Processamento e Análise dos Sinais EMG . . . . .</b>	<b>24</b>
3.1	Obtenção do Sinal . . . . .	25
<b>3.1.1</b>	Módulo de Aquisição EMG . . . . .	25
<b>3.1.2</b>	Configuração do Sistema de Aquisição . . . . .	27
3.2	Análise do Sinal - Original . . . . .	29
<b>3.2.1</b>	Primeira Configuração — Original . . . . .	31
<b>3.2.2</b>	Análise dos sinais - Original — Configuração 1 . . . . .	32
3.3	Filtro . . . . .	36
<b>3.3.1</b>	Passa-Faixa . . . . .	36
<b>3.3.2</b>	Rejeita-Faixa . . . . .	38
3.4	Análise do Sinal — Filtrado . . . . .	39
<b>3.4.1</b>	Primeira Configuração - Filtrada . . . . .	40
<b>3.4.2</b>	Segunda Configuração — Filtrada . . . . .	43
<b>3.4.3</b>	Terceira Configuração - Filtrada . . . . .	47
<b>3.4.4</b>	Quarta Configuração — Filtrada . . . . .	50
3.5	Conclusão da Análise . . . . .	53
<b>4</b>	<b>Extração de Features . . . . .</b>	<b>55</b>
4.1	Domínio do Tempo . . . . .	56
<b>4.1.1</b>	Amplitude Envelope . . . . .	56
<b>4.1.2</b>	RMS — Root Mean Square . . . . .	56
<b>4.1.3</b>	Zero Crossing Rate (ZCR) . . . . .	57
<b>4.1.4</b>	Mean Absolute Value (MAV) . . . . .	57
<b>4.1.5</b>	Waveform Length (WL) . . . . .	57
<b>4.1.6</b>	Média, Variância e Desvio Padrão . . . . .	57
<b>4.1.7</b>	Slope Sign Changes (SSC) . . . . .	57
<b>4.1.8</b>	MAVS — Mean Absolute Value with Slope Weighting . . . . .	58
4.2	Domínio da Frequência . . . . .	58
<b>4.2.1</b>	Band Energy Ratio (BER) . . . . .	58

<b>4.2.2</b>	Spectral Centroid (SC) . . . . .	59
<b>4.2.3</b>	Bandwidth (BW) . . . . .	59
<b>4.2.4</b>	Frequência Fundamental ( $f_0$ ) . . . . .	59
<b>4.2.5</b>	Potência de Banda dos Harmônicos . . . . .	59
<b>4.2.6</b>	Potência de Banda do Ruído . . . . .	60
<b>4.2.7</b>	Energia Harmônica . . . . .	60
<b>4.2.8</b>	Energia do Ruído . . . . .	60
<b>4.2.9</b>	Harmonic-to-Noise Ratio (HNR) . . . . .	60
<b>4.2.10</b>	Median Frequency (MDF) . . . . .	61
<b>4.2.11</b>	Mean Frequency (MNF) . . . . .	61
<b>4.3</b>	Conclusão . . . . .	61
<b>5</b>	<b>Modelos Não Supervisionados de Machine Learning para Classificação de Movimentos . . . . .</b>	<b>62</b>
<b>5.1</b>	Estratégia de Otimização do Agrupamento . . . . .	63
<b>5.2</b>	Modelos Não Supervisionados . . . . .	64
<b>5.2.1</b>	Aplicação do Modelo . . . . .	65
<b>5.2.2</b>	Configuração de parâmetros e otimização por conjunto de dados . . . . .	66
<b>5.2.3</b>	Análise dos Resultados . . . . .	66
<b>6</b>	<b>Modelo Supervisionado de Machine Learning para Classificação de Movimentos . . . . .</b>	<b>68</b>
<b>6.1</b>	Resultados do Modelo Supervisionado . . . . .	69
<b>6.1.1</b>	Desempenho resumido por configuração . . . . .	69
<b>6.1.2</b>	Análise de Robustez e Overfitting . . . . .	70
<b>6.1.3</b>	Limitações e Aplicações Futuras . . . . .	70
<b>6.1.4</b>	Considerações finais . . . . .	70
<b>7</b>	<b>Conclusão . . . . .</b>	<b>71</b>
<b>7.1</b>	Trabalhos Futuros . . . . .	72
<b>7.1.1</b>	Modelo simplificado para abertura e fechamento da mão . . . . .	72
<b>7.1.2</b>	Testes com Sensor Projetado . . . . .	72
<b>7.1.3</b>	Aquisição multicanal e multiclasse . . . . .	72
<b>7.1.4</b>	Implementação em sistema embarcado . . . . .	73
<b>7.1.5</b>	Desenvolvimento da prótese mecânica . . . . .	73
	<b>REFERÊNCIAS . . . . .</b>	<b>74</b>
<b>A</b>	<b>Projeto do Sensor EMG . . . . .</b>	<b>77</b>
<b>A.1</b>	Desenvolvimento do Sensor . . . . .	77
<b>A.1.1</b>	Eletrodos . . . . .	78
<b>A.1.2</b>	Amplificação . . . . .	79
<b>A.1.3</b>	Filtragem Analógica . . . . .	81
<b>A.1.4</b>	Offset - Somador . . . . .	84

<b>A.1.5</b>	Placa de Circuito Impresso – PCB	85
--------------	----------------------------------	----

## 1 Introdução

Com o avanço das tecnologias digitais, tem-se ampliado significativamente a possibilidade de desenvolvimento de ferramentas que, até poucos anos atrás, seriam consideradas inviáveis do ponto de vista técnico ou econômico. Nesse contexto, observa-se a crescente disponibilidade de plataformas, bibliotecas e ferramentas gratuitas ou de código aberto, que viabilizam o desenvolvimento de soluções tecnológicas em diversas áreas.

Entretanto, para aplicações mais complexas — como aquelas voltadas à área da saúde e de tecnologias assistivas — muitos dos avanços ainda se encontram restritos a produtos de alto custo comercial, que demandam infraestrutura especializada e mão de obra altamente qualificada. Esse cenário limita o acesso de grande parte da população a tecnologias que poderiam proporcionar ganhos significativos em qualidade de vida.

Diante disso, surge a oportunidade de atuação de profissionais das áreas de engenharia e computação no desenvolvimento de soluções mais acessíveis, seja por meio da criação de dispositivos de menor custo, seja pela disseminação de conhecimento técnico que permita sua replicação e adaptação.

Nesse contexto, este trabalho tem como objetivo a captação e a análise de sinais eletromiográficos (EMG) utilizando técnicas de machine learning, visando ao desenvolvimento de uma prótese ativa de baixo custo. A proposta busca oferecer uma solução acessível para pessoas com algum tipo de limitação motora ou necessidades especiais.

O estudo abrange todas as etapas relacionadas ao desenvolvimento do sensor, instrumentação, aquisição e processamento do sinal, construção do modelo de aprendizado e análise dos dados, estabelecendo um procedimento que possa ser aplicado de forma ampla. Dessa forma, pretende-se criar uma base sólida para a futura implementação do modelo em um sistema embarcado, seguindo as especificações apresentadas neste trabalho.

Ao longo do texto, são detalhados os métodos empregados, as escolhas técnicas realizadas e os resultados obtidos, com o intuito de demonstrar a viabilidade da proposta e contribuir para o avanço de soluções assistivas de baixo custo.

### 1.1 Motivação

Durante o processo de escolha do tema para o Trabalho de Conclusão de Curso, buscou-se priorizar um assunto que despertasse interesse acadêmico, envolvesse ciência teórica e aplicada, abrangesse uma parcela significativa dos conteúdos estudados ao longo da graduação e apresentasse relevância prática.

A convivência com profissionais que atuam junto a pessoas com necessidades especiais teve papel fundamental nesse direcionamento. A partir dessa influência, foi possível associar essa motivação ao conhecimento técnico adquirido ao longo da formação,

identificando-se uma oportunidade de aplicação das competências desenvolvidas em um projeto com potencial de impacto social.

A proposta mostrou-se viável e ainda mais relevante a partir do contato com o vídeo do PhD Max Ortiz-Catalan, disponível no canal da WIRED no YouTube, intitulado “How Mind-Controlled Bionic Arms Fuse to the Body”. Nesse material, é apresentado o funcionamento de uma prótese avançada desenvolvida pelo pesquisador. Embora se trate de uma tecnologia significativamente mais sofisticada do que a abordada neste trabalho, o conteúdo evidencia os desafios técnicos e humanos envolvidos nesse tipo de desenvolvimento, reforçando o impacto concreto que soluções dessa natureza podem proporcionar. Adicionalmente, a análise do mercado e de pesquisas correlatas contribuiu para o refinamento da proposta apresentada.

## 1.2 Objetivos

Este trabalho tem como objetivo compreender o funcionamento do músculo humano e, a partir disso, analisar como é possível extrair sinais eletromiográficos (EMG) para classificar movimentos utilizando modelos de machine learning. Busca-se que esse processo seja universal, permitindo sua reprodução com diferentes indivíduos. Inicialmente, essa etapa será realizada utilizando um módulo comercial para captação dos dados.

Paralelamente, será desenvolvido um sensor próprio para aquisição de sinais EMG, com foco em oferecer um dispositivo modificável, mais acessível e com documentação robusta. Isso possibilitará que o projeto, futuramente, seja embarcado para aplicações reais e comparado a módulos disponíveis no mercado.

Assim, os objetivos principais consistem em:

1. Captar sinais EMG e analisá-los;
2. Classificar movimentos a partir desses sinais;
3. Desenvolver, em paralelo, um sensor próprio para captação dos dados.

## 1.3 Divisão do Trabalho

O desenvolvimento deste trabalho foi organizado em etapas complementares, de forma a contemplar tanto a aquisição e análise dos sinais EMG quanto a construção de modelos de classificação e a futura implementação embarcada. A divisão do trabalho pode ser resumida da seguinte forma:

1. **Embasamento biológico:** Estudo dos princípios da contração muscular, sinais eletromiográficos e anatomia muscular relacionada aos músculos do antebraço e mão, a fim de compreender a origem dos sinais e orientar a disposição dos eletrodos.

2. **Projeto do sensor EMG:** Desenvolvimento de um sensor próprio, incluindo eletrodos, amplificação, filtragem analógica, offset e placa de circuito impresso. Em paralelo, foi utilizada a aquisição de um módulo comercial para obtenção de dados e análise preliminar, servindo como referência para calibração e estudo do sinal.
3. **Aquisição de sinais e pré-processamento:** Captura de sinais EMG em quatro configurações de eletrodos distintas, visando maximizar a informação obtida de diferentes músculos e movimentos. Os sinais foram filtrados digitalmente para remoção de ruídos e análise de cross-talk, permitindo identificar transições de estado (contração/relaxamento).
4. **Extração de *features* e análise não supervisionada:** Implementação de pipeline para extração de características nos domínios do tempo e frequência, seguida de classificação não supervisionada para rotular os dados e validar padrões de ativação muscular.
5. **Modelo supervisionado de classificação:** Construção de modelos supervisionados binários, baseados nas *features* brutas e rotulagem obtida na etapa anterior, com avaliação de desempenho, robustez e análise de overfitting. Essa etapa serviu como base para futuras implementações multicanais e multiclasse.
6. **Análise de resultados:** Consolidação do desempenho de diferentes algoritmos de classificação, análise de métricas (*precision*, *recall*, *f1-score* ponderado) e discussão sobre aplicabilidade em tempo real, considerando limitações do modelo binário e interferência entre canais.
7. **Trabalhos futuros e implementação embarcada:** Propostas para teste do sensor próprio, aquisição multicanal, otimização de *features* para embarque em microcontroladores (como ESP32) e desenvolvimento da prótese mecânica, integrando sinais EMG, classificação e acionamento de motores.

Essa estrutura permitiu organizar o trabalho de forma sequencial e lógica, garantindo que cada etapa fornecesse subsídios para a seguinte, desde o estudo biológico até o desenvolvimento de um modelo supervisionado com potencial de implementação prática em próteses mioelétricas.

#### 1.4 Códigos

Para o desenvolvimento deste trabalho, foram implementados diversos códigos em Python e C++, com o objetivo de tratar problemas específicos, gerar gráficos, extrair parâmetros, executar modelos de aprendizado de máquina e realizar demais etapas necessárias à pesquisa.

Todos os scripts, juntamente com a base de dados utilizada, estão disponibilizados no repositório GitHub:

```
https:  
//github.com/VinicioFranklin22/emg-prosthesis-ml-experimental-study
```

Para evitar a repetição de descrições ao longo do texto, informa-se que todos os códigos encontram-se devidamente documentados no repositório. O arquivo `README.md` auxilia na identificação da estrutura de pastas e na localização dos arquivos relevantes, garantindo fácil compreensão e reproduzibilidade do estudo.

## 2 Embasamento Biológico

Com o intuito de detectar movimentos visando à construção de uma prótese ativa, torna-se necessário obter um sinal no qual seja possível identificar de forma confiável a intenção de movimento do usuário. A partir de diversas pesquisas, observa-se a existência de dois caminhos principais para esse tipo de aplicação. O primeiro envolve o uso do sinal eletroencefalográfico (EEG), que consiste no monitoramento da atividade elétrica cerebral. Contudo, essa abordagem apresenta elevada complexidade técnica e custos significativamente mais altos.

Em contrapartida, pesquisas de mercado indicam que a solução mais amplamente utilizada em dispositivos comerciais e acadêmicos é baseada no sinal eletromiográfico (EMG), o qual mede a resposta elétrica do músculo em decorrência de uma estimulação nervosa. Dessa forma, o sinal EMG é adotado como objeto de estudo desta pesquisa.

Para uma melhor compreensão do sinal a ser trabalhado, é fundamental entender o sistema biológico que lhe dá origem — neste caso, o sistema muscular. Esse entendimento fornece uma base conceitual sólida para o desenvolvimento da pesquisa e para a interpretação adequada dos resultados obtidos.

### 2.1 Princípios da Contração Muscular

Esta seção foi desenvolvida a partir de uma revisão de literatura que incluiu livros-texto clássicos de anatomia e fisiologia, artigos científicos, normas técnicas, materiais institucionais e conteúdos educacionais de divulgação científica. Esses materiais foram fundamentais para a construção de uma visão abrangente sobre os princípios fisiológicos da contração muscular e sua relação com os sinais bioelétricos, servindo como base conceitual para o desenvolvimento deste trabalho [4, 10, 11, 13, 14, 15, 18, 19, 23, 25].

O corpo humano constitui um sistema extremamente complexo, cujo funcionamento é amplamente controlado por fenômenos elétricos. Com o avanço da tecnologia, tornou-se possível interpretar esses sinais e modelar, ainda que de forma aproximada, os mecanismos envolvidos. Assim, antes de compreender o processo de contração muscular, é necessário entender como essa contração é ativada.

A contração muscular ocorre em resposta à transmissão neuromuscular, mediada pelo sistema nervoso somático. No caso da contração voluntária — na qual há consciência e intenção de executar um movimento — essa ativação ocorre na musculatura estriada esquelética.

A combinação entre um neurônio motor e as fibras musculares por ele inervadas forma a chamada unidade motora. Cada unidade motora é composta por um único neurônio e um conjunto de fibras musculares associadas. Os movimentos são coordenados

principalmente pelo córtex motor e pelo cerebelo. Quando se decide executar um movimento, o córtex motor envia sinais elétricos por meio da medula espinhal e dos nervos periféricos até os músculos, controlando o grau de contração. Paralelamente, sensores localizados nos músculos e articulações enviam informações de retorno ao cerebelo e a outras regiões do cérebro, indicando a posição e o estado do músculo, configurando um sistema de realimentação análogo a uma malha de controle.

Para que ocorra a comunicação entre neurônios, existe, ao final de cada axônio, uma região denominada sinapse, responsável pela transmissão da informação entre células nervosas. Quando um neurônio é ativado, ele libera substâncias químicas chamadas neurotransmissores, que atravessam o espaço sináptico e transportam a informação até o neurônio receptor. Assim, o neurônio pode ser interpretado como um elemento de chaveamento controlado por impulsos elétricos. Existem estudos que exploram analogias entre neurônios e dispositivos eletrônicos, como o artigo “Transistors and Brain Neurons: Unveiling the Striking Similarities”, da NeuroLaunch, que discute semelhanças funcionais entre esses sistemas.

Todos os músculos esqueléticos são formados por fascículos, e cada fascículo é composto por fibras musculares. No interior dessas fibras encontram-se as miofibrilas, organizadas em unidades repetitivas chamadas sarcômeros, que constituem a unidade funcional da contração muscular. A Figura 1 ilustra essa organização hierárquica, desde o músculo até o nível do sarcômero.

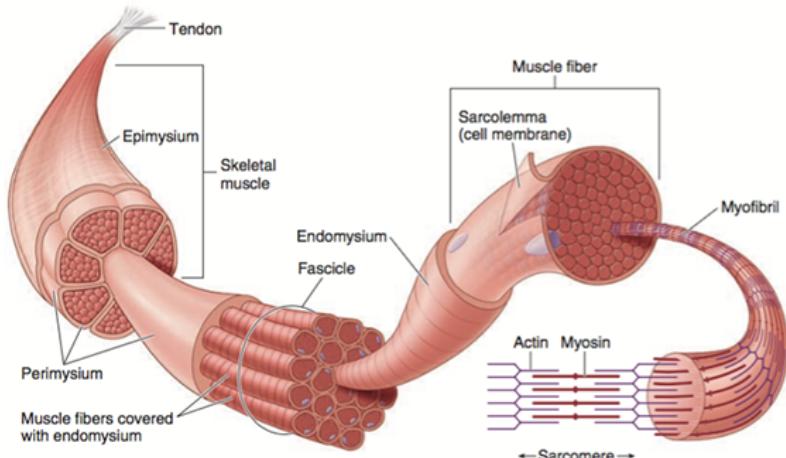


Figura 1: Esquema ilustrativo da organização das fibras musculares. Fonte: IESPE [28].

Os sarcômeros são divididos em regiões responsáveis pela aparência estriada do músculo esquelético. Em uma análise mais detalhada, observam-se os miofilamentos que compõem essas regiões. Os filamentos grossos, constituídos por miosina, estendem-se pela banda A e estão conectados na linha M. Os filamentos finos, formados por actina, estendem-se da banda I até a banda A.

A miosina é uma proteína que possui regiões denominadas cabeças de miosina, capazes de se ligar ao ATP. As estruturas de actina apresentam sítios específicos onde a miosina pode se ligar. Quando a fibra muscular está relaxada, essa ligação é bloqueada pela proteína tropomiosina. Essa organização estrutural pode ser melhor visualizada na Figura 2.

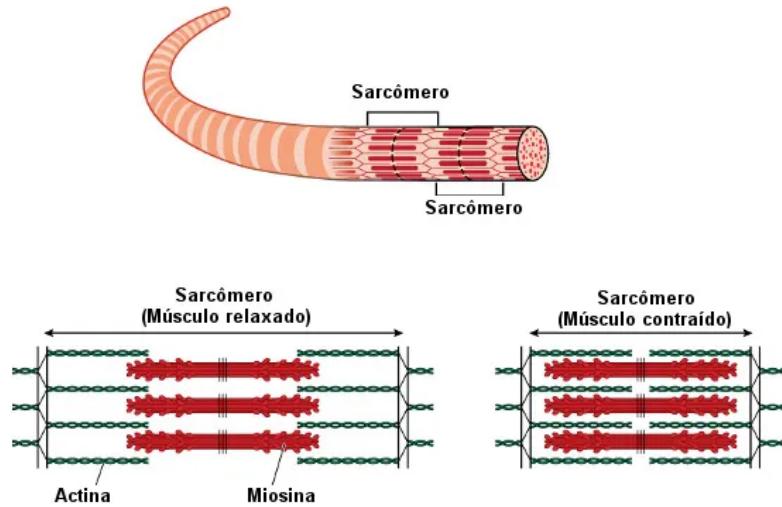


Figura 2: Estrutura de um sarcômero. Fonte: Brasil Escola [27].

Quando o sistema nervoso estimula as fibras musculares, as cabeças de miosina dos filamentos grossos interagem com os sítios de ligação das subunidades de actina. Essas ligações são formadas e desfeitas repetidamente, em um processo no qual o filamento grosso puxa o filamento fino em direção ao centro do sarcômero. Como consequência, as bandas se aproximam e o músculo como um todo encurta, caracterizando o mecanismo de contração muscular.

Esse processo é iniciado na junção neuromuscular, presente em cada fibra muscular. Nessa região, os terminais do axônio do neurônio motor encontram-se muito próximos da fibra muscular, separados pela fenda sináptica. Quando um impulso nervoso alcança o terminal do axônio, ocorre a liberação de acetilcolina na fenda sináptica. Essa substância liga-se aos receptores presentes na membrana da fibra muscular, promovendo uma mudança conformacional que pode ser observada na Figura 3.

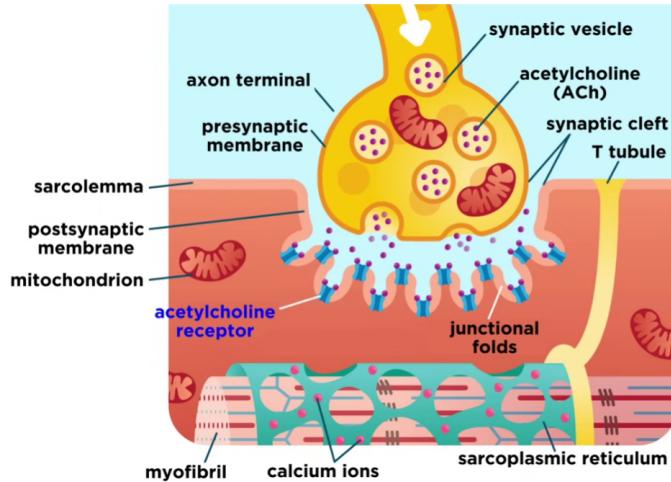


Figura 3: Junção neuromuscular. Fonte: Professor David Explains (YouTube) [18].

Essa proteína atua como um canal iônico, permitindo a entrada de íons sódio e a saída de íons potássio, ainda que em quantidades diferentes. O influxo predominante de sódio altera o potencial elétrico da membrana, modificando a distribuição de cargas entre o meio intra e extracelular. Antes da abertura do canal, o interior da célula apresenta maior carga negativa; com a entrada dos íons sódio, ocorre a despolarização da membrana. Esse fenômeno desencadeia a abertura de canais adjacentes, promovendo uma reação em cadeia ao longo da membrana celular, conforme ilustrado na Figura 4.

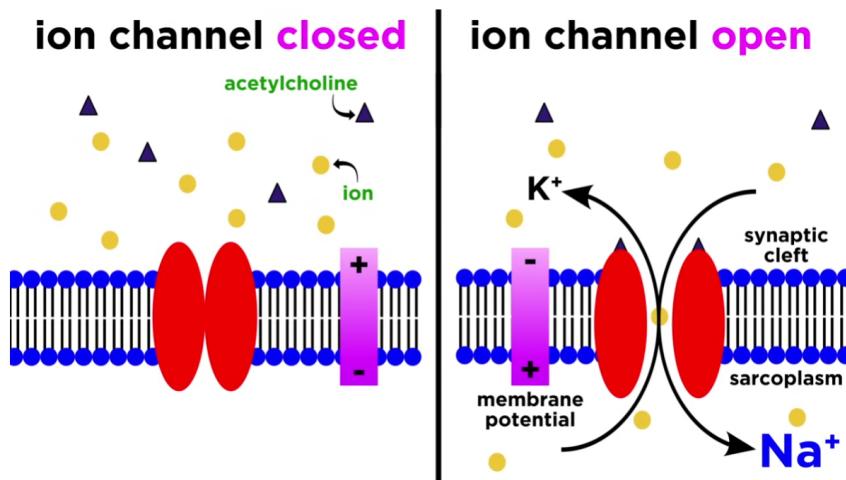


Figura 4: Bomba de sódio e potássio. Fonte: Professor David Explains (YouTube) [18].

Quando o potencial de membrana atinge um valor limiar — em uma analogia semelhante ao funcionamento de transistores — ocorre a geração de um potencial de ação. Nesse momento, íons sódio entram na célula em maior quantidade, enquanto a enzima acetilcolinesterase, presente na fenda sináptica, degrada a acetilcolina, promovendo o fechamento dos canais iônicos e prevenindo contrações contínuas até a chegada de um novo impulso nervoso. O potencial de ação, entretanto, continua a se propagar ao longo da sarcolema. Essa variação de polarização pode ser observada na Figura 5.

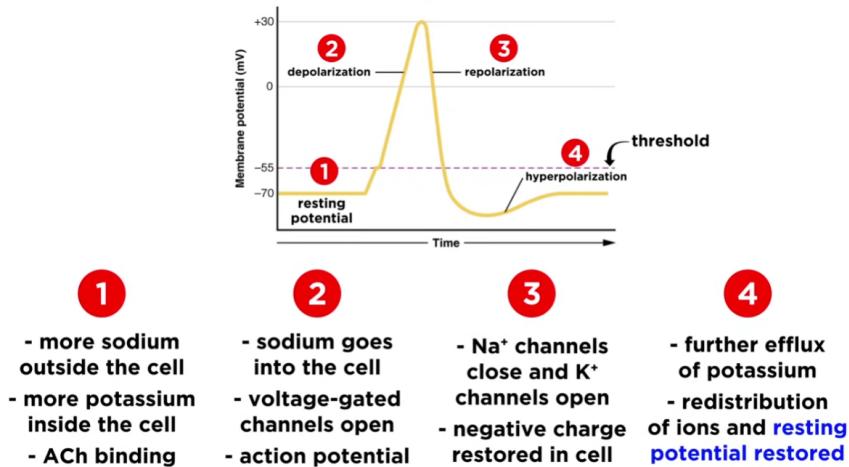


Figura 5: Potencial de membrana em função do tempo. Fonte: Professor David Explains (YouTube) [18].

O potencial de ação desencadeia o processo de acoplamento excitação–contração. A propagação do sinal resulta no aumento da concentração de íons cálcio no citosol das fibras musculares, o que permite o deslizamento dos filamentos. Quando a célula muscular está relaxada, a tropomiosina bloqueia os sítios de ligação da miosina na actina. À medida que os íons cálcio se ligam à troponina, ocorre uma mudança conformacional que desloca a tropomiosina, liberando os sítios de ligação e permitindo o ciclo de pontes cruzadas.

Durante esse processo, as cabeças de miosina utilizam ATP para alterar sua conformação e puxar repetidamente os filamentos de actina, resultando na contração muscular. Quando os níveis de cálcio diminuem, a troponina retorna ao seu estado original, a tropomiosina volta a bloquear os sítios de ligação e a fibra muscular relaxa.

## 2.2 Sinais Eletromiográficos

Esta subseção foi desenvolvida a partir de uma revisão de literatura que inclui artigos científicos clássicos e contemporâneos sobre eletromiografia, normas técnicas de instrumentação, livros-texto de referência e materiais institucionais, os quais forneceram o embasamento teórico necessário para a compreensão das características fisiológicas, espectrais e instrumentais do sinal eletromiográfico [3, 4, 8, 9, 10, 11, 26] .

Compreendendo o sistema neuromuscular como um sistema dinâmico altamente complexo, controlado predominantemente por sinais elétricos, torna-se possível medir sua atividade a partir da detecção dos potenciais elétricos gerados durante a estimulação nervosa do músculo. O sinal eletromiográfico (EMG) corresponde exatamente a essa manifestação elétrica, resultante da ativação das unidades motoras e da propagação dos potenciais de ação ao longo das fibras musculares.

Neste trabalho, será utilizada a eletromiografia de superfície (*surface EMG* —

sEMG), realizada por meio de eletrodos posicionados sobre a pele. Essa abordagem apresenta vantagens importantes, como ser não invasiva, de baixo custo e amplamente empregada em aplicações de reabilitação e próteses mioelétricas. Alternativamente, o sinal EMG também pode ser adquirido por meio de eletrodos invasivos, como agulhas intramusculares, que permitem maior seletividade espacial e melhor isolamento de unidades motoras individuais, porém à custa de maior complexidade, desconforto ao usuário e inviabilidade prática para aplicações contínuas.

Do ponto de vista fisiológico, o sinal EMG superficial não corresponde à atividade de uma única fibra muscular, mas sim à superposição temporal e espacial dos potenciais de ação das unidades motoras (*Motor Unit Action Potentials* – MUAPs). Cada unidade motora é composta por um neurônio motor e o conjunto de fibras musculares por ele inervadas, e sua ativação gera um potencial elétrico que se propaga ao longo das fibras. O sinal captado pelos eletrodos de superfície é, portanto, a soma de diversos MUAPs provenientes não apenas do músculo de interesse, mas também de músculos adjacentes.

Essa superposição de MUAPs provenientes de diferentes músculos constitui uma das principais causas do fenômeno conhecido como *cross-talk*, no qual a atividade elétrica de músculos adjacentes interfere no sinal medido. Esse efeito é particularmente relevante em regiões como o antebraço, caracterizadas por alta densidade muscular e pela presença de compartimentos anatômicos compartilhados. Dessa forma, o posicionamento adequado dos eletrodos torna-se fundamental, sendo recomendado que o par diferencial seja instalado sobre o ventre muscular do músculo de interesse, afastado das regiões tendíneas e alinhado, sempre que possível, com a direção das fibras musculares.

Devido à baixa amplitude e à elevada suscetibilidade a ruídos do sinal EMG, sua aquisição é comumente realizada por meio de uma configuração diferencial (Figura 6), composta por dois eletrodos ativos e um eletrodo de referência. Essa configuração tem como objetivo atenuar interferências em modo comum, explorando o elevado índice de rejeição de modo comum (*Common Mode Rejection Ratio* — CMRR) do sistema de aquisição. Para que esse cancelamento seja eficaz, é essencial que os eletrodos ativos estejam submetidos a condições elétricas e ambientais semelhantes, de modo que o ruído comum seja suprimido na etapa de amplificação diferencial. O eletrodo de referência, por sua vez, é tipicamente posicionado em uma região eletricamente estável, como uma proeminência óssea, minimizando sua influência sobre o sinal diferencial.

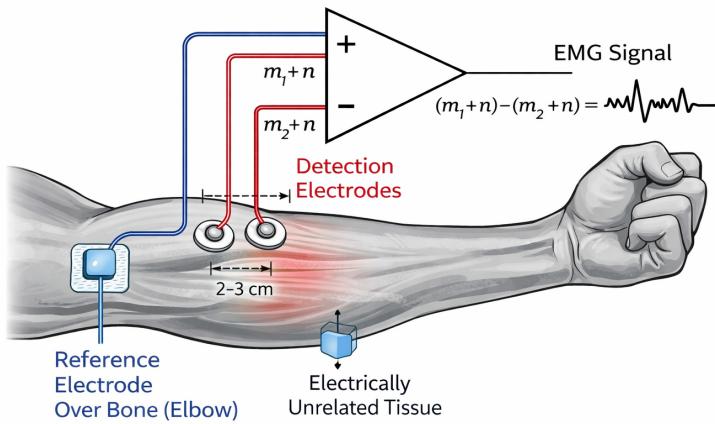


Figura 6: Configuração de aquisição diferencial do sinal EMG. Fonte: Autoria Própria

Outra característica importante do sinal EMG é a sua relação direta com o nível de força muscular exercido. De acordo com a literatura, o aumento da força produzida por um músculo está associado tanto ao recrutamento de um maior número de unidades motoras quanto ao aumento da taxa de disparo das unidades já ativas. Como consequência, observa-se um aumento da amplitude e da energia do sinal EMG à medida que o esforço muscular se intensifica. Ressalta-se, entretanto, que o sinal EMG não representa diretamente a força mecânica produzida, mas sim o grau de ativação neural responsável pela contração muscular.

Sob a perspectiva do processamento de sinais, o EMG é classificado como um sinal não estacionário e estocástico, cujas propriedades estatísticas variam ao longo do tempo em função do movimento executado, do nível de contração e de fatores fisiológicos individuais. Essa natureza não estacionária inviabiliza análises puramente globais no domínio da frequência e justifica o uso de técnicas baseadas em janelas temporais, como espectrogramas e extração de características por *frames*. Tais abordagens permitem acompanhar a evolução temporal do conteúdo espectral do sinal, sendo especialmente adequadas para aplicações de classificação de movimentos e controle de próteses mioelétricas.

Diversos estudos caracterizam as propriedades típicas do sinal EMG. De acordo com Raez et al. [10], a amplitude do sinal EMG varia tipicamente de 0 a 10 mV pico a pico antes da amplificação, sendo fortemente influenciada por ruídos introduzidos durante sua propagação através dos diferentes tecidos biológicos. No que diz respeito ao espectro de frequência, os autores indicam que o sinal EMG pode apresentar componentes que se estendem até aproximadamente 1 kHz.

De acordo com Basmajian e De Luca [30], a energia útil do sinal EMG encontra-se predominantemente limitada à faixa de 0 a 500 Hz, com maior concentração espectral

entre 50 e 150 Hz. Por sua vez, Fridlund e Cacioppo [29] indicam que a energia dominante do sinal situa-se entre 10 e 200 Hz, sendo a faixa de 10 a 30 Hz principalmente associada às taxas de disparo das unidades motoras, enquanto componentes acima de 30 Hz estão relacionadas aos potenciais de ação das fibras musculares.

Essas características tornam o sinal EMG particularmente desafiador do ponto de vista de processamento digital, exigindo técnicas apropriadas de filtragem, segmentação e extração de características, aspectos que serão abordados nos capítulos subsequentes.

### 2.3 Anatomia Muscular

Conforme discutido anteriormente, a qualidade do sinal eletromiográfico (EMG) é fortemente influenciada pelo posicionamento adequado dos eletrodos e pela correta escolha do músculo a ser analisado. Visando orientar essa etapa experimental e reduzir erros associados à localização anatômica dos músculos, foram adotadas como referências obras clássicas e amplamente consolidadas na literatura, tais como o *The Muscle and Bone Palpation Manual*, de Muscolino [15], o *Atlas of Pain Management Injection Techniques*, de Waldman [14], e o *Atlas of Human Anatomy*, de Netter [13]. Adicionalmente, foram consultados materiais educacionais de apoio disponibilizados pela plataforma CY Vigor, voltada ao estudo de anatomia funcional e cinesiologia [12].

A compreensão detalhada do ambiente anatômico no qual se realiza a aquisição do sinal é fundamental para a correta identificação do músculo de interesse. No presente trabalho, a análise concentra-se no antebraço, região que apresenta elevada complexidade anatômica devido à alta concentração de músculos responsáveis pelos movimentos da mão e dos dedos. Essa característica torna o processo de captação do sinal particularmente desafiador, uma vez que aumenta a probabilidade de interferências provenientes de músculos adjacentes, intensificando o efeito de *cross-talk* na eletromiografia de superfície.

A mão humana constitui uma estrutura altamente complexa, envolvendo mais de 30 músculos distribuídos entre a mão e o antebraço, que atuam de forma coordenada para permitir uma ampla variedade de movimentos. Os dedos possuem dois flexores longos principais, localizados na face anterior do antebraço, responsáveis pelo movimento de flexão. O músculo flexor profundo dos dedos (*flexor digitorum profundus*) insere-se na falange distal, enquanto o músculo flexor superficial dos dedos (*flexor digitorum superficialis*) insere-se na falange média. A ação combinada desses músculos possibilita a flexão efetiva dos dedos. Além disso, a mão conta com músculos intrínsecos, como os interósseos e os lumbricais, que contribuem para movimentos mais finos, como abdução, adução e extensão dos dedos.

Os músculos responsáveis pelos movimentos dos dedos estão localizados tanto no antebraço quanto na mão. Aqueles encarregados da extensão dos dedos são denominados músculos extensores e encontram-se predominantemente na face posterior do antebraço,

oposta à palma da mão. Quando contraídos, esses músculos tracionam os ossos do punho e dos dedos, promovendo o movimento de extensão. Essa ação é essencial para diversas atividades cotidianas, como digitar, segurar objetos, apontar e realizar movimentos de preensão controlada.

Os músculos extensores do antebraço estão organizados em seis compartimentos anatômicos distintos, conforme ilustrado na Figura 7. Os quatro primeiros compartimentos localizam-se nos sulcos do dorso da extremidade distal do rádio, o quinto compartimento situa-se entre o rádio e a ulna, e o sexto encontra-se no sulco dorsal da extremidade distal da ulna. Os tendões desses músculos contribuem para a formação da chamada *tabaqueira anatômica*. Destaca-se ainda que os dedos indicador e mínimo possuem músculos extensores adicionais, o que possibilita maior independência de movimento, particularmente no gesto de apontar.

#### **Muscles of Forearm (Superficial Layer): Posterior View**

SEE ALSO PLATES 439, 447

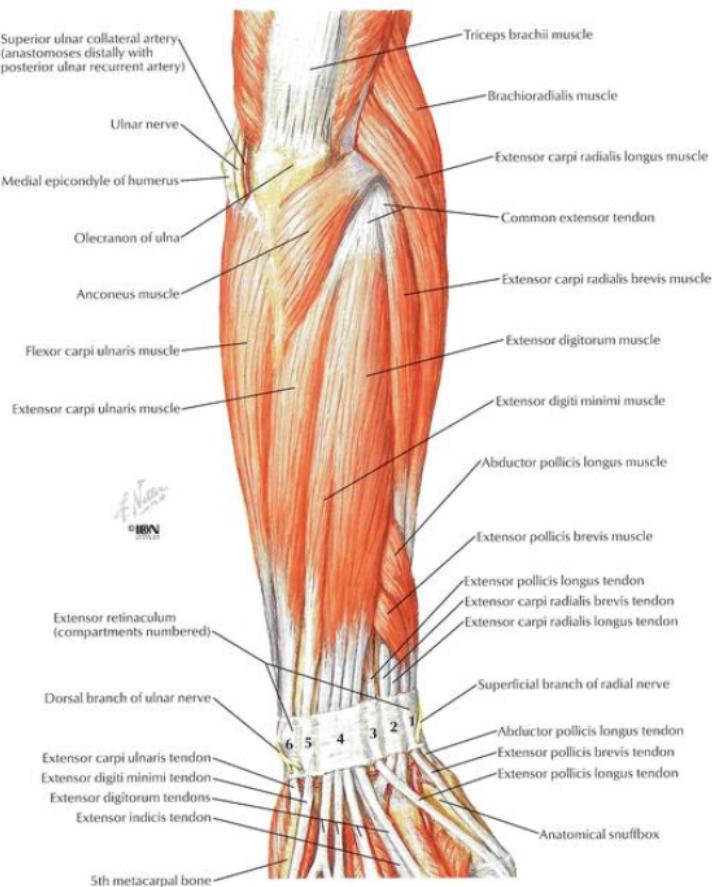


Figura 7: Músculos do antebraço (camada superficial) — visão posterior. Fonte: *Atlas of Human Anatomy* [13].

Os músculos lumbricais constituem outro grupo relevante na biomecânica da mão.

Apesar de auxiliarem na extensão dos dedos, esses músculos também participam da flexão das articulações metacarpofalângicas (MCP), localizadas nos nós dos dedos. Seu nome deriva da semelhança morfológica com uma minhoca. Os músculos interósseos, por sua vez, dividem-se em dorsais e palmares. Enquanto todos os interósseos contribuem para a flexão das articulações MCP, os interósseos dorsais permitem o afastamento dos dedos, e os palmares são responsáveis por aproximá-los.

A flexão dos dedos é realizada predominantemente pelos músculos flexores, apresentados na Figura 8. Conforme mencionado, os dedos contam com dois flexores longos localizados na face anterior do antebraço. O flexor profundo dos dedos, situado em uma camada mais profunda, origina quatro tendões que atravessam o túnel do carpo e se inserem nas falanges distais dos dedos indicador, médio, anelar e mínimo, possibilitando a flexão de todas as articulações desses dedos.

### ***Muscles of Forearm (Superficial Layer): Anterior View***

SEE ALSO PLATES 444, 445

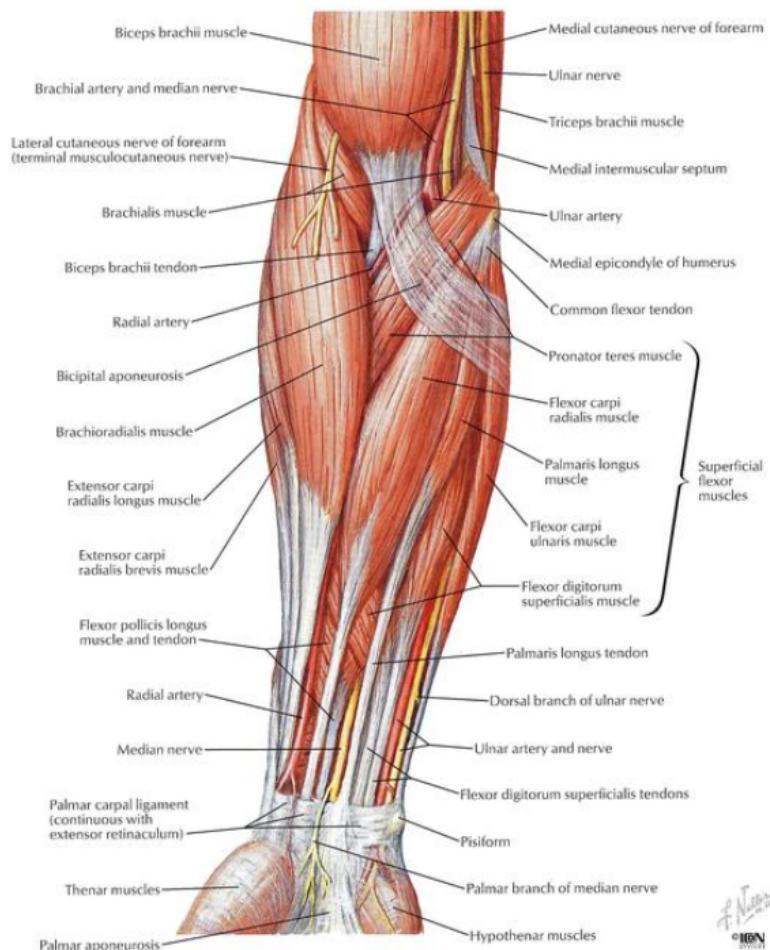


Figura 8: Músculos do antebraço (camada superficial) — visão anterior. Fonte: *Atlas of Human Anatomy* [13].

O polegar apresenta uma organização muscular distinta, contando com um flexor longo e um flexor curto, pertencentes ao grupo muscular tenar, localizado na base do polegar. Esse grupo é composto pelos músculos abdutor curto do polegar, flexor curto do polegar e oponente do polegar. O flexor curto do polegar permite a flexão em direção ao dedo mínimo, enquanto o flexor longo do polegar possibilita a flexão da falange distal.

Os dedos indicador, médio, anelar e mínimo são flexionados pelo músculo flexor profundo dos dedos. Entretanto, observa-se que os dedos médio, anelar e mínimo compartilham, em geral, um mesmo ventre muscular, o que dificulta a flexão isolada da falange distal de apenas um desses dedos. Em contrapartida, o dedo indicador possui um ventre muscular mais independente, permitindo maior controle motor fino. Essa característica anatômica evidencia que, mesmo no contexto da anatomia humana, existe uma limitação natural à independência funcional de determinados dedos, aspecto que será explorado de forma mais detalhada nas análises posteriores deste trabalho.

A partir da análise das Figuras 7 e 8, confirma-se a elevada densidade muscular presente no antebraço, que concentra mais de 30 músculos distribuídos entre o antebraço e a mão. Essa complexidade anatômica reforça os desafios associados à captação de sinais EMG de forma seletiva nessa região. Dessa forma, a escolha do músculo a ser analisado deve considerar não apenas sua função biomecânica no movimento de interesse, mas também sua acessibilidade anatômica e a possibilidade de minimizar interferências provenientes de músculos adjacentes. Tais critérios tornam-se especialmente relevantes no contexto da eletromiografia de superfície, na qual a captação do sinal reflete a atividade elétrica volumétrica dos tecidos sob os eletrodos, limitando a seletividade muscular. Assim, a análise anatômica apresentada fornece uma base fundamental para a definição do músculo explorado neste trabalho, cuja justificativa e implicações serão discutidas de forma mais detalhada no capítulo de Processamento e Análise dos Sinais EMG.

### 3 Processamento e Análise dos Sinais EMG

A partir do estudo da parte anatômica, é possível estabelecer uma base sólida para compreender como posicionar adequadamente os sensores, permitindo a obtenção dos sinais eletromiográficos utilizando o módulo citado.

Conforme discutido, o sinal adquirido é altamente ruidoso devido à presença de diversos músculos na região do antebraço. Esses músculos geram interferências que dificultam a identificação dos sinais desejados. Assim, torna-se necessário determinar uma configuração ótima de posicionamento dos eletrodos para obter a melhor qualidade de sinal possível. É importante ressaltar que, mesmo com um processamento de sinais robusto, a qualidade final depende majoritariamente da correta disposição dos eletrodos sobre a pele.

Entende-se que não é possível extrair todos os movimentos da mão a partir da atividade de um único músculo. Dessa forma, neste trabalho serão inicialmente estudadas configurações individuais de captação de sinais EMG e, posteriormente, estratégias para a combinação dessas informações. Para a construção de uma prótese funcional, não é necessário identificar todos os movimentos possíveis da mão humana, mas apenas aqueles considerados relevantes para a execução de tarefas do cotidiano.

Considerando que cada dedo apresenta dinâmica muscular própria, adotou-se uma estratégia específica de posicionamento dos eletrodos. Essa abordagem permite que, por meio da combinação dos sinais obtidos, seja possível captar alguns movimentos básicos da mão. Neste estudo, esses movimentos são definidos como movimentos-alvo. Ressalta-se, entretanto, que, a depender da qualidade dos sinais adquiridos e dos resultados obtidos nos processos de classificação, é possível que movimentos adicionais venham a ser identificados, mesmo que não sejam estritamente necessários para aplicações práticas no dia a dia.

Os movimentos selecionados como alvo neste trabalho são:

- Abertura da mão (extensão simultânea dos dedos);
- Fechamento da mão (flexão simultânea dos dedos);
- Apontar (extensão do dedo indicador com os demais dedos flexionados);
- Pinça (flexão do polegar e do dedo indicador);
- Extensão do polegar (gesto popularmente conhecido como “beleza”);

A análise adotada terá caráter binário, isto é, determinaremos se o músculo está contraído ou relaxado. Para isso, os sinais serão captados seguindo padrões pré-estabelecidos, permitindo uma análise consistente. Assim, diferentes conjuntos de dados serão criados, cada um correspondente a uma categoria específica:

- Músculo relaxado;
- Músculo contraído;
- Movimento de contração e relaxamento com período de , aproximadamente, 10 segundos;
- Movimento de contração e relaxamento com período de , aproximadamente, 5 segundos;
- Movimento de contração e relaxamento de cada dedo individualmente, com período de , aproximadamente, 5 segundos, para analisar interferências e a individualidade dos sinais.

### 3.1 Obtenção do Sinal

Para a obtenção do sinal eletromiográfico, adotou-se inicialmente a estratégia mais simples possível, uma vez que o objetivo desta etapa consiste na análise *offline* dos dados. Assim, os *datasets* utilizados foram obtidos diretamente a partir dos sinais captados pelo sistema de aquisição EMG.

Conforme discutido ao longo deste trabalho, o sinal eletromiográfico apresenta um espectro típico compreendido entre aproximadamente 20 e 500 Hz. Dessa forma, para atender ao critério de Nyquist, é necessário que a frequência de amostragem seja, no mínimo, o dobro da maior frequência presente no sinal, resultando em uma frequência mínima de 1 kHz.

#### 3.1.1 Módulo de Aquisição EMG

No contexto deste projeto, foi desenvolvido um sensor próprio para aquisição de sinais eletromiográficos, com o objetivo de proporcionar maior escalabilidade, integração com sistemas embarcados e redução de custos, visando aplicações futuras no controle de próteses. Entretanto, por limitações de tempo, não foi possível realizar a validação experimental completa desse sensor no escopo deste trabalho.

Dessa forma, visando garantir maior confiabilidade experimental, repetibilidade dos testes e redução de variáveis não controladas, optou-se pela utilização de um módulo comercial de aquisição EMG nos experimentos apresentados. O projeto do sensor EMG desenvolvido é apresentado de forma complementar no Anexo A, não sendo essencial para a compreensão dos resultados obtidos neste estudo.

Atualmente, existem diversos módulos comerciais disponíveis no mercado para aquisição de sinais eletromiográficos (EMG). Entretanto, muitos desses módulos não são de fácil acesso ou apresentam limitações técnicas para determinadas aplicações. Durante o período de pesquisa, observou-se que diversos projetos utilizam, inclusive, módulos

originalmente projetados para eletrocardiografia (ECG), como o AD8232. Contudo, a banda de frequência do sinal de ECG difere significativamente daquela do sinal EMG, o que pode comprometer a detecção adequada de características relevantes do sinal muscular.

Um módulo amplamente citado na literatura é o MyoWare, produzido pela empresa Advancer Technologies, utilizado, por exemplo, no trabalho de Lee et al. [3], para a classificação de gestos de mão e dedos por meio de redes neurais artificiais. Apesar de suas vantagens, o módulo MyoWare apresenta elevado custo e dificuldade de aquisição no mercado nacional.

Diante dessas limitações, a alternativa adotada neste trabalho foi o *Módulo Sensor Eletromiográfico de Sinal Muscular – EMG*, mostrado na Figura 9. Uma das principais limitações desse módulo é a ausência de documentação técnica detalhada ou modelo elétrico oficial, sendo possível obter informações apenas por meio de projetos e relatos de outros usuários disponíveis na literatura informal e em fóruns técnicos.

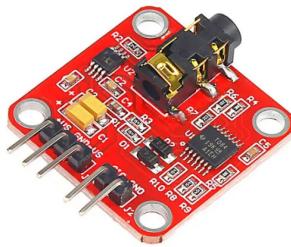


Figura 9: Módulo EMG comercial. Fonte: smartkits.com.br.

O princípio de funcionamento desse módulo é semelhante ao adotado no circuito desenvolvido neste projeto, utilizando alimentação simétrica por meio de duas baterias de 9 V, fornecendo as tensões  $+V_s$ ,  $-V_s$  e o terra de referência. O módulo é compatível com plataformas como o Arduino, apresentando saída analógica com amplitude de até 5 V. Dessa forma, para utilização com o microcontrolador ESP32, torna-se necessária uma adaptação do nível de tensão, em função das limitações do conversor analógico-digital desse dispositivo.

Para sua correta conexão, o terminal de saída (*SIG*) deve ser ligado a uma porta analógica do microcontrolador, enquanto o terminal de terra (*GND*) deve ser conectado ao terra comum do sistema.

Assim como discutido no desenvolvimento do circuito próprio, a utilização de cabos do tipo P02 para conexão dos eletrodos também representa um desafio, uma vez que não há padronização clara quanto à identificação dos terminais correspondentes ao par diferencial e ao eletrodo de referência. Após testes experimentais e análise de projetos semelhantes, foi possível identificar a configuração correta do cabo utilizado neste trabalho, conforme ilustrado na Figura 10.



Figura 10: Cabo P02 utilizado no módulo EMG. Fonte: Autoria própria.

Nesse cabo, o terminal preto identificado com a letra “L” corresponde ao eletrodo de referência, enquanto os terminais branco (“R”) e vermelho (“L”) são utilizados como par diferencial para captação do sinal EMG.

Outro ponto relevante relacionado a esse módulo diz respeito ao seu custo, que pode variar significativamente dependendo do fornecedor, alcançando valores próximos a R\$ 200,00. Esse fator reforça a motivação para o desenvolvimento de um circuito próprio de aquisição de sinais EMG, o qual apresenta potencial para redução de custos, maior flexibilidade de integração com outros sistemas e melhor adequação às necessidades específicas do projeto de prótese em desenvolvimento.

### 3.1.2 Configuração do Sistema de Aquisição

Considerando que o módulo atualmente utilizado não foi desenvolvido pelos autores, e visando manter uma margem de segurança adequada, adotou-se uma frequência de amostragem nominal de 2 kHz. Para tal, foi empregado um *Arduino Uno*. Embora esse microcontrolador não seja ideal para aplicações de processamento intensivo de sinais, em virtude de suas limitações de arquitetura e frequência de operação, ele se mostra adequado para a função de aquisição de dados via conversor analógico-digital (ADC) e transmissão das amostras por comunicação serial.

Dessa forma, foram adotados os seguintes parâmetros de aquisição:

- **Baud rate:** 230400, valor próximo ao limite máximo suportado pelo microcontrolador, possibilitando a comunicação na taxa requerida;
- **Frequência de amostragem nominal:** 2 kHz, definida a partir de um intervalo temporal de aproximadamente  $500 \mu\text{s}$  entre leituras sucessivas.

A aquisição do sinal EMG foi realizada utilizando controle temporal baseado na função `micros()` do microcontrolador. Em razão das limitações inerentes à comunicação

serial em altas taxas de amostragem, foram observadas pequenas variações no intervalo entre amostras. Assim, para a análise temporal do sinal, utilizou-se o *timestamp* registrado em cada amostra, enquanto a taxa de amostragem efetiva foi estimada a partir da média dos intervalos temporais medidos. Ressalta-se que, apesar dessas variações, a taxa de amostragem efetiva permaneceu significativamente superior ao dobro da maior frequência de interesse do sinal EMG, assegurando o atendimento ao critério de Nyquist e não comprometendo a análise de amplitude nem o conteúdo espectral do sinal.

A taxa de amostragem efetiva  $f_{s,\text{ef}}$  foi estimada a partir dos instantes temporais registrados, sendo definida como:

$$f_{s,\text{ef}} = \frac{1}{\frac{1}{N-1} \sum_{n=2}^N (t_n - t_{n-1})} \quad (3.1)$$

Considere-se  $t_n$  o instante temporal da  $n$ -ésima amostra, com  $n = 1, 2, \dots, N$ . Sendo  $N$  então o número total de amostras adquiridas.

A utilização do valor médio dos intervalos temporais permite reduzir a influência de pequenas variações no tempo de aquisição, fornecendo uma estimativa representativa da taxa de amostragem do sistema.

O código utilizado realiza o envio, via interface de comunicação serial, do instante temporal correspondente a cada amostra, juntamente com o valor obtido pelo ADC. O referido código encontra-se disponível no repositório GitHub associado a este trabalho, sob o nome `ADC_EMG.ino`.

Para a construção do *dataset*, foi desenvolvida uma rotina em Python executada na mesma máquina em que o Arduino está conectado. O objetivo é ler continuamente os dados enviados pelo monitor serial e salvá-los em um arquivo `.csv`. Como a saída do Arduino foi previamente padronizada para imprimir sempre os valores no formato `tempo,valor`, separados por vírgula, a criação do arquivo torna-se direta. As colunas foram nomeadas como `tempo_arduino_micro_s` e `valor_ADC`.

Devemos levar em consideração as características do conversor ADC do Arduino Uno que será utilizado, para compreendermos nossos resultados. Como já mencionado, o módulo empregado foi projetado para se adequar à tensão do Arduino Uno, assim como a maioria dos módulos comerciais. Para o ADC do Arduino Uno, temos:

- **Número de Bits:** 10 bits, o que significa que o conversor gera  $2^{10} = 1024$  níveis discretos. Como a contagem inicia em zero, o valor máximo será 1023.
- **Faixa de Tensão:** 0 V a 5 V.

- **Resolução:** A resolução em tensão é dada por:

$$\text{Resolução} = \frac{5 \text{ V}}{1024} \approx 0,0049 \text{ V (4,9 mV por unidade)}.$$

**Observação:** Ao longo deste trabalho, os valores provenientes do conversor analógico-digital serão frequentemente expressos em unidades do próprio ADC, as quais serão denotadas por **uADC**.

Dessa forma, toda a infraestrutura necessária para captura e armazenamento dos dados já está implementada. O próximo passo consiste em definir as configurações desejadas e iniciar o processo de aquisição dos sinais.

### 3.2 Análise do Sinal - Original

A alocação dos eletrodos envolve uma abordagem que combina o conhecimento anatômico com uma análise empírica. Diversos dedos compartilham compartimentos musculares comuns, como os músculos *flexor digitorum superficialis* e *flexor digitorum profundus*, o que resulta na sobreposição de sinais nos eletrodos, além da presença de *cross-talk* e das limitações inerentes à relação sinal-ruído do EMG superficial. Mesmo com o posicionamento adequado dos eletrodos sobre o ventre muscular, o sinal EMG superficial sofre interferência proveniente de músculos adjacentes, fenômeno conhecido como *cross-talk*. Tal efeito é intensificado pela elevada densidade muscular do antebraço e pela propagação difusa dos potenciais elétricos através do tecido subcutâneo.

Dessa forma, a estratégia de posicionamento não pode se restringir apenas à identificação do músculo responsável pela principal função motora do dedo analisado, sendo necessário considerar conjuntamente os efeitos de interferência, sobreposição de sinais e variabilidade anatômica. A combinação do estudo anatômico com a análise empírica, incluindo a palpação do antebraço durante a execução dos movimentos, permite identificar regiões de maior ativação muscular. Essa abordagem integrada é utilizada para a determinação dos pontos mais adequados para a captação do sinal.

Os eletrodos destinados à análise diferencial devem ser posicionados sobre o ventre muscular, mantendo-se uma distância aproximada de 2 a 3 cm entre si. O eletrodo de referência, por sua vez, deve ser colocado em uma região de baixa atividade elétrica, preferencialmente sobre uma proeminência óssea; neste trabalho, foi adotado o posicionamento no cotovelo.

A utilização do par diferencial tem como principal objetivo a redução do ruído presente no sinal adquirido, conforme discutido no Capítulo referente ao Projeto do Sensor EMG. Para maximizar a rejeição em modo comum (CMRR), é fundamental que os dois eletrodos do par estejam submetidos a condições elétricas e ambientais semelhantes. Assim, optou-se pelo posicionamento sobre regiões amplas do ventre muscular, evitando áreas

próximas à inserção tendínea. Quanto maior a similaridade do ambiente elétrico ao qual ambos os eletrodos estão expostos, maior será a eficácia da rejeição do sinal em modo comum. Esse aspecto mostrou-se particularmente relevante em músculos cuja amplitude de contração é relativamente reduzida, uma vez que o sinal diferencial resulta da subtração entre os sinais captados.

Para ilustrar esse conceito, o processo pode ser comparado à medição de tensão em dois pontos distintos de uma linha de transmissão utilizando um voltímetro. Caso esses pontos estejam excessivamente distantes, a atenuação da linha pode distorcer o sinal, reduzindo sua magnitude em relação ao ponto de entrada. Dessa forma, torna-se necessário manter uma distância relativamente curta entre os pontos de medição.

Nessa analogia, consideram-se dois pontos monitorados ao longo da linha e um sinal de entrada. Seja  $V_{in}$  o sinal aplicado na entrada da linha,  $v_1$  a tensão medida no primeiro ponto e  $v_2$  a tensão medida no segundo ponto, conforme ilustrado na Figura 12.

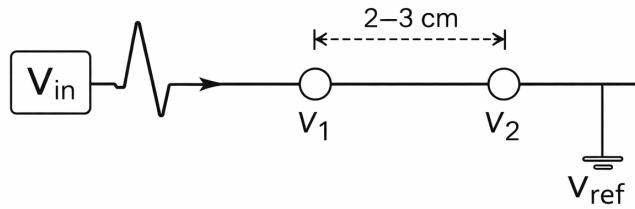


Figura 11: Analogia entre a disposição dos eletrodos e uma linha de transmissão. Fonte: Autoria Própria

Se  $V_{in}$  for um impulso, o sinal diferencial  $v_1 - v_2$ , referenciado ao potencial de terra (0 V), apresentará um valor positivo no instante em que o impulso atinge o ponto  $v_1$  e um valor negativo quando atingir o ponto  $v_2$ . A análise do sinal muscular segue a mesma lógica, sendo que, neste caso, a “linha de transmissão” corresponde ao próprio músculo.

Dessa forma, as configurações de posicionamento adotadas foram validadas a partir desse conjunto de critérios, garantindo sua adequação para a análise proposta neste trabalho.

Para fins de demonstração, a análise inicial será apresentada considerando apenas a primeira configuração de posicionamento dos eletrodos, de modo a evitar repetições desnecessárias. Nesta etapa, será analisado o sinal eletromiográfico em sua forma original, conforme adquirido pelo sistema e antes da aplicação de qualquer técnica de processamento.

O objetivo dessa análise é avaliar as características do sinal bruto à medida que ele é recebido pelo computador, bem como identificar os principais componentes espectrais e as limitações associadas à sua qualidade. Para isso, será apresentado o espectro de frequência completo do sinal, e não na forma de spectrograma, uma vez que essa abordagem permite uma comparação mais direta entre o sinal original e o sinal após a aplicação dos filtros, além de oferecer elevada resolução espectral.

Posteriormente, serão apresentados os procedimentos de filtragem adotados e, em seguida, a análise do sinal já processado, mantendo-se a coerência metodológica e evitando redundâncias ao longo do capítulo.

### 3.2.1 Primeira Configuração — Original

A primeira configuração foi instalada sobre o músculo *Flexor Carpi Radialis*. O posicionamento dos eletrodos foi definido com base em informações anatômicas obtidas no site CY Vigor, bem como nas descrições apresentadas no livro *Atlas of Pain Management Injection Techniques* (Fourth Edition, 2023), de Steven D. Waldman [14], e no *Netter: Atlas of Human Anatomy* [13]. Essas referências foram utilizadas para identificar o trajeto do músculo, sua função motora e sua relação com estruturas adjacentes, orientando o posicionamento adequado dos eletrodos sobre a anatomia superficial do antebraço.

O músculo *Flexor Carpi Radialis* localiza-se na região anterior do antebraço e tem como principais funções a flexão e a abdução do punho. Ele se origina no epicôndilo medial do úmero e percorre o antebraço adjacente ao músculo *flexor digitorum superficialis*, inserindo-se na base do segundo metacarpo, além de apresentar inserções secundárias em estruturas próximas. O músculo é inervado pelo nervo mediano, característica relevante para a análise do sinal eletromiográfico.

Dessa forma, o *Flexor Carpi Radialis* apresenta-se como um ponto de partida adequado para o estudo, por se tratar de um músculo relativamente volumoso e superficial, o que favorece a captação e a análise dos sinais EMG. O posicionamento dos eletrodos adotado nesta configuração é ilustrado na Figura 12.

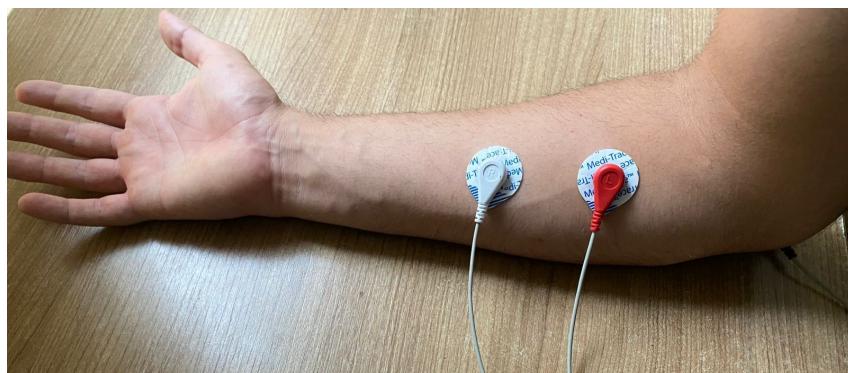


Figura 12: Posicionamento dos eletrodos no músculo *Flexor Carpi Radialis*. Fonte: Autoria Própria

Os códigos e os *datasets* referentes a esta análise encontram-se disponíveis no repositório GitHub do projeto.

**Observação:** Para os gráficos do sinal no domínio da frequência, sempre iremos mostrar os eixos normalizados. Ou seja, sendo  $X[k]$  a Transformada Discreta de Fourier (DFT) do sinal  $x[n]$ , a normalização será feita da seguinte forma:

$$X_{\text{norm}}[k] = \frac{X[k]}{\sum_{b=0}^{N-1} X[b]} \quad (3.2)$$

em que,  $N$  é o número total de amostras do sinal no domínio do tempo. Essa normalização garante que a escala do espectro seja proporcional à energia do sinal original, facilitando a comparação entre diferentes sinais.

Outro ponto relevante é que, como o sinal possui um grande número de amostras e, nesta etapa inicial, será analisado em sua totalidade, a resolução da Transformada Discreta de Fourier (DFT) torna-se bastante elevada. A resolução em frequência é dada por:

$$\Delta f = \frac{f_s}{N}, \quad (3.3)$$

em que,  $f_s$  representa a frequência de amostragem e  $N$  o número total de amostras do sinal. Dessa forma, quanto maior for o valor de  $N$ , menor será o espaçamento entre os pontos do espectro, resultando em uma análise espectral mais detalhada e precisa. No limite, quando  $N \rightarrow \infty$ , tem-se  $\Delta f \rightarrow 0$ , caracterizando uma representação espectral com resolução arbitrariamente alta.

Em sinais adquiridos por meio de microcontroladores, é comum a presença de uma componente DC (offset) significativa. Tal efeito decorre principalmente do fato de que esses sistemas operam com sinais unipolares, não representando diretamente amplitudes negativas. Como consequência, essa componente média tende a dominar o espectro, inviabilizando a análise das demais componentes de interesse no domínio da frequência.

Por esse motivo, optou-se pela remoção da componente média do sinal, procedimento equivalente à aplicação de um filtro passa-altas simples. Seja  $s[n]$  o sinal original no domínio do tempo, a remoção da componente DC é dada por:

$$s'[n] = s[n] - \frac{1}{N} \sum_{n=0}^{N-1} s[n], \quad (3.4)$$

em que,  $N$  corresponde ao número total de amostras do sinal.

Dessa forma, com o objetivo de melhorar a análise espectral, todos os sinais apresentados a partir deste ponto já terão a componente média removida. Sem esse procedimento, a extração de informações relevantes a partir do espectro do sinal EMG torna-se significativamente prejudicada.

Na sequência, será apresentada a análise dos sinais correspondentes a cada padrão de aquisição descrito anteriormente.

### 3.2.2 Análise dos sinais - Original — Configuração 1

A Figura 13 apresenta os sinais eletromiográficos adquiridos para a Configuração 1, utilizando um *dataset* representativo para cada padrão de movimento, no domínio do

tempo e da frequência, considerando cinco condições experimentais: músculo relaxado, músculo contraído, contração e relaxamento com períodos de 10 s e 5 s, e movimentação individual dos dedos.

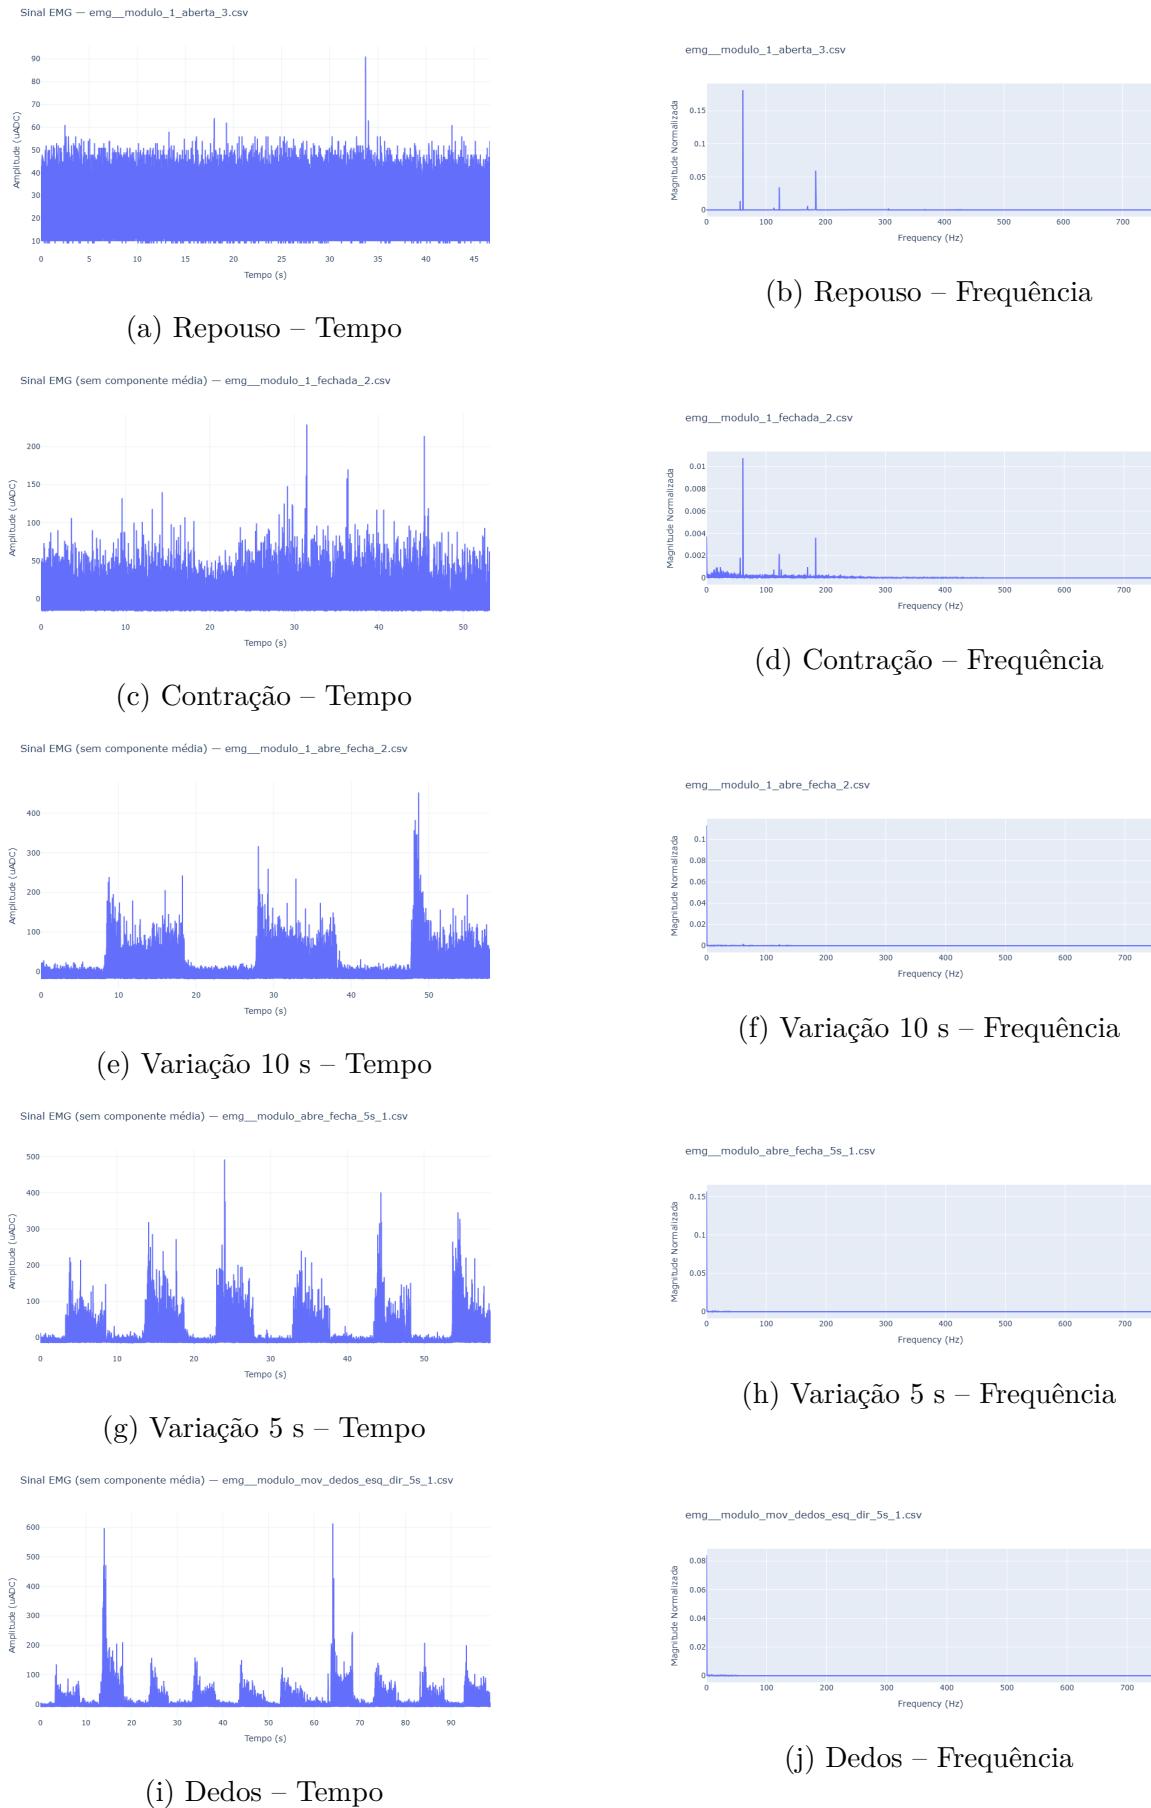


Figura 13: Matriz comparativa dos sinais EMG no domínio do tempo (coluna esquerda) e da frequência (coluna direita) para as cinco variações de movimento analisadas — Configuração 1. Fonte: Autoria Própria.

No estado de repouso, observa-se no domínio da frequência a predominância da componente em 60 Hz e de suas harmônicas, associadas à interferência da rede elétrica, comportamento típico em sistemas de aquisição de sinais biomédicos. A baixa potência nas demais faixas confirma a ausência de ativação muscular significativa nessa condição.

Para o músculo contraído, o sinal no domínio do tempo apresenta aumento expressivo de amplitude e energia, refletindo a ativação muscular. No domínio da frequência, surgem componentes adicionais distribuídas ao longo da banda característica do sinal EMG, embora ainda sejam observadas componentes em baixas frequências, próximas à frequência zero.

Nos *datasets* com variação periódica entre contração e relaxamento, tanto para períodos de 10 s quanto de 5 s, verifica-se uma clara distinção entre os estados musculares no domínio do tempo. O comportamento espectral é semelhante em ambos os casos, indicando que a redução do período não compromete a identificação dos estados, aspecto relevante para aplicações práticas.

No caso da movimentação individual dos dedos, a sequência temporal dos movimentos não é explicitamente indicada no gráfico, sendo, portanto, descrita na Tabela 1, que apresenta os intervalos de tempo e os respectivos estados musculares adotados durante o experimento.

Tabela 1 – Sequência temporal da movimentação individual dos dedos com período de 5 s — Configuração 1

Intervalo de tempo (s)	Estado	Descrição do movimento
0 – 5	Repouso	Todos os dedos estendidos
5 – 10	Contração	Mindinho
10 – 15	Repouso	Todos os dedos estendidos
15 – 20	Contração	Anelar
20 – 25	Repouso	Todos os dedos estendidos
25 – 30	Contração	Dedo médio
30 – 35	Repouso	Todos os dedos estendidos
35 – 40	Contração	Indicador
40 – 45	Repouso	Todos os dedos estendidos
45 – 50	Contração	Polegar
50 – 55	Repouso	Todos os dedos estendidos
55 – 60	Contração	Indicador
60 – 65	Repouso	Todos os dedos estendidos
65 – 70	Contração	Dedo médio
70 – 75	Repouso	Todos os dedos estendidos
75 – 80	Contração	Anelar
80 – 85	Repouso	Todos os dedos estendidos
85 – 90	Contração	Mindinho

Por fim, na movimentação individual dos dedos, conforme a sequência definida na Tabela 1, observa-se a presença significativa de *cross-talk*, resultado esperado, uma vez que

o músculo analisado não é responsável pela flexão isolada de um único dedo. Ainda assim, variações de amplitude associadas aos diferentes dedos podem ser identificadas, com maior destaque para o dedo anelar.

De forma geral, a análise dos sinais sem filtragem evidencia a presença de interferências da rede elétrica, componentes indesejadas em baixas frequências e efeitos de *cross-talk*, justificando a necessidade da aplicação de técnicas de filtragem adequadas, abordadas na etapa seguinte.

### 3.3 Filtro

#### 3.3.1 Passa-Faixa

Para melhorar a qualidade das informações extraídas do sinal EMG, é necessária a aplicação de técnicas de filtragem digital. Conforme discutido anteriormente, a banda de interesse para este tipo de sinal se encontra, em geral, entre aproximadamente 20 e 500 Hz. Portanto, o filtro adotado neste trabalho possui frequência de corte inferior ligeiramente abaixo de 20 Hz, a fim de rejeitar eficientemente componentes indesejados de muito baixa frequência.

A escolha do tipo de filtro digital envolve fatores clássicos: qual arquitetura utilizar (FIR ou IIR), qual ordem, como lidar com o atraso introduzido e como a implementação embarcada será afetada. Esses pontos se tornam especialmente importantes considerando que o projeto final será executado em hardware embarcado, com recursos limitados e exigência de processamento em tempo real. Assim, é necessária uma análise criteriosa.

Optou-se pela construção de um filtro passa-faixa utilizando a biblioteca *SciPy* em Python, que facilita o projeto e a simulação da resposta do filtro. Antes da implementação embarcada, é fundamental caracterizar e compreender a resposta em frequência do filtro projetado.

Como o sistema final deverá processar um grande volume de dados em tempo real, é desejável utilizar o menor número possível de coeficientes. Por esse motivo, selecionou-se um filtro IIR (Infinite Impulse Response) em vez de um FIR (Finite Impulse Response). Para obter uma resposta em frequência comparável, um filtro FIR exigiria um número muito maior de coeficientes, o que aumentaria o custo computacional. Embora o FIR ofereça fase linear, o que é uma vantagem, neste projeto prioriza-se a eficiência computacional e a possibilidade de implementação embarcada. A questão da fase não linear do IIR será discutida e devidamente tratada ao longo do trabalho.

Assim, as especificações do filtro adotado são:

- Tipo Butterworth
- Ordem 8

- Frequência de corte inferior: 20 Hz
- Frequência de corte superior: 500 Hz

A Figura 14 apresenta a resposta em magnitude e o atraso de grupo do filtro IIR Butterworth, parâmetros fundamentais para a análise inicial do seu comportamento em termos de seletividade espectral e distorção temporal.

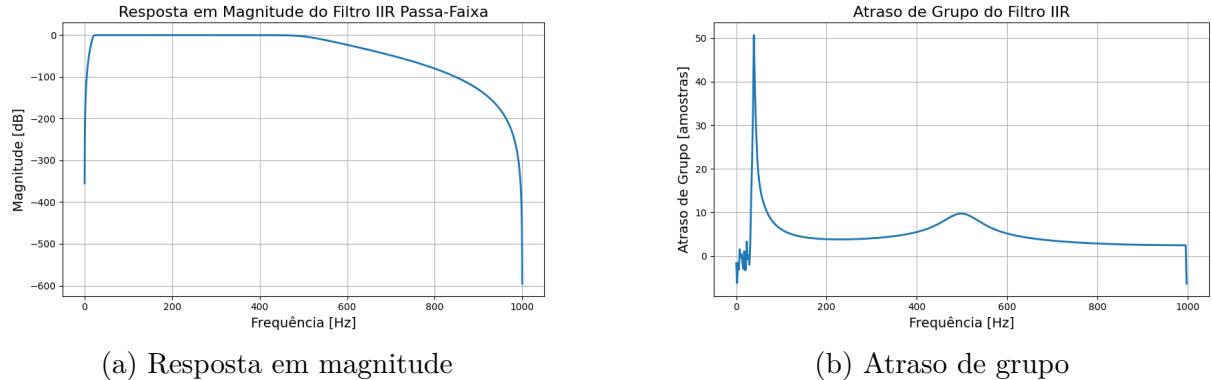


Figura 14: Filtro IIR Butterworth — Resposta em magnitude e atraso de grupo. Fonte: Autoria Própria.

A resposta em magnitude mostra que, mesmo com uma ordem relativamente baixa, o filtro apresenta boa rejeição fora da banda passante. Um dos principais problemas encontrados nos sinais originais é a presença de componentes de baixa frequência (próximas de 0 Hz) com amplitudes elevadas, o que dificulta a análise do sinal. O filtro projetado atenua fortemente essas componentes, apresentando uma transição rápida até atingir a banda de passagem inferior. Na região acima de 500 Hz, a rejeição ainda é adequada; além disso, as amplitudes nessas frequências geralmente não possuem grande relevância no contexto do EMG analisado.

O atraso de grupo evidencia que a fase do filtro não é linear, o que é uma característica esperada de filtros IIR. Observa-se que o atraso varia conforme a frequência, indicando que o filtro distorce a forma de onda no domínio do tempo. Em sinais em que a morfologia exata é essencial — como ECG — esse comportamento poderia representar um problema. Entretanto, para EMG, o formato exato da onda não possui a mesma importância; a informação relevante está principalmente na energia instantânea do sinal.

Diante desse compromisso entre complexidade computacional e linearidade de fase, adotou-se a estratégia de treinar o modelo de classificação utilizando o próprio sinal filtrado com o IIR. Dessa forma, o modelo aprende a lidar naturalmente com o atraso introduzido pelo filtro. Paralelamente, durante o desenvolvimento, também será utilizada a técnica de filtragem com fase zero (`signal.sosfiltfilt`), que elimina o atraso ao custo de não ser causal, exigindo acesso a amostras futuras. Isso permite comparar o comportamento do modelo quando aplicado ao sinal com fase não linear versus ao sinal sem distorção

de fase, possibilitando validar se os momentos de contração e relaxamento detectados correspondem à realidade. Assim, minimiza-se o impacto da distorção de fase do IIR, obtendo um equilíbrio entre eficiência computacional e fidelidade temporal.

Cabe destacar que o filtro foi projetado na forma de seções de segunda ordem (SOS, *Second Order Sections*), o que é relevante para a implementação embarcada, pois aumenta a estabilidade numérica e facilita o uso em microcontroladores.

### 3.3.2 Rejeita-Faixa

Conforme demonstrado nas análises espectrais anteriores, observa-se a presença significativa das componentes harmônicas associadas à rede elétrica, centradas em 60 Hz e seus múltiplos. À primeira vista, seria natural considerar a aplicação de filtros do tipo rejeita-faixa (*notch*) para a remoção dessas interferências. Entretanto, a implementação dessa abordagem exigiria o uso de múltiplos filtros para atenuar não apenas a componente fundamental, mas também seus harmônicos, o que acarretaria um aumento considerável da complexidade do sistema.

Além disso, a aplicação sucessiva de filtros rejeita-faixa introduziria distorções adicionais de fase, somando-se àquelas já inerentes ao filtro passa-faixa empregado no processamento do sinal. Tal efeito é particularmente indesejável neste projeto, uma vez que o modelo final possui como objetivo a implementação embarcada, na qual a complexidade computacional e a preservação das características temporais do sinal são fatores críticos.

Outro ponto relevante é que essas componentes espectrais associadas à rede elétrica estão presentes tanto durante os períodos de contração quanto de relaxamento muscular. Ou seja, apesar de sua elevada potência, tais interferências mantêm-se aproximadamente invariantes em relação ao estado do músculo, não comprometendo de forma significativa a discriminação entre os padrões de movimento. Essa característica torna-se ainda mais evidente nas análises por meio de espectrogramas, nas quais se observa que as componentes em torno de 60 Hz se estendem ao longo de todo o tempo de aquisição, independentemente da atividade muscular executada.

Dessa forma, optou-se por não empregar filtros rejeita-faixa adicionais. Essa decisão também está alinhada com o objetivo do trabalho, que consiste na aquisição de sinais EMG para o treinamento de modelos de aprendizado de máquina robustos a condições reais de operação. A remoção excessiva de componentes espectrais poderia, inclusive, eliminar informações relevantes para a correta classificação dos movimentos, prejudicando o desempenho do sistema em cenários práticos.

Um ponto que merece destaque diz respeito ao uso de amplificadores diferenciais na aquisição do sinal EMG. Em teoria, a principal vantagem dessa configuração é a elevada rejeição de sinais em modo comum, quantificada pela razão de rejeição de modo comum (*Common-Mode Rejection Ratio* — CMRR). O CMRR é definido como a razão entre o

ganho diferencial e o ganho em modo comum, sendo expresso por:

$$\text{CMRR} = 20 \log_{10} \left( \frac{A_d}{A_{cm}} \right) \quad (3.5)$$

em que,  $A_d$  representa o ganho diferencial e  $A_{cm}$  o ganho em modo comum.

Apesar de o módulo EMG empregar um amplificador diferencial com alto CMRR, observa-se que a interferência da rede elétrica não é completamente eliminada. Esse comportamento pode ser atribuído a diversos fatores, como diferenças de impedância entre os eletrodos de superfície, acoplamentos capacitivos não uniformes, ruídos induzidos pelos cabos de conexão e, principalmente, ao fato de que o CMRR é finito e dependente da frequência, tendendo a se degradar em frequências próximas à da rede elétrica.

Portanto, a presença residual da componente de 60 Hz no sinal adquirido é esperada e coerente com sistemas reais de aquisição EMG, não comprometendo a análise proposta neste trabalho.

### 3.4 Análise do Sinal — Filtrado

Com o filtro devidamente caracterizado, prossegue-se com a análise dos sinais eletromiográficos após a etapa de filtragem. Nesta seção, são considerados tanto o sinal filtrado de forma causal, utilizando o filtro IIR com fase não linear, quanto o sinal obtido por meio da filtragem com fase zero. Essa comparação permite avaliar se a distorção de fase introduzida pelo filtro causal exerce impacto relevante sobre a análise proposta, além de possibilitar a visualização clara das diferenças entre as abordagens no domínio do tempo.

Adicionalmente, será empregada a análise por meio de espectrogramas, uma vez que o sinal EMG apresenta variação significativa ao longo do tempo. Essa ferramenta é particularmente adequada para esse tipo de sinal, pois fornece uma representação conjunta das componentes espetrais em função do tempo, permitindo uma análise mais completa da distribuição de energia ao longo da duração do sinal.

No capítulo seguinte, intitulado “**Extração de Features**”, será detalhado o processo de definição do tamanho dos frames, do espaçamento entre janelas (*hop length*) e da janela de ponderação utilizada. Entretanto, como nesta etapa o objetivo principal é a análise qualitativa do comportamento espectral do sinal filtrado, esses parâmetros serão adotados sem uma justificativa aprofundada, a qual será apresentada posteriormente. Assim, consideram-se os seguintes valores:

- **Tamanho do frame (Frame Size):** 1024 amostras, correspondendo a aproximadamente 0,52 s.

- **Tamanho do pulo (Hop Length):** 256 amostras, resultando em aproximadamente 0,13 s entre janelas consecutivas.
- **Resolução da DFT:**  $F_s/N = 1,94$  Hz.

A análise do sinal filtrado é realizada a partir da construção de espectrogramas. Esse tipo de representação é especialmente relevante para sinais não periódicos, como o EMG, pois fornece uma visualização tridimensional da potência espectral em função do tempo e da frequência. Para a obtenção dos espectrogramas, aplica-se a Transformada Discreta de Fourier (DFT) a cada frame do sinal, com janelas deslocadas de acordo com o *hop length*, permitindo a análise contínua do conteúdo espectral ao longo do tempo.

Para a geração dos espectrogramas, foi utilizada a biblioteca **Librosa**. O sinal foi elevado ao quadrado com o objetivo de representar uma grandeza proporcional à potência, uma vez que os valores provenientes do conversor analógico-digital correspondem a tensões, e a potência é proporcional ao quadrado da tensão. Em seguida, os valores de potência foram convertidos para a escala de decibéis, e o eixo de frequência foi representado em escala logarítmica.

Como a biblioteca utilizada não permite a personalização direta dos rótulos dos eixos, adotou-se a seguinte padronização:

- **Eixo X:** tempo (em segundos);
- **Eixo Y:** frequência (em Hz);
- **Eixo Z:** potência (em dB).

Na sequência, são apresentados os gráficos do sinal filtrado tanto com fase não linear (filtro causal) quanto com fase zero (filtro não causal). No domínio do tempo, são analisadas as formas de onda resultantes, enquanto no domínio da frequência a análise é realizada por meio dos espectrogramas. Esses resultados são apresentados para cada padrão de movimento previamente definido, considerando suas respectivas configurações de posicionamento dos eletrodos.

A utilização conjunta das versões causal e de fase zero permite avaliar o impacto da resposta de fase do filtro sobre a preservação dos instantes de transição entre os estados de contração e relaxamento. Em particular, a filtragem com fase zero é empregada como referência para verificar se os instantes de alteração do estado muscular são mantidos mesmo na presença de distorções de fase introduzidas pelo filtro causal.

### 3.4.1 Primeira Configuração - Filtrada

A Figura 15 apresenta os sinais EMG da Configuração 1 após a aplicação do filtro IIR Butterworth, organizados em uma matriz comparativa contendo, para cada padrão de

movimento analisado, o sinal filtrado por meio de um filtro causal, o sinal filtrado com fase zero (não causal) e o respectivo spectrograma.

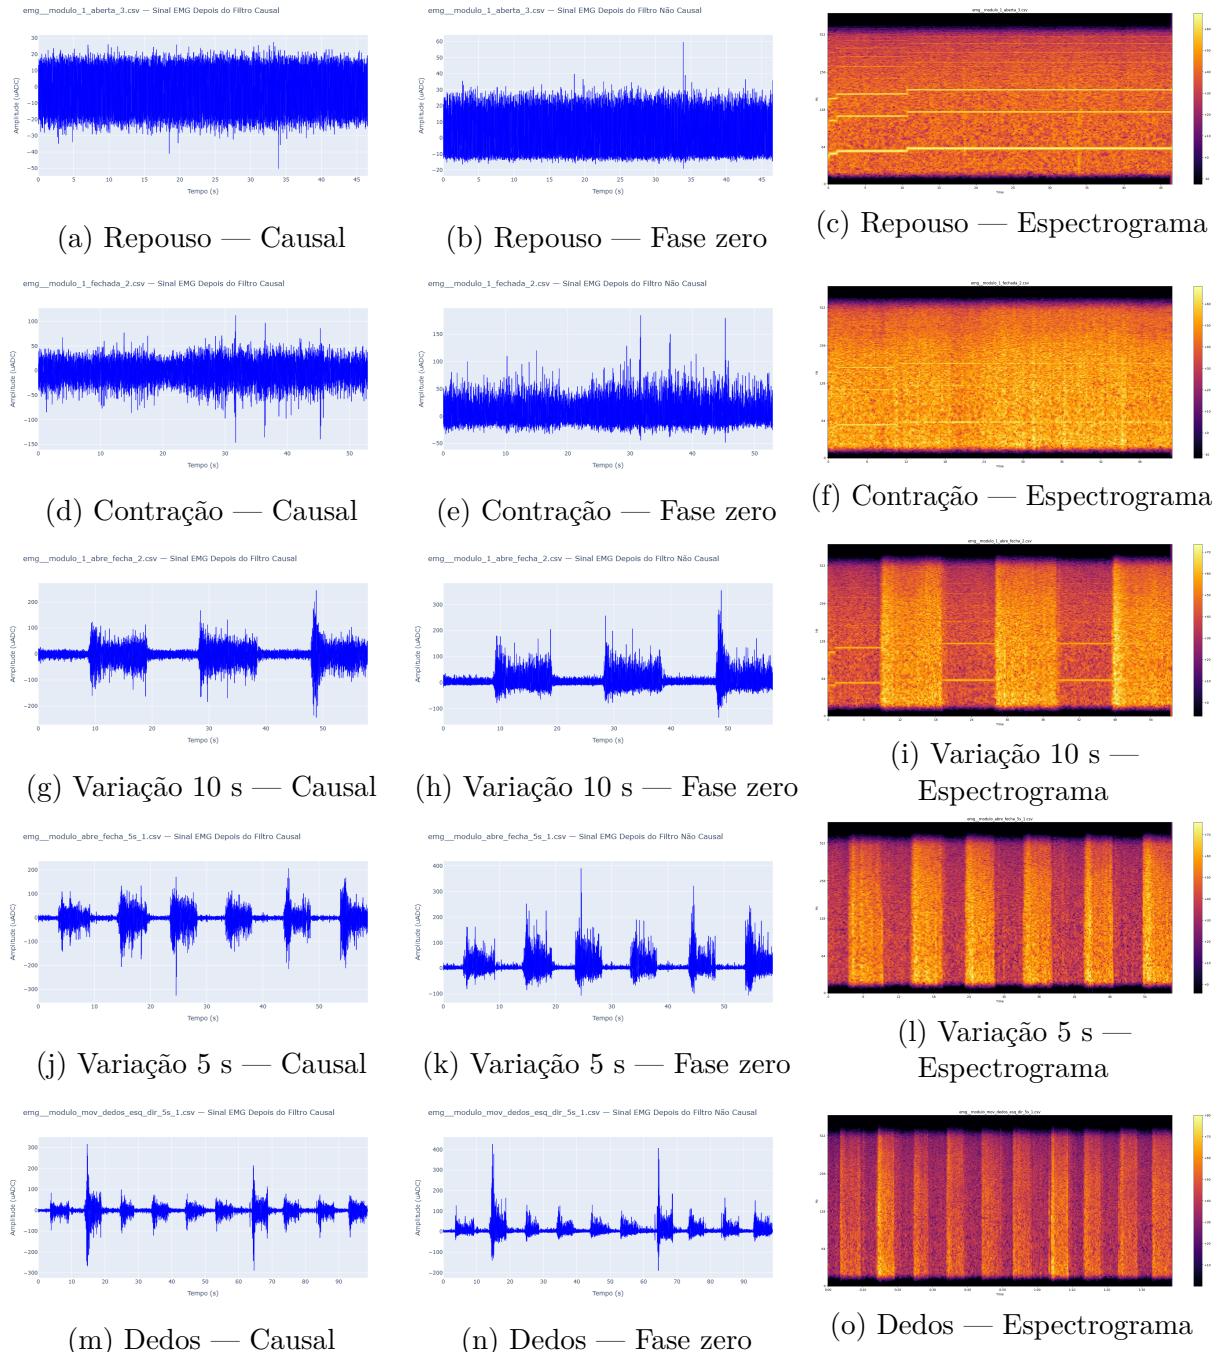


Figura 15: Matriz comparativa dos sinais EMG filtrados da Configuração 1: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria.

A análise detalhada dos sinais no domínio do tempo e da frequência para os dados não filtrados foi apresentada na seção anterior. Assim, nesta etapa, o foco recai exclusivamente sobre os efeitos introduzidos pelo processo de filtragem.

De modo geral, no domínio do tempo, observa-se que a aplicação do filtro não

altera significativamente as características essenciais dos sinais EMG, independentemente do padrão de movimento considerado. Tal comportamento já era esperado, uma vez que, mesmo nos sinais originais, os instantes de ativação muscular podiam ser identificados principalmente por variações de amplitude. Após a filtragem, os sinais obtidos por meio das versões causal e não causal apresentam elevada semelhança no contexto global, diferindo sobretudo por deslocamentos temporais e inversões de fase associadas à resposta de fase não linear do filtro causal. Essas diferenças, entretanto, não comprometem a identificação dos instantes de contração e relaxamento, uma vez que os momentos de alteração de estados são mantidos.

No domínio espectral, os espectrogramas evidenciam que as componentes fora da banda de passagem do filtro são atenuadas de forma consistente, enquanto as faixas de frequência associadas à atividade muscular permanecem preservadas. Para condições estáticas, como músculo relaxado ou contraído, a distribuição de potência ao longo do tempo mantém-se relativamente estável, com predominância de potência concentrada nas proximidades dos harmônicos associados à interferência da rede elétrica, em torno de 60 Hz. Para movimentos dinâmicos, como as variações periódicas de contração e relaxamento e a movimentação individual dos dedos, o espectrograma destaca claramente as transições entre estados, caracterizadas por aumentos globais de potência ao longo de praticamente toda a faixa de frequências durante a ativação muscular.

Cabe destacar que a presença de harmônicos bem definidos durante os períodos de relaxamento não se mostra consistente em todos os conjuntos de dados analisados. Em alguns casos, tais componentes não são claramente observadas nos espectrogramas, o que indica que essa característica não constitui um padrão fixo. Esse comportamento pode estar associado ao fato de os *datasets* terem sido adquiridos em momentos distintos, além de fatores como alterações na impedância da pele, presença de suor, fadiga muscular ou mesmo à eficiência do CMRR do par diferencial, que pode ter atenuado essas interferências quando suas amplitudes eram suficientemente reduzidas. Ainda assim, a análise baseada na distribuição de potência por faixas de frequência permanece válida, uma vez que captura variações relevantes associadas aos diferentes estados musculares, mesmo na ausência de componentes harmônicas evidentes.

Por fim, no caso da movimentação individual dos dedos, conforme a sequência temporal apresentada na Tabela 1, observa-se que o posicionamento do sensor resulta em maior sensibilidade à ativação do dedo anelar, embora contribuições dos demais dedos também sejam identificáveis. Esse comportamento indica que, apesar da predominância da atividade de determinados músculos, o sinal contém informações suficientes para a inferência de movimentos mais complexos quando combinado com outras configurações de eletrodos, aspecto que será explorado nas etapas subsequentes de extração de *features* e classificação.

### 3.4.2 Segunda Configuração — Filtrada

Nesta segunda configuração, buscou-se priorizar a captação de sinais relacionados ao polegar, com o objetivo de isolá-lo o máximo possível em relação aos demais músculos do antebraço. Após extensa revisão bibliográfica, constatou-se que o músculo *Flexor Pollicis Longus* (FPL) constitui um dos principais responsáveis pelos movimentos do polegar, sendo, portanto, um candidato adequado para este estudo.

Como principal referência anatômica, utilizou-se o livro *The Muscle and Bone Palpation Manual*, de Muscolino [15], amplamente empregado na área da fisioterapia. Esse material apresenta descrições detalhadas dos músculos, incluindo imagens e orientações práticas para a localização e palpação dos ventres musculares.

De acordo com essa referência, o músculo FPL possui como funções principais a flexão do polegar nas articulações carpometacarpal (CMC), metacarpofalangeana (MCP) e interfalangeana (IP). Além disso, contribui para a flexão da mão na articulação do punho e auxilia na flexão do antebraço na articulação do cotovelo, embora essas funções secundárias sejam menos relevantes no contexto deste trabalho.

A Figura 16 foi fundamental para a correta localização do ventre muscular do FPL durante a flexão do polegar na articulação interfalangeana. A imagem ilustra a palpação do ventre do músculo *Flexor Pollicis Longus* da mão direita, com o músculo *Pronator Quadratus* representado de forma translúcida, facilitando a identificação das estruturas envolvidas.



Figura 16: Palpação do ventre do músculo *Flexor Pollicis Longus* da mão direita. Fonte: Muscolino [15].

Com base nessa referência anatômica, foram testadas diversas posições para o posicionamento dos eletrodos. Pequenas variações na localização dos eletrodos podem resultar em diferenças significativas nos sinais adquiridos. Durante todos os testes, o eletrodo de referência foi mantido na região do cotovelo, local caracterizado por baixa atividade mioelétrica devido à predominância de tecido ósseo, o que contribui para a redução de ruídos comuns ao sinal.

A configuração final adotada para o posicionamento dos eletrodos no músculo FPL é apresentada na Figura 17, a partir da qual se procedeu à coleta dos dados experimentais utilizados neste trabalho.

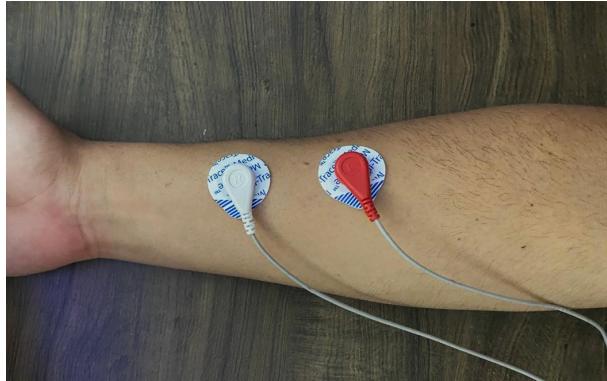


Figura 17: Posicionamento dos eletrodos no músculo *Flexor Pollicis Longus* da mão direita. Fonte: Autoria Própria.

A partir dessa disposição, foram realizadas as coletas de dados empregadas nas etapas subsequentes de processamento e classificação dos sinais.

A Figura 18 apresenta os sinais EMG da Configuração 2 após a aplicação do filtro IIR Butterworth, organizados em uma matriz comparativa contendo, para cada padrão de movimento analisado, o sinal filtrado por meio de um filtro causal, o sinal filtrado com fase zero (não causal) e o respectivo espectrograma.

De forma geral, no domínio do tempo, observa-se que os sinais filtrados apresentam comportamento compatível com os estados musculares analisados. Na condição de músculo relaxado, caracterizada pela extensão de todos os dedos, o sinal apresenta baixa amplitude, atingindo aproximadamente  $\pm 60$  uADC no caso da filtragem causal. Já na condição de músculo contraído, associada à flexão do polegar com os demais dedos estendidos, verifica-se um aumento significativo da amplitude do sinal, alcançando valores superiores a 200 uADC em módulo. Em ambos os casos, as versões causal e não causal da filtragem apresentam elevada semelhança global, diferindo principalmente por deslocamentos temporais e inversões de fase decorrentes da resposta de fase não linear do filtro causal, sem prejuízo à identificação dos instantes de ativação muscular.

Nos padrões de movimento dinâmico, nos quais o polegar alterna entre extensão e flexão com períodos de aproximadamente 10 s e 5 s, enquanto os outros dedos permanecem estendidos, a variação de amplitude entre os estados de relaxamento e contração mostra-se clara e bem definida no domínio do tempo. Para o período de 10 s, observa-se boa rejeição de ruído durante os intervalos de repouso, com amplitudes significativamente reduzidas fora dos instantes de contração. Já no caso do período de 5 s, nota-se uma amplitude proporcionalmente maior durante os intervalos de relaxamento, indicando aumento de energia residual possivelmente associado à menor recuperação muscular entre contrações

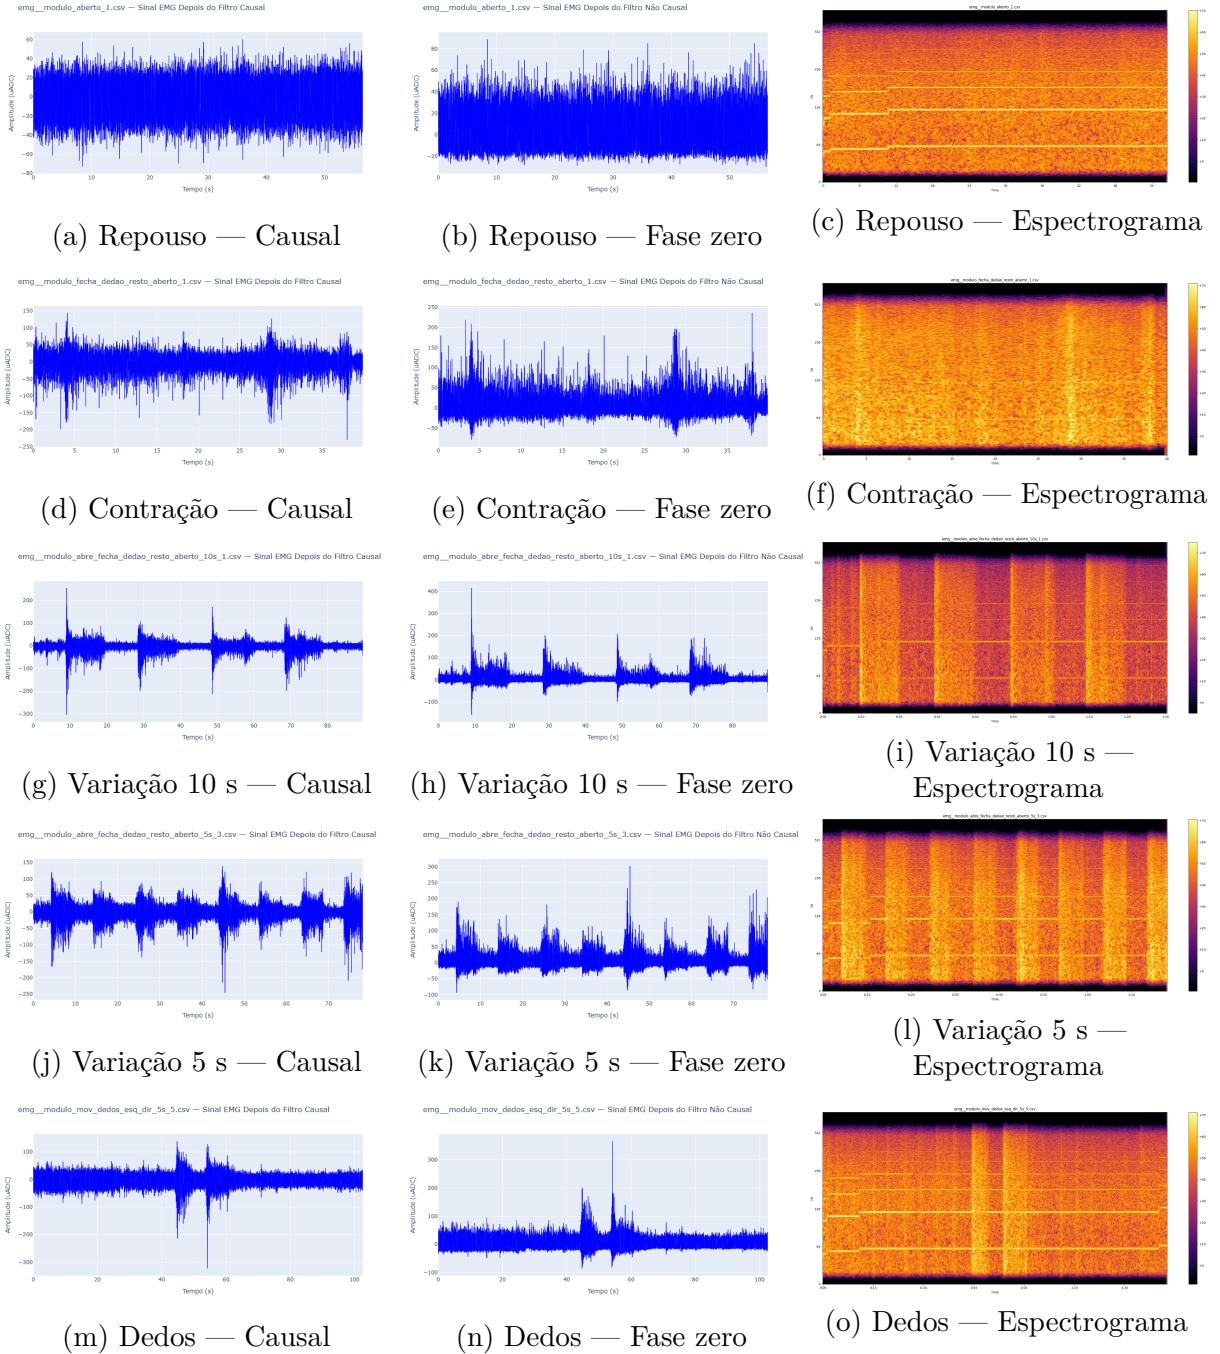


Figura 18: Matriz comparativa dos sinais EMG filtrados da Configuração 2: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria.

sucessivas. Ainda assim, as transições entre os estados musculares permanecem claramente identificáveis, e os instantes de ocorrência dos eventos não são significativamente alterados pela diferença de fase entre as filtragens causal e não causal.

No domínio da frequência, os espectrogramas evidenciam um comportamento consistente entre os diferentes padrões analisados. Na condição de músculo relaxado, observa-se elevada concentração de potência em torno de 60 Hz e de seus harmônicos,

comportamento recorrente mesmo com a alteração da configuração de posicionamento dos eletrodos. Durante os intervalos de contração, tanto nos movimentos estáticos quanto nos dinâmicos, verifica-se uma distribuição mais homogênea da potência ao longo da banda de interesse, com aumento expressivo da energia espectral durante a ativação muscular. Nos movimentos periódicos, essa variação manifesta-se de forma clara no domínio tempo-frequência, destacando as transições entre os estados de relaxamento e contração.

A Tabela 2 apresenta a sequência temporal detalhada dos movimentos realizados durante a aquisição.

Tabela 2 – Sequência temporal da movimentação individual dos dedos com período de 5 s — Configuração 2

<b>Intervalo de tempo (s)</b>	<b>Estado</b>	<b>Descrição do movimento</b>
0 – 5	Repouso	Todos os dedos estendidos
5 – 10	Contração	Dedo mínimo (mindinho)
10 – 15	Repouso	Todos os dedos estendidos
15 – 20	Contração	Anelar
20 – 25	Repouso	Todos os dedos estendidos
25 – 30	Contração	Dedo médio
30 – 35	Repouso	Todos os dedos estendidos
35 – 40	Contração	Indicador
40 – 45	Repouso	Todos os dedos estendidos
45 – 50	Contração	Polegar
50 – 55	Repouso	Todos os dedos estendidos
55 – 60	Contração	Polegar
60 – 65	Repouso	Todos os dedos estendidos
65 – 70	Contração	Indicador
70 – 75	Repouso	Todos os dedos estendidos
75 – 80	Contração	Dedo médio
80 – 85	Repouso	Todos os dedos estendidos
85 – 90	Contração	Anelar
90 – 95	Repouso	Todos os dedos estendidos
95 – 100	Contração	Dedo mínimo (mindinho)

A análise da movimentação individual dos dedos, realizada com período de 5 s conforme a sequência temporal apresentada na Tabela 2, distingue-se das demais condições avaliadas. Nesse padrão, apenas um dedo é flexionado por vez, enquanto os demais permanecem estendidos, permitindo a avaliação da interferência por *cross-talk*. Observa-se que o músculo associado ao movimento do polegar apresenta maior grau de isolabilidade em relação aos demais dedos, característica coerente com sua fisiologia mais especializada e maior independência funcional.

Nos sinais filtrados no domínio do tempo, são identificados picos bem definidos correspondentes aos instantes de contração do polegar indicados na Tabela 2, os quais

permanecem alinhados mesmo com a alteração da resposta de fase do filtro causal. No espectrograma, esses instantes são marcados por aumentos significativos de potência, caracterizando de forma clara a ativação muscular. Esse comportamento reforça que a Segunda Configuração permite tratar o movimento do polegar como uma variável binária isolável, possibilitando a distinção entre flexão e extensão de forma independente do estado dos demais dedos.

Dessa forma, os resultados indicam que a Segunda Configuração é particularmente adequada para a extração de *features* voltadas à identificação específica dos movimentos do polegar, fornecendo subsídios consistentes para sua incorporação como grau de liberdade adicional em modelos de classificação mais complexos.

### 3.4.3 Terceira Configuração - Filtrada

Na terceira configuração, a investigação foi direcionada a um músculo a partir do qual fosse possível extrair informações relacionadas ao movimento do dedo indicador. Para isso, selecionou-se o músculo *Flexor Digitorum Superficialis* (FDS) atua na flexão dos dedos médio e indicador, permitindo movimentos mais seletivos, como o gesto de apontar.

Anatomicamente, o músculo *Flexor Digitorum Superficialis*, que, segundo [15], tem origem no epicôndilo medial do úmero (por meio do tendão flexor comum), no processo coronóide da ulna e na metade proximal da face anterior do rádio, inserindo-se nas superfícies anteriores das falanges médias dos dedos dois a cinco. Suas principais ações incluem a flexão dos dedos dois a cinco nas articulações metacarpofalangianas (MCP) e interfalangianas proximais (IP), além de contribuir para a flexão do punho e do antebraço na articulação do cotovelo.

Esse músculo pode ser localizado conforme ilustrado na Figura 8. Observa-se que o *Flexor Digitorum Superficialis* encontra-se em uma região extremamente densa em termos de musculatura, não sendo um músculo superficial. Dessa forma, foram realizados diversos testes experimentais com o objetivo de identificar a posição mais adequada para a colocação dos eletrodos, buscando maximizar a sensibilidade ao movimento do indicador e minimizar interferências indesejadas.

Após esses testes, definiu-se a disposição dos eletrodos apresentada na Figura 19.

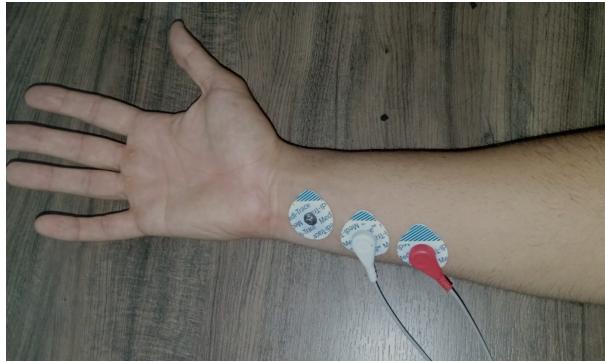


Figura 19: Posicionamento dos eletrodos no músculo *Flexor Digitorum Superficialis* da mão direita. Fonte: Autoria Própria.

A partir dessa configuração, foram realizadas as coletas de dados utilizadas nas etapas subsequentes de processamento, extração de características e classificação dos sinais EMG.

A Figura 20 apresenta os sinais EMG da Configuração 3 após a aplicação do filtro IIR Butterworth, organizados em uma matriz comparativa contendo, para cada padrão de movimento analisado, o sinal filtrado por meio de um filtro causal, o sinal filtrado com fase zero (não causal) e o respectivo espectrograma.

A matriz da Figura 20 confirma os comportamentos previamente discutidos. Adicionalmente, observa-se que os movimentos com variação de 10 s e 5 s foram realizados a partir da extensão e flexão do dedo indicador, mantendo-se os demais dedos estendidos. Nessa condição, a distinção entre os estados de repouso e contração torna-se claramente perceptível tanto no domínio do tempo quanto da frequência, evidenciando elevada rejeição a ruídos. Embora a amplitude do sinal associado ao movimento não seja elevada em termos absolutos, o contraste em relação ao repouso — caracterizado por amplitudes extremamente reduzidas — permite uma separação bem definida entre os estados.

O aspecto mais relevante desta configuração está associado aos efeitos de interferência entre os dedos. Considerando o padrão de movimentação individual dos dedos conforme a Tabela 2, observa-se, no domínio do tempo, que o dedo mínimo apresenta a maior amplitude de ativação, seguido pelo dedo anelar e, em seguida, pelo dedo indicador. Os demais dedos apresentam variações de amplitude pouco expressivas, não sendo consideradas relevantes nesta configuração.

A confirmação da relevância desses três dedos — mínimo, anelar e indicador — torna-se ainda mais evidente na análise espectral. Durante os períodos de contração com duração de 5 s, observa-se a presença consistente do padrão espectral típico de contração muscular para esses dedos ao longo de todo o intervalo de ativação, o que não ocorre de forma significativa para os demais.

Após a realização de diversos testes com diferentes posicionamentos de eletrodos, a

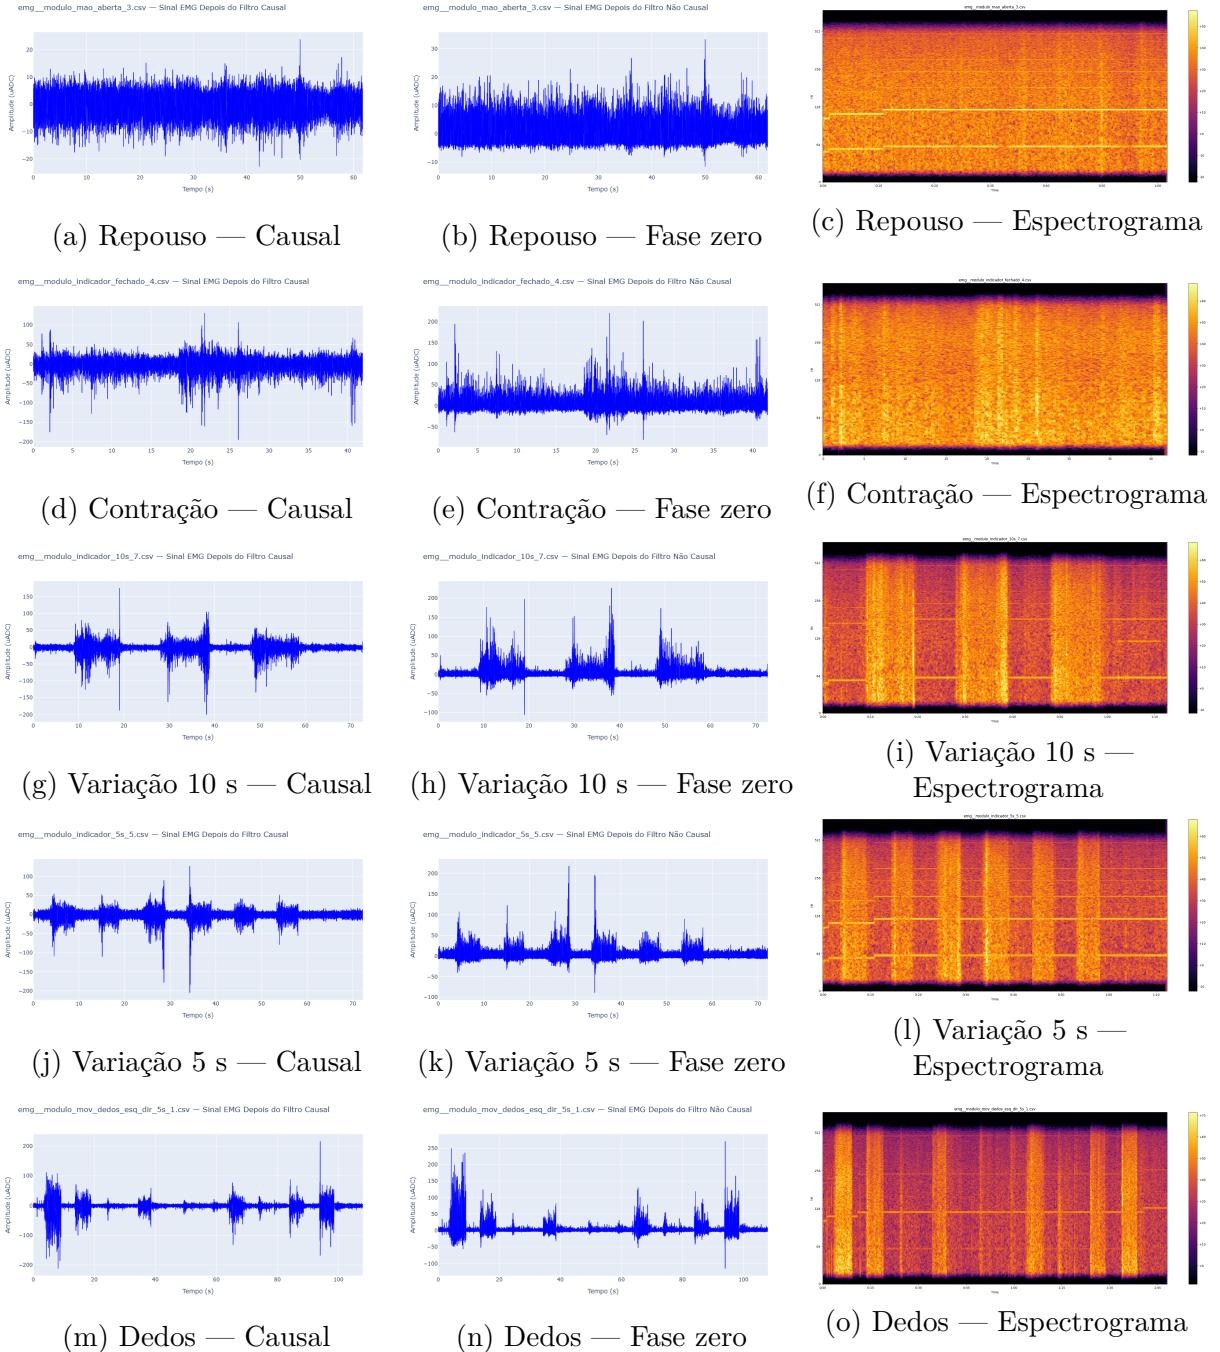


Figura 20: Matriz comparativa dos sinais EMG filtrados da Configuração 3: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria.

configuração apresentada mostrou-se a mais adequada para a identificação do movimento do dedo indicador. Ressalta-se, contudo, que o isolamento completo desse dedo é inviável do ponto de vista anatômico, uma vez que sua movimentação geralmente ocorre de forma acoplada a outros dedos, não apresentando a independência funcional observada, por exemplo, no polegar.

### 3.4.4 Quarta Configuração — Filtrada

Até as configurações anteriores, o foco da captação dos sinais EMG concentrou-se predominantemente em músculos flexores do antebraço, uma vez que estes apresentam, em geral, maior superficialidade e facilidade de posicionamento dos eletrodos. No entanto, para uma análise mais completa dos padrões de movimento dos dedos, torna-se relevante a investigação da atividade muscular associada aos movimentos de extensão.

Dessa forma, optou-se pela utilização do músculo *Extensor Digitorum*, responsável pela extensão dos dedos indicador, médio, anelar e mínimo (dedos 2 a 5). Esse músculo atua principalmente na extensão das articulações metacarpofalângicas e interfalângicas proximais, além de participar de maneira sinérgica em movimentos funcionais da mão. Embora não apresente ação totalmente independente sobre cada dedo, sua ativação é claramente observável durante movimentos de extensão, especialmente quando os dedos se encontram inicialmente flexionados, o que o torna adequado para estudos de eletromiografia de superfície [5, 6, 7].

Como referência inicial para a localização anatômica e posicionamento dos eletrodos, foram utilizados os estudos apresentados em [15], bem como a palpação do ventre muscular conforme ilustrado na Figura 21.



Figura 21: Palpação do ventre do músculo *Extensor Digitorum* da mão direita. Fonte: Muscolino [15].

A partir dessa referência anatômica, foi possível definir o posicionamento dos eletrodos conforme apresentado na Figura 22.



Figura 22: Posicionamento dos eletrodos no músculo *Extensor Digitorum* da mão direita.  
Fonte: Autoria Própria.

A partir dessa configuração, foram realizadas as coletas de dados utilizadas nas etapas subsequentes de processamento, extração de características e classificação dos sinais EMG.

A Figura 23 apresenta os sinais EMG da Configuração 4 após a aplicação do filtro IIR Butterworth, organizados em uma matriz comparativa contendo, para cada padrão de movimento analisado, o sinal filtrado por meio de um filtro causal, o sinal filtrado com fase zero (não causal) e o respectivo espectrograma.

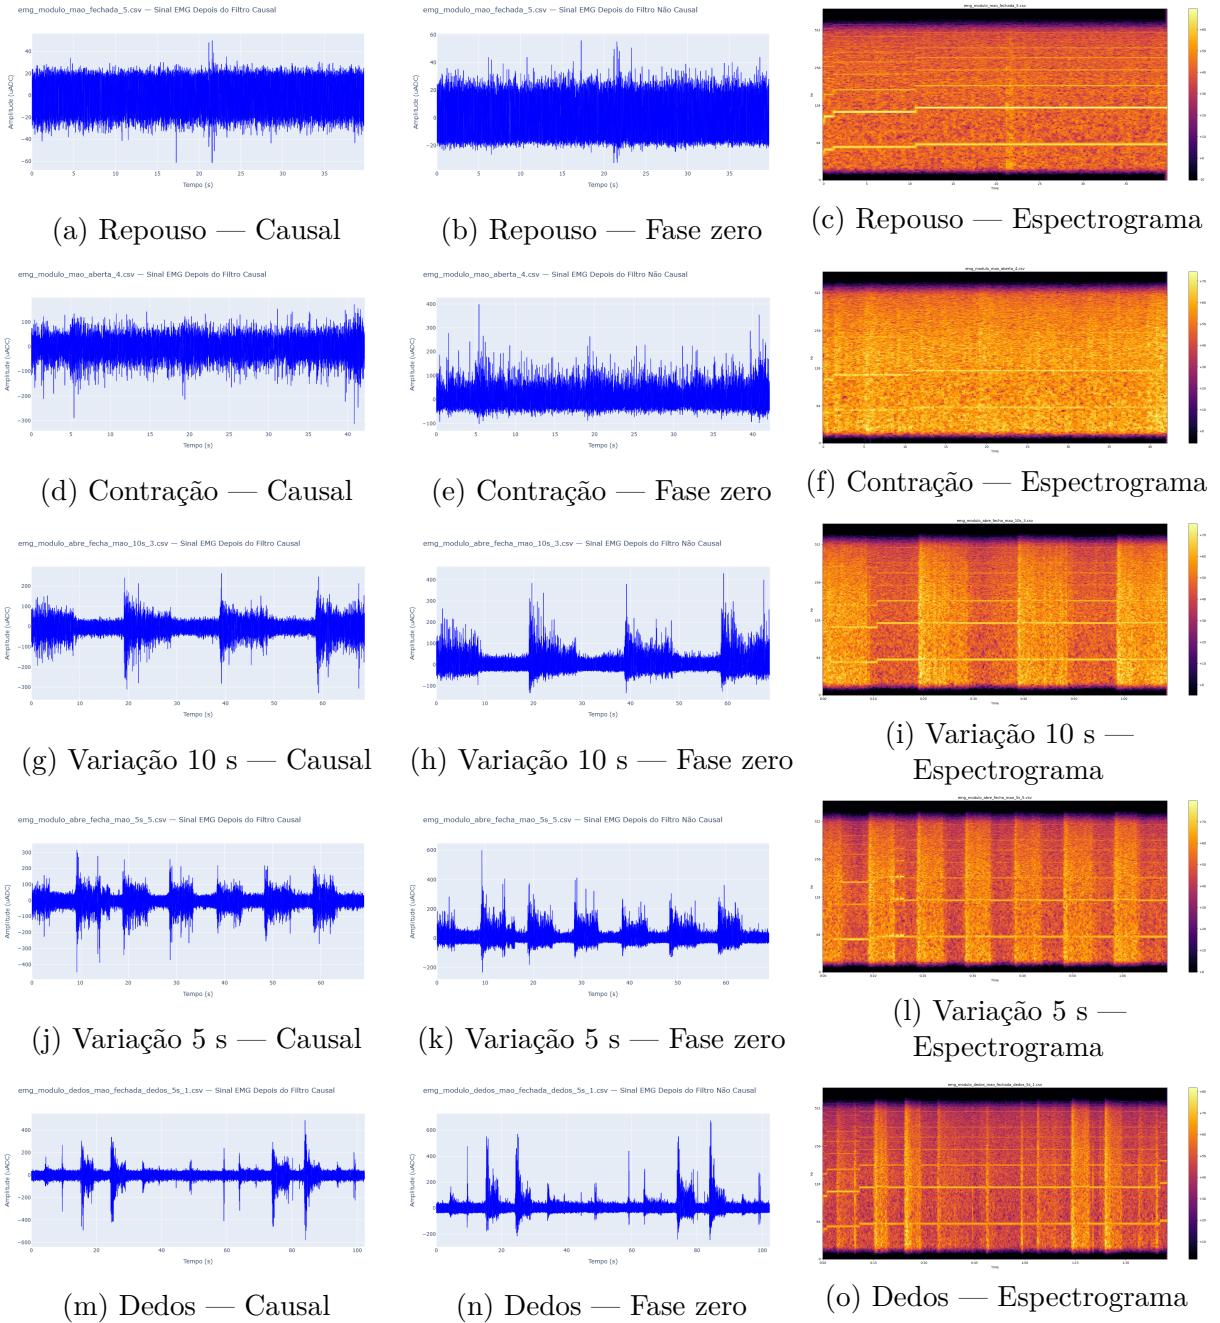


Figura 23: Matriz comparativa dos sinais EMG filtrados da Configuração 4: filtro IIR causal (coluna esquerda), filtro com fase zero (coluna central) e espectrograma (coluna direita) para os diferentes padrões de movimento analisados. Fonte: Autoria Própria.

A análise da matriz apresentada na Figura 23 evidencia o mesmo comportamento geral observado nas configurações anteriores, com aumento de potência durante os períodos de contração muscular e redução significativa das amplitudes durante os intervalos de repouso. No entanto, nesta configuração ocorre uma inversão conceitual dos estados, uma vez que a contração muscular está associada à mão aberta (extensão dos dedos), enquanto o repouso corresponde à mão fechada (flexão dos dedos).

Esse aspecto reflete-se diretamente nos conjuntos de dados de variação temporal de

5 s e 10 s, nos quais os trechos iniciais apresentam elevada atividade muscular, seguidos por períodos de menor potência, comportamento inverso ao observado nas configurações baseadas em músculos flexores.

Na análise do conjunto de dados correspondente à movimentação individual dos dedos, utilizando como referência a sequência apresentada na Tabela 2, observa-se que os maiores níveis de ativação estão associados principalmente aos dedos médio e anelar. Esse comportamento é consistente com a ação funcional do músculo *Extensor Digitorum*, que atua de forma conjunta sobre os dedos 2 a 5, resultando em menor seletividade para o dedo indicador. Ainda assim, é possível identificar picos de ativação associados aos demais dedos, embora com menor relevância quando comparados aos dois dedos predominantes.

Esses resultados indicam que, apesar das limitações anatômicas impostas pela ação conjunta do músculo, a Configuração 4 permite a identificação de padrões consistentes de extensão dos dedos, sendo particularmente sensível aos movimentos do dedo médio e do dedo anelar.

### 3.5 Conclusão da Análise

A partir das análises realizadas, observa-se que o sinal eletromiográfico apresenta características típicas de um sinal de potência, no qual as componentes harmônicas individuais não carregam, de forma isolada, informações relevantes sobre a atividade muscular. As informações de interesse estão majoritariamente associadas à distribuição de potência ao longo da banda de frequências, o que reforça a importância da análise espectral no estudo de sinais EMG.

Foi também evidenciada a presença recorrente de interferências provenientes da rede elétrica, cujas componentes harmônicas, em especial a componente de 60 Hz, manifestam-se de forma praticamente constante ao longo dos diferentes *datasets*. Observou-se que tais interferências não apresentam variação significativa de potência durante os períodos de aquisição.

Nesse contexto, torna-se fundamental a utilização de um filtro passa-faixa adequado ao sistema, sobretudo considerando que, de forma empírica, verificou-se que o módulo de aquisição não realizava um isolamento satisfatório da banda de interesse. A aplicação do filtro mostrou-se essencial, principalmente para a análise no domínio da frequência, permitindo a atenuação de componentes indesejadas e a preservação das faixas associadas à atividade muscular.

Após sucessivas etapas de estudo, testes e ajustes experimentais, foram definidas quatro configurações de eletrodos consideradas satisfatórias, nas quais se obteve qualidade adequada dos sinais EMG. Em todas elas, observou-se uma distinção clara entre os estados de contração e relaxamento muscular, mantendo-se um padrão consistente entre

as diferentes configurações analisadas.

Destaca-se, entretanto, que o aumento do número de configurações de eletrodos implica diretamente no aumento do número de canais de aquisição, o que eleva de forma significativa a complexidade computacional do sistema, especialmente considerando sua futura implementação em plataforma embarcada.

Por fim, a análise realizada evidencia que, devido à complexidade anatômica do antebraço, a obtenção de movimentos minimamente complexos por meio de uma única configuração de eletrodos apresenta limitações significativas. Ainda assim, os resultados obtidos indicam que, ao se considerar um modelo multicanal, há uma possibilidade concreta de distinção entre diferentes padrões de movimento, aspecto que será explorado de forma mais aprofundada nas etapas posteriores relacionadas à extração de características e ao desenvolvimento dos modelos de classificação.

## 4 Extração de Features

A extração de características é uma etapa essencial na construção de um modelo de *machine learning* clássico. O objetivo é representar adequadamente o sinal EMG de modo que suas propriedades relevantes possam ser identificadas e classificadas pelo algoritmo. Neste projeto, optou-se pelo método clássico em vez de uma abordagem baseada em *deep learning*, principalmente por ser mais leve, mais interpretável e mais adequado ao contexto embarcado, onde o custo computacional é mais restrito.

Para a extração de informações relevantes do sinal EMG, torna-se necessária a sua segmentação em janelas temporais (*frames*). A definição do tamanho dessas janelas foi baseada em testes empíricos, na taxa efetiva de amostragem do sistema (aproximadamente 1500 Hz), no tempo de resposta fisiológica do músculo e na necessidade de obter resolução espectral adequada para a análise via DFT.

Adicionalmente, optou-se por utilizar tamanhos de frame que fossem potências de dois, de modo a otimizar o custo computacional do cálculo da transformada rápida de Fourier (FFT), aspecto relevante considerando a possibilidade de implementação embarcada do modelo.

Os parâmetros adotados para a segmentação do sinal são apresentados a seguir:

- **Tamanho do frame (Frame Size):** 1024 amostras, correspondendo a aproximadamente 0.68 s considerando a taxa efetiva de amostragem.
- **Tamanho do pulo (Hop Length):** 256 amostras, resultando em um deslocamento temporal de aproximadamente 0.17 s entre janelas consecutivas, o que implica sobreposição de 75%.
- **Resolução da DFT:**  $\Delta f = \frac{F_s}{N} \approx \frac{1500}{1024} \approx 1.46$  Hz.

Esses valores atendem aos requisitos do projeto: o frame deve ser pequeno o suficiente para capturar mudanças significativas no sinal, mas não tão pequeno a ponto de prejudicar a resolução espectral — um equilíbrio necessário, dado que as frequências relevantes encontravam-se na faixa das harmônicas de 60 Hz. Para reduzir o vazamento espectral, adotou-se a janela de Hann aplicada a cada frame:

$$w[n] = 0.5 - 0.5 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1$$

Com essa estrutura de segmentação, inicia-se a extração de características tanto no domínio do tempo quanto no domínio da frequência. Inicialmente, será adotado um conjunto amplo de features, permitindo maior riqueza de informação para o aprendizado não supervisionado. Posteriormente, essas características poderão ser analisadas

individualmente para identificar combinações mínimas e eficientes, reduzindo o custo computacional em implementações embarcadas — especialmente considerando que a cada hop (256 amostras) todas essas features precisam ser recalculadas. Apesar de alguns métodos recursivos ajudarem, o custo das features espectrais continua sendo significativo devido à dependência da DFT.

A seguir, apresentamos todas as características utilizadas, iniciando pelo domínio do tempo e, posteriormente, pelo domínio da frequência. Muitas das escolhas metodológicas e técnicas de análise empregadas foram baseadas no livro *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*, de Meinard Müller [16], bem como no curso *Audio Signal Processing for Machine Learning*, ministrado por Valerio Velardo [33]— pesquisador e engenheiro de machine learning especializado em processamento de sinais de áudio. Embora ambos os materiais sejam voltados para o domínio acústico, seus fundamentos sobre análise espectral, janelas, segmentação temporal e extração de características são diretamente aplicáveis ao processamento de sinais EMG utilizado neste projeto.

Para a obtenção desses parâmetros, foi desenvolvido um pipeline em Python, robusto e modular, capaz de extrair automaticamente todas as características descritas nesta seção. A implementação utiliza principalmente as bibliotecas NumPy e Librosa devido à sua eficiência no processamento de sinais. Tanto o código-fonte quanto a base de dados utilizados neste trabalho encontram-se disponíveis no repositório GitHub mencionado anteriormente.

## 4.1 Domínio do Tempo

Nesta seção, consideramos que o sinal discretizado é representado por  $x[n]$ , onde  $n$  denota o índice temporal discreto. A cada janela (*frame*) do processamento, extraímos  $N$  amostras consecutivas do sinal, formando o  $i$ -ésimo frame  $x[n]$  com  $0 \leq n < N$ . Assim, definimos que Feature $[i]$  representa o valor da característica calculada a partir dessas  $N$  amostras do frame de índice  $i$ .

### 4.1.1 Amplitude Envelope

A *Amplitude Envelope* representa o maior valor absoluto dentro de cada frame, sendo útil para identificar picos de ativação muscular:

$$AE[i] = \max_{0 \leq n < N} |x[n]|. \quad (4.1)$$

### 4.1.2 RMS — Root Mean Square

O valor RMS mede a energia média do sinal dentro do frame:

$$RMS[i] = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2}. \quad (4.2)$$

#### 4.1.3 Zero Crossing Rate (ZCR)

A taxa de cruzamento por zero conta quantas vezes o sinal muda de sinal dentro do frame. A implementação segue a definição baseada na função *sign*:

$$ZCR[i] = \frac{1}{N-1} \sum_{n=0}^{N-2} \frac{1}{2} |\text{sign}(x[n]) - \text{sign}(x[n+1])|. \quad (4.3)$$

#### 4.1.4 Mean Absolute Value (MAV)

Valor médio absoluto do frame, representando o nível médio de ativação muscular:

$$MAV[i] = \frac{1}{N} \sum_{n=0}^{N-1} |x[n]|. \quad (4.4)$$

#### 4.1.5 Waveform Length (WL)

A *Waveform Length* mede a complexidade do sinal ao longo do tempo:

$$WL[i] = \sum_{n=1}^{N-1} |x[n] - x[n-1]|. \quad (4.5)$$

Essa métrica é útil por capturar variações rápidas no sinal EMG, refletindo mudanças na atividade muscular.

#### 4.1.6 Média, Variância e Desvio Padrão

A média do frame é dada por:

$$\mu[i] = \frac{1}{N} \sum_{n=0}^{N-1} x[n]. \quad (4.6)$$

A variância populacional:

$$\sigma^2[i] = \frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \mu[i])^2. \quad (4.7)$$

E o desvio padrão:

$$\sigma[i] = \sqrt{\sigma^2[i]}. \quad (4.8)$$

#### 4.1.7 Slope Sign Changes (SSC)

A implementação utilizada detecta mudanças de sinal na derivada discreta, ou seja, quantas vezes a inclinação do sinal se inverte:

$$SSC[i] = \sum_{n=0}^{N-3} [\text{sign}(x[n+1] - x[n]) \neq \text{sign}(x[n+2] - x[n+1])]. \quad (4.9)$$

Essa métrica é importante para identificar mudanças bruscas na evolução temporal do sinal.

#### 4.1.8 MAVS — Mean Absolute Value with Slope Weighting

O MAV ponderado utiliza pesos lineares que aumentam do início ao fim do frame, conforme implementado:

$$w[n] = 0.5 + \frac{n}{N - 1}. \quad (4.10)$$

$$MAVS[i] = \frac{1}{N} \sum_{n=0}^{N-1} |x[n]| w[n]. \quad (4.11)$$

Essa ponderação dá maior relevância às amostras centrais e finais do frame, o que pode ajudar na identificação de padrões de ativação.

## 4.2 Domínio da Frequênciа

Nesta seção, seja  $X[k]$  o espectro de magnitude de um frame do sinal  $x[n]$  obtido pela FFT, considerando apenas a faixa positiva ( $0 \leq k < N/2$ ). O índice  $i$  continuará representando o número do frame, como definido anteriormente.

### 4.2.1 Band Energy Ratio (BER)

A razão de energia entre bandas (*Band Energy Ratio* — BER) é uma métrica que divide o espectro em duas regiões separadas por uma frequência de corte  $F$ . Essa métrica indica se a maior parte da energia do sinal está concentrada em baixas ou altas frequências. No presente trabalho, a frequência de corte foi definida como 70 Hz, baseada na análise espectral realizada anteriormente.

A fórmula para o cálculo do BER é dada por:

$$BER[i] = \frac{\sum_{k=0}^{F-1} |X[k]|^2}{\sum_{k=F}^{N/2-1} |X[k]|^2 + \varepsilon}, \quad (4.12)$$

em que,  $X[k]$  representa os coeficientes da Transformada Discreta de Fourier (DFT) para o frame analisado,  $N$  é o tamanho da DFT, e  $\varepsilon$  é um termo pequeno adicionado para evitar divisões por zero.

Essa métrica será utilizada para avaliar a distribuição de energia entre as faixas de frequência, permitindo identificar padrões relacionados à contração e ao relaxamento muscular. Valores elevados de BER indicam maior concentração de energia em baixas frequências, enquanto valores reduzidos sugerem predominância de energia em altas frequências.

#### 4.2.2 Spectral Centroid (SC)

O centróide espectral representa o “centro de gravidade” do espectro de magnitudes, indicando a região de maior concentração de energia:

$$SC[i] = \frac{\sum_{k=0}^{N/2-1} k |X[k]|}{\sum_{k=0}^{N/2-1} |X[k]|}. \quad (4.13)$$

Valores mais altos indicam maior presença de componentes de alta frequência.

#### 4.2.3 Bandwidth (BW)

A largura de banda espectral representa a dispersão das frequências em torno do centróide espectral:

$$BW[i] = \frac{\sum_{k=0}^{N/2-1} |k - SC[i]| |X[k]|}{\sum_{k=0}^{N/2-1} |X[k]|}. \quad (4.14)$$

Essa métrica indica quão espalhado é o espectro em relação ao seu centro de massa.

#### 4.2.4 Frequênci Fundamental ( $f_0$ )

A frequência fundamental é definida como a frequência associada ao maior pico espectral:

$$f_0[i] = \arg \max_{0 \leq k < N/2} |X[k]|. \quad (4.15)$$

Essa métrica identifica a frequência dominante do frame.

#### 4.2.5 Potênci de Banda dos Harmônicos

Considerando que os principais harmônicos associados à interferência da rede elétrica encontram-se próximos aos múltiplos de 60 Hz — conforme observado no capítulo de análise do sinal — foram definidas bandas espetrais centradas em torno de aproximadamente  $60 \cdot n$  Hz, em que  $n$  representa a ordem do harmônico.

Por convenção, assume-se que as componentes localizadas nessas bandas estão associadas predominantemente à interferência da rede, enquanto as demais componentes são tratadas como ruído. Para cada harmônico, foi considerada uma largura de banda de  $\pm 10$  Hz em relação à frequência central.

A potênci normalizada de uma banda espectral é definida por:

$$BP(f_1, f_2)[i] = \frac{\sum_{k: f_1 \leq f[k] \leq f_2} |X[k]|^2}{\sum_{k=0}^{N/2-1} |X[k]|^2}, \quad (4.16)$$

em que  $X[k]$  representa o espectro do sinal no frame  $i$ ,  $f[k]$  a frequênci correspondente ao índice  $k$ , e  $N$  o tamanho da DFT.

As bandas harmônicas consideradas neste trabalho são:

$$BP_1[i] = BP(50, 70), \quad (4.17)$$

$$BP_2[i] = BP(110, 130), \quad (4.18)$$

$$BP_3[i] = BP(170, 190), \quad (4.19)$$

$$BP_4[i] = BP(230, 250). \quad (4.20)$$

#### 4.2.6 Potência de Banda do Ruído

De forma complementar, definiram-se faixas espectrais intermediárias para caracterizar a energia associada ao ruído, isto é, componentes fora das bandas harmônicas da rede elétrica. Essas bandas são dadas por:

$$BP_{\text{noise}1}[i] = BP(0, 50), \quad (4.21)$$

$$BP_{\text{noise}2}[i] = BP(70, 110), \quad (4.22)$$

$$BP_{\text{noise}3}[i] = BP(130, 170), \quad (4.23)$$

$$BP_{\text{noise}4}[i] = BP(190, 230), \quad (4.24)$$

$$BP_{\text{noise}5}[i] = BP(250, 500). \quad (4.25)$$

#### 4.2.7 Energia Harmônica

A energia total associada às componentes harmônicas da rede elétrica é definida como a soma das potências normalizadas das bandas harmônicas:

$$HarmEnergy[i] = BP_1[i] + BP_2[i] + BP_3[i] + BP_4[i]. \quad (4.26)$$

#### 4.2.8 Energia do Ruído

De maneira análoga, a energia total do ruído espectral é obtida pela soma das potências das bandas complementares definidas anteriormente:

$$NoiseEnergy[i] = BP_{\text{noise}1}[i] + BP_{\text{noise}2}[i] + BP_{\text{noise}3}[i] + BP_{\text{noise}4}[i] + BP_{\text{noise}5}[i]. \quad (4.27)$$

#### 4.2.9 Harmonic-to-Noise Ratio (HNR)

O *Harmonic-to-Noise Ratio* (HNR) expressa a razão entre a energia associada às componentes harmônicas e a energia associada ao ruído espectral. Essa métrica é amplamente utilizada para quantificar o grau de periodicidade de um sinal, sendo particularmente útil na diferenciação entre estados de contração e relaxamento muscular.

O HNR é definido por:

$$HNR[i] = 100 \cdot \frac{HarmEnergy[i]}{NoiseEnergy[i] + \varepsilon}, \quad (4.28)$$

em que  $\varepsilon$  é uma *constante de regularização* (ou *termo de estabilização numérica*), escolhida como um valor suficientemente pequeno, de modo a evitar indeterminações do tipo 0/0 sem impactar significativamente o valor da razão.

#### 4.2.10 Median Frequency (MDF)

A frequência mediana é definida como a frequência onde a energia acumulada atinge 50% da energia total:

$$\sum_{k=0}^{k_{mdf}} |X[k]|^2 = \frac{1}{2} \sum_{k=0}^{N/2-1} |X[k]|^2, \quad (4.29)$$

$$MDF[i] = f[k_{mdf}]. \quad (4.30)$$

#### 4.2.11 Mean Frequency (MNF)

A frequência média é dada por:

$$MNF[i] = \frac{\sum_{k=0}^{N/2-1} f[k] |X[k]|^2}{\sum_{k=0}^{N/2-1} |X[k]|^2}. \quad (4.31)$$

### 4.3 Conclusão

A partir da extração sistemática das características do sinal eletromiográfico por meio de um pipeline automatizado, obteve-se um conjunto de dados estruturado no qual cada *frame* é representado por um vetor de *features*. Em função da estratégia de segmentação adotada, a cada *hop length* é gerado um novo *frame*, permitindo a análise contínua e sobreposta do sinal ao longo do tempo.

Essa abordagem mostrou-se eficaz para representar o conteúdo temporal e espectral do sinal EMG, fornecendo informações relevantes sobre a dinâmica da contração muscular em janelas curtas de tempo. Além disso, a utilização de um conjunto abrangente de características possibilita maior flexibilidade na etapa posterior de seleção de atributos, permitindo a identificação de combinações mais informativas e computacionalmente eficientes para aplicações embarcadas.

Com o conjunto de características devidamente estruturado, o problema passa a ser tratado no domínio do aprendizado de máquina, no qual os vetores de *features* extraídos servirão como entrada para os modelos de classificação. No capítulo seguinte, essas características serão utilizadas na implementação prática dos algoritmos de *machine learning*, visando à identificação e discriminação dos movimentos estudados.

## 5 Modelos Não Supervisionados de Machine Learning para Classificação de Movimentos

Após o processamento do sinal, a análise nos domínios do tempo e da frequência e a extração das *features*, podemos avançar para a criação do modelo de *Machine Learning*. Mas qual modelo e qual abordagem utilizar?

Quando o *dataset* é adquirido, ele é obtido em tempo real, contendo apenas o sinal bruto, sem qualquer informação adicional indicando se o músculo está contraído ou relaxado. Dessa forma, trata-se de um conjunto de dados não rotulado (*unlabeled data*), o que caracteriza um problema típico para modelos de aprendizado não supervisionado.

O objetivo consiste, a partir do sinal filtrado, em construir uma matriz de *features* para cada *dataset*, utilizando um *pipeline* desenvolvido para a extração dessas características. Com base nessas *features*, realiza-se a classificação dos movimentos musculares. A estratégia adotada consiste na construção de modelos binários para cada configuração de eletrodos, considerando os estados de contração (1) e relaxamento (0), utilizando algoritmos de aprendizado não supervisionado para a obtenção dos rótulos. Essa abordagem permite, posteriormente, a integração das diferentes configurações e *datasets*, viabilizando a construção de um modelo mais robusto, capaz de representar movimentos musculares mais complexos.

**Por que não utilizar apenas limiares (*threshold*)?** Embora essa abordagem seja possível, ela se mostra muito mais frágil e suscetível a erros, principalmente devido à variabilidade do sinal EMG e à presença de ruído. Ao aplicar um modelo não supervisionado para a obtenção dos rótulos, criamos uma base muito mais consistente para o modelo supervisionado. Apesar de o aprendizado não supervisionado ser mais desafiador, quando bem ajustado, ele fornece rótulos confiáveis, tornando o treinamento supervisionado mais robusto. Além disso, essa estratégia é mais profissional e escalável.

Antes disso, é importante dar um passo atrás: como mencionado, estamos trabalhando com dados sem rótulos. Assim, o plano inicial é utilizar algoritmos de agrupamento (*clustering*) para gerar esses rótulos. Para isso, foram escolhidos dois métodos clássicos de aprendizado não supervisionado: **K-Means Clustering** e **Gaussian Mixture Model (GMM)**. Ambos realizam a classificação do sinal em um número de grupos (*clusters*) previamente definido. O K-Means é eficiente para grandes volumes de dados e fornece clusters bem definidos, enquanto o GMM permite modelar distribuições mais complexas, considerando variâncias diferentes entre grupos.

Os modelos serão aplicados apenas aos *datasets* que apresentam variação de estado (contração e relaxamento). Para os conjuntos que contêm apenas um estado, os rótulos serão atribuídos manualmente, com valor 1 para contraído e 0 para relaxado.

Importante salientar que, neste trabalho, foi construído para cada configuração um

modelo binário para a identificação da contração ou não do músculo, a partir do *dataset* e dos padrões de movimento previamente observados. Tal abordagem se deve ao fato de o projeto dispor de apenas um módulo para a obtenção dos dados, o que impossibilita a captura simultânea de múltiplas configurações de eletrodos. Dessa forma, não faria sentido realizar aquisições em momentos distintos com o objetivo de compará-las diretamente.

Ainda assim, esse procedimento corresponde exatamente ao mesmo processo que poderia ser empregado em um modelo multicanal. Inclusive, o mesmo *pipeline* de extração de *features* e de classificação adotado neste trabalho poderia ser diretamente reutilizado. Ademais, considerando a captação dos dados a partir de um movimento de interesse com duração entre 5 e 10 segundos, intercalado com períodos de relaxamento (mão aberta), é esperado que determinada configuração evidencie de forma clara a contração principal ou que o conjunto dos canais permita a identificação do movimento executado.

Portanto, apesar das limitações relacionadas aos recursos materiais, esta etapa do trabalho permanece relevante, pois comprova a validade do método proposto e do *pipeline* de classificação, que constitui o principal produto deste projeto. Cada *dataset* de *features* foi gerado a partir do sinal filtrado com filtro IIR causal, conforme descrito no capítulo anterior. Antes da aplicação dos algoritmos, utilizamos a técnica **Min-Max Scaler** para normalizar as *features*, garantindo uma melhor análise.

## 5.1 Estratégia de Otimização do Agrupamento

O processo de *clustering* adotado neste trabalho foi otimizado de forma individual para cada *dataset*, uma vez que modelos de aprendizado não supervisionado são altamente sensíveis às características estatísticas do sinal de entrada. Como os conjuntos de dados diferem tanto em relação ao tipo de movimento quanto à dinâmica de ativação muscular, não é possível definir uma configuração única de parâmetros que seja ótima para todos os casos.

Nesta etapa, não foram realizadas alterações nos filtros aplicados diretamente ao sinal no domínio da frequência, uma vez que estes já haviam sido definidos na etapa de aquisição e pré-processamento. Assim, a estratégia de otimização concentrou-se nos seguintes aspectos:

- 1. Filtragem das *features*:** Ajuste de filtros temporais, como média móvel e mediana, aplicados às séries de características extraídas, bem como a avaliação do impacto da elevação ao quadrado, utilizada para amplificação de diferenças entre estados.
- 2. Pós-processamento dos rótulos de *cluster*:** Aplicação de técnicas de suavização temporal sobre os rótulos gerados pelo algoritmo de agrupamento, como filtragem por mediana e *run-length smoothing*, com o objetivo de reduzir classificações espúrias e aumentar a consistência temporal.

3. **Seleção de *features*:** Avaliação de diferentes combinações de características no domínio do tempo e da frequência, uma vez que a relevância das *features* varia conforme o movimento analisado e o padrão de ativação muscular.
4. **Intervenção manual pontual:** Em casos isolados, ajustes manuais foram realizados após a aplicação de todas as estratégias automáticas, principalmente para correção de inversão de rótulos ou pequenas inconsistências temporais.

Essas técnicas mostraram-se necessárias devido à ocorrência de classificações pontuais incorretas, comuns em sinais EMG, geralmente associadas a ruído, variações de contato dos eletrodos ou interferências externas. No contexto de uma futura aplicação embarcada, essa limitação pode ser mitigada por meio da implementação de lógicas adicionais, como a exigência de permanência do sinal em um mesmo estado por um número mínimo de ciclos antes da execução de uma ação.

Por fim, a qualidade do agrupamento foi avaliada por meio de inspeção visual, utilizando o sinal filtrado com fase zero apenas para fins de análise, sobreposto aos rótulos gerados pelo *cluster*. Essa abordagem permite verificar de forma intuitiva a coerência entre os estados de contração e relaxamento identificados pelo modelo.

## 5.2 Modelos Não Supervisionados

Nesta seção, é apresentado o processo de clusterização utilizando o algoritmo que se mostrou mais adequado ao *dataset* em questão (K-Means ou *Gaussian Mixture Model* – GMM).

Ressalta-se que os *datasets* apresentados nesta seção são apenas exemplos, sendo os mesmos utilizados na exemplificação do capítulo de análise de dados. Diversos outros conjuntos de dados foram obtidos, sempre respeitando as categorias de movimento previamente definidas. Entretanto, com o objetivo de simplificar a apresentação, foi selecionado apenas um *dataset* de cada categoria para fins ilustrativos. Essa diversidade de dados é fundamental para que o modelo supervisionado, apresentado posteriormente, seja treinado sob diferentes condições, contribuindo para a redução de erros de classificação.

Adicionalmente, são apresentados gráficos dos clusters (classes 0 ou 1) sobrepostos ao sinal filtrado por um filtro IIR de fase zero, de modo a manter o sinal o mais próximo possível de sua forma original. Embora o treinamento dos modelos tenha sido realizado com um filtro causal, que introduz distorções de fase, essa abordagem permite uma análise visual mais precisa da qualidade da clusterização. Nesse contexto, a avaliação visual mostra-se uma ferramenta particularmente eficaz.

Para cada *dataset*, também é apresentada a configuração dos parâmetros considerados ótimos para o sucesso do processo de clusterização. Todo esse procedimento, bem

como os respectivos parâmetros, foi devidamente documentado nos arquivos em *Python* desenvolvidos para esta etapa do projeto.

### 5.2.1 Aplicação do Modelo

A Figura 24 apresenta uma comparação dos resultados da clusterização aplicada aos diferentes *datasets*, considerando as quatro configurações de eletrodos analisadas. Em cada subfigura, os rótulos obtidos pelo modelo não supervisionado (classes 0 e 1) são sobrepostos ao sinal EMG filtrado com filtro IIR de fase zero, permitindo uma avaliação visual da correspondência entre os instantes de contração e relaxamento muscular.

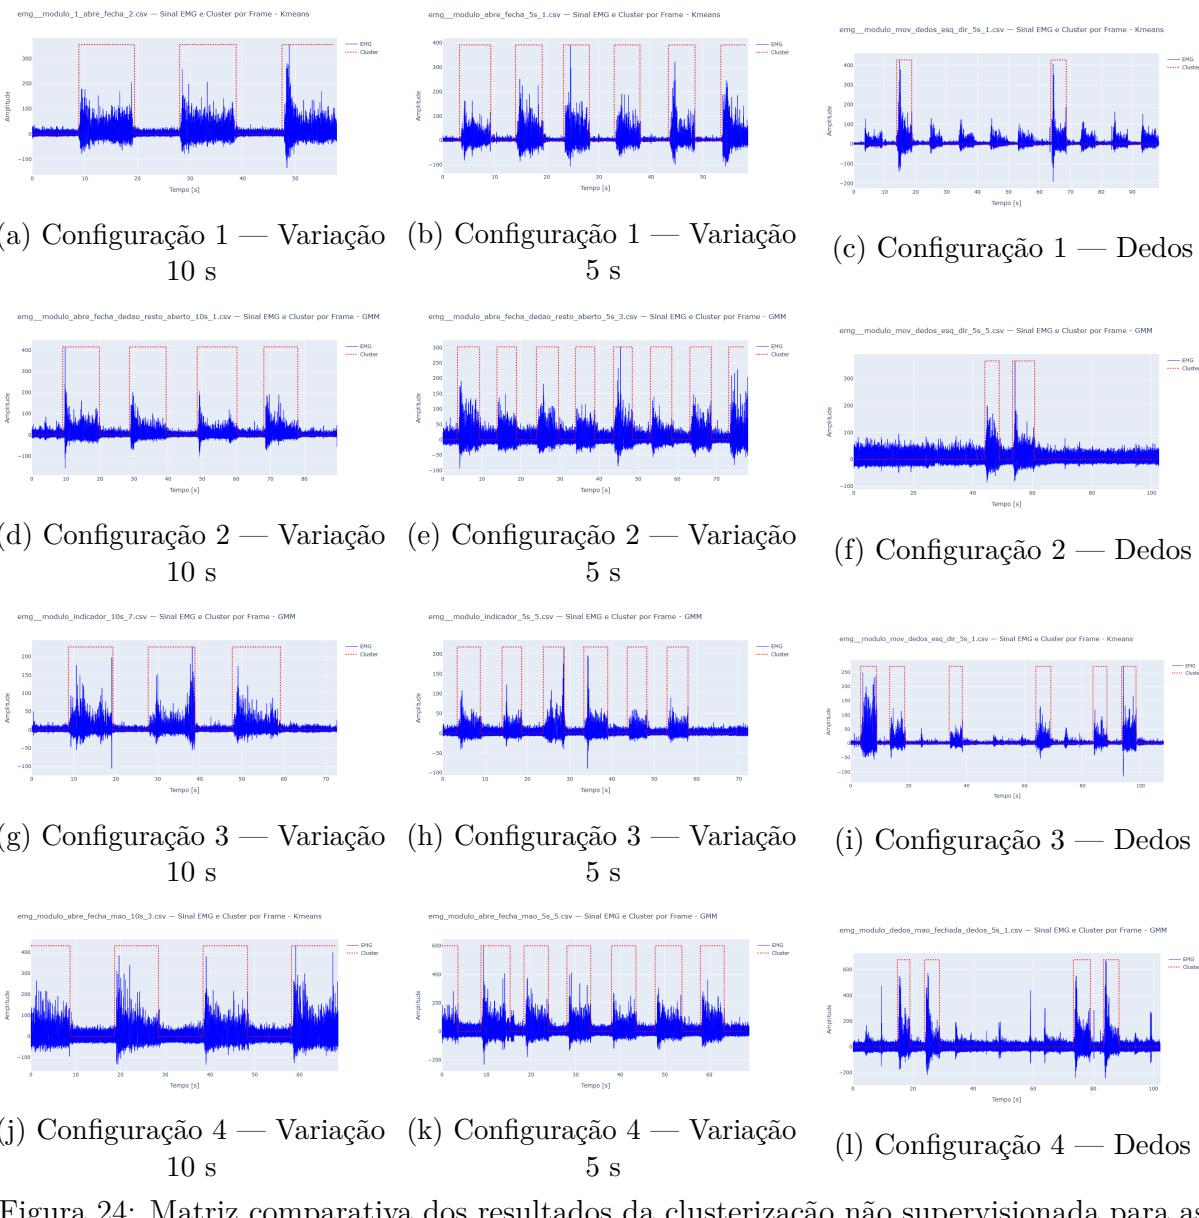


Figura 24: Matriz comparativa dos resultados da clusterização não supervisionada para as quatro configurações de eletrodos analisadas. As classes obtidas (0 e 1) são sobrepostas ao sinal EMG filtrado com filtro IIR de fase zero, permitindo a avaliação visual da correspondência entre os rótulos gerados e os períodos de contração e relaxamento muscular.

### 5.2.2 Configuração de parâmetros e otimização por conjunto de dados

A definição dos parâmetros ótimos do sistema de clusterização foi realizada individualmente para cada conjunto de dados, considerando tanto o tipo de movimento executado. Essa abordagem mostrou-se essencial devido à elevada variabilidade inerente aos sinais EMG e às diferenças significativas entre movimentos globais da mão e movimentos específicos dos dedos.

Em diversos *datasets*, observou-se a necessidade de **seletividade de features**, sendo priorizadas combinações de características nos domínios do tempo e da frequência que maximizassem o desempenho do agrupamento. Em outros casos, a utilização do conjunto completo de *features* apresentou melhores resultados, evidenciando que a relevância das características depende diretamente do padrão de ativação muscular e das particularidades do próprio conjunto de dados.

Além disso, a aplicação de **filtros temporais sobre as séries de features** e de **técnicas de pós-processamento dos rótulos de cluster** mostrou-se fundamental para garantir maior estabilidade temporal da classificação. Em um número bastante reduzido de conjuntos de dados, foram necessárias **correções manuais pontuais**, como a inversão dos rótulos de cluster e pequenos ajustes em janelas temporais específicas. Ressalta-se que essas intervenções ocorreram em pouquíssimos *datasets* e que a interferência manual não ultrapassou 5% do total das amostras em nenhum dos casos analisados.

No que diz respeito aos algoritmos de agrupamento, o **Gaussian Mixture Model (GMM)** apresentou melhor desempenho na maioria dos cenários com maior sobreposição entre classes, enquanto o **K-means** mostrou-se adequado para movimentos mais simples e bem definidos. Esses resultados reforçam a importância da adaptação conjunta entre seleção de *features*, filtragem temporal e método de clusterização.

Os parâmetros específicos adotados para cada conjunto de dados encontram-se documentados nos códigos de extração de características e de classificação, disponibilizados como material suplementar, uma vez que sua inclusão integral neste texto comprometeria a clareza e a objetividade da apresentação.

### 5.2.3 Análise dos Resultados

De modo geral, os resultados obtidos são expressivos, especialmente considerando a elevada sensibilidade inerente aos modelos de aprendizado não supervisionado. Observa-se, na maioria dos casos, uma identificação quase perfeita dos períodos de contração e relaxamento muscular.

Cabe destacar que a obtenção desses resultados não é trivial. Para diversos *datasets*, foram necessários múltiplos testes até se atingir uma combinação adequada de *features* e parâmetros de pós-processamento. Dessa forma, evidencia-se que, em aplicações

práticas, modelos não supervisionados requerem uma supervisão manual criteriosa, principalmente quando seus resultados são utilizados como rótulos para o treinamento de modelos supervisionados.

Nos *datasets* relacionados à movimentação individual dos dedos, a definição dos estados de contração e relaxamento baseou-se diretamente na análise prévia dos sinais no domínio do tempo e da frequência. Na Configuração 1, por exemplo, conforme discutido anteriormente, apenas a contração do dedo anelar foi considerada como estado ativo, devido à sua potência significativamente superior. Em outras configurações, diferentes combinações de dedos foram consideradas como contração, de acordo com a predominância observada nos espectrogramas e na análise temporal.

Essas decisões já haviam sido fundamentadas no capítulo de análise do sinal e mostraram-se coerentes quando confrontadas com os resultados da clusterização, reforçando a consistência do pipeline proposto.

## 6 Modelo Supervisionado de Machine Learning para Classificação de Movimentos

Nesta etapa, foi construída uma base de dados consistente, devidamente rotulada e segmentada em *frames* para a realização da classificação. Com a experiência adquirida na etapa de modelo não supervisionado, o processo de rotulagem torna-se mais eficiente, evitando erros comuns ao rotular *frames* sem referência prévia. O modelo supervisionado constitui o produto final desta etapa, destinado à implementação na prótese.

Foram utilizados *datasets* de *features* brutas obtidos previamente, aplicando-se técnicas adicionais como **RandomOverSampler** para balanceamento de classes em caso de desproporção. A normalização foi realizada com **Min-Max Scaler**, implementando-se manualmente o processo para que novas amostras possam ser normalizadas com os mesmos parâmetros previamente calculados e armazenados.

Inicialmente, todas as *features* foram consideradas para avaliar a efetividade do modelo. Posteriormente, pode-se realizar otimização, reduzindo o número de *features* para melhorar o desempenho em tempo real, evitando cálculos desnecessários em cada atualização.

As configurações dos eletrodos foram analisadas considerando os movimentos previamente definidos. Devido à limitação de disponibilidade de apenas um módulo, não foi possível adquirir dados de todas as configurações simultaneamente. Mesmo com aquisições separadas, foi mantido um padrão consistente de categorias de movimentos, permitindo a classificação de movimentos complexos.

O modelo supervisionado foi desenvolvido para cada configuração, com saída binária (0 ou 1) representando relaxamento ou contração muscular. A combinação desses modelos permite gerar um número binário representando o movimento completo, em que cada bit corresponde a uma configuração:

$$\text{Frame}_t = [\text{Features}_{\text{Conf}_1}(t) \mid \text{Features}_{\text{Conf}_2}(t) \mid \text{Features}_{\text{Conf}_3}(t) \mid \text{Features}_{\text{Conf}_4}(t)]$$

$$\text{Label}_t = [b_1 \ b_2 \ b_3 \ b_4], \quad b_i \in \{0, 1\}$$

Cada bit indica relaxamento ou contração para cada configuração:

- **Conf 1:** Anelar — abertura/fechamento da mão
- **Conf 2:** Polegar — movimentos de oposição/pinça
- **Conf 3:** Mindinho, anelar e indicador — movimentos combinados dos dedos laterais
- **Conf 4:** Extensor do anelar e médio — extensão da mão

Algumas combinações de bits e os movimentos correspondentes:

- **0001** — Mão aberta (C4 ativo, extensão do anelar e médio)
- **1110** — Mão fechada (C1, C2, C3 ativos, C4 relaxado)
- **1111** — Apontar com o dedo médio (C4 ativo com todos os outros)
- **1010** — Extensão do polegar (C1 e C3 ativos, C2 e C4 relaxados)
- **0111** — Pinça (C2, C3, C4 ativos, C1 relaxado)

Outras combinações também podem ser obtidas, porém muitas representam movimentos pouco funcionais ou irrelevantes para o controle da prótese.

Movimentos finos, como apontar com o indicador, não puderam ser detectados de forma confiável devido à interferência de outros dedos nos canais binários. Um modelo multicanal multiclasses poderia superar essa limitação, mantendo a mesma metodologia de extração de *features*, filtragem e classificação, apenas alterando a aquisição simultânea dos sinais.

Os resultados de classificação supervisionada para cada configuração serão apresentados a seguir. Por se tratar de um modelo binário, a taxa de sucesso tende a ser alta, com possibilidade de erro limitada a um único bit por *frame*.

## 6.1 Resultados do Modelo Supervisionado

Foram avaliados diversos modelos de classificação supervisionada, com desempenho semelhante. Para fins de apresentação, os resultados são resumidos utilizando o **Random Forest Classifier**, considerando apenas o *weighted average* das métricas, que reflete a performance global em cada configuração.

### 6.1.1 Desempenho resumido por configuração

Tabela 3 – Resumo das métricas de classificação (*weighted average*) por configuração.

Configuração	Precision	Recall	F1-score	Accuracy
C1	0.96	0.96	0.96	0.96
C2	0.97	0.97	0.97	0.97
C3	0.99	0.99	0.99	0.99
C4	0.98	0.98	0.98	0.98

Observa-se que o desempenho é elevado em todas as configurações, com a menor *accuracy* e *f1-score* atingindo 96%. Esse resultado demonstra que a classificação binária

de contração e relaxamento muscular é altamente efetiva, com os momentos de transição sendo identificados de forma consistente.

### 6.1.2 Análise de Robustez e Overfitting

O modelo foi treinado utilizando apenas 20% dos dados, com 80% reservados para teste. A manutenção de alto desempenho mesmo com proporção reduzida de treino poderia, isoladamente, ser interpretada como indicativo de possível **overfitting**. No entanto, neste caso específico, o dataset utilizado para treinamento e teste foi construído através da concatenação horizontal de diversos conjuntos de dados independentes, adquiridos em momentos diferentes para a mesma configuração de eletrodos e dentro dos padrões de movimento previamente definidos.

Essa construção confere diversidade real ao conjunto de teste, garantindo que o modelo não está apenas memorizando padrões específicos de um único sinal. Assim, a elevada acurácia (mínimo de 96%) e os altos valores de *weighted average* para **precision**, **recall** e **f1-score** refletem a capacidade do modelo de generalizar, mesmo diante de pequenas variações na ativação muscular entre diferentes execuções dos mesmos movimentos.

### 6.1.3 Limitações e Aplicações Futuras

Como o modelo é binário por configuração, a separação de movimentos muito finos, como apontar com o indicador, é limitada devido à interferência entre dedos. Movimentos mais complexos, como “apontar com o dedo médio” ou “pinça”, foram corretamente classificados, mas outros movimentos possíveis podem ser obtidos e rotulados, embora sejam menos relevantes para a aplicação prática. A metodologia pode ser expandida para um modelo multicanal multiclasse, que permitiria capturar movimentos isolados mais finos, utilizando o mesmo pipeline de classificação e *features*, mas requerendo captação simultânea de múltiplos módulos.

### 6.1.4 Considerações finais

O modelo supervisionado binário, aliado ao pré-processamento das *features* e ao pós-processamento dos rótulos, mostrou-se eficiente e confiável para aplicações em tempo real. A abordagem é extensível a modelos multicanal multiclasse, desde que a captação simultânea de dados seja viável.

## 7 Conclusão

Este trabalho trata-se de um projeto de alta complexidade, voltado para a construção de uma prótese, e se mostrou efetivo para a criação de uma base sólida para seu desenvolvimento futuro. Foi possível obter um entendimento profundo do ambiente em que o sistema será alocado, bem como das características da contração muscular, da disposição dos músculos do antebraço e do comportamento do sinal eletromiográfico (*EMG*).

Para a aquisição do sinal, inicialmente foi projetado um sensor próprio, descrito no Anexo A. Entretanto, em função de restrições de cronograma e visando garantir a viabilidade experimental do trabalho, optou-se pela utilização de um módulo comercial. Essa escolha permitiu a realização de estudos experimentais e a avaliação de sinais reais de *EMG* em condições controladas.

A partir dessa abordagem, tornou-se possível analisar o comportamento do sinal, definir posicionamentos estratégicos de eletrodos e compreender como sinais complementares podem ser captados visando à melhoria do desempenho na classificação de movimentos.

O estudo biológico e experimental revelou a complexidade inerente à aquisição de sinais *EMG*, evidenciando fenômenos como *cross-talk* e variações individuais de ativação muscular. Foram realizadas quatro configurações de eletrodos, todas capazes de capturar sinais significativos, possibilitando a análise detalhada e o desenvolvimento de filtros digitais. O processamento dos sinais filtrados permitiu identificar momentos de transição entre estados de contração e relaxamento, bem como compreender melhor a interferência entre músculos vizinhos.

Com base nesses dados, foi desenvolvido um pipeline de extração de *features* e um modelo de aprendizado não supervisionado para classificar os conjuntos de dados. Essa abordagem mostrou-se extremamente eficaz, sendo um ponto de destaque do trabalho. Apesar da limitação de captar apenas um canal por vez, o método é plenamente aplicável a cenários com múltiplos canais simultâneos.

Na etapa de aprendizado supervisionado, o modelo apresentou desempenho muito alto, com acurácia mínima de 96% e ótima consistência entre *precision*, *recall* e *f1-score*. Observou-se, no entanto, que a classificação binária sofre limitações devido ao *cross-talk*, o que restringe a identificação de alguns movimentos específicos. Ainda assim, os princípios desenvolvidos neste trabalho são diretamente aplicáveis para o desenvolvimento de modelos multicanais e multiclasse, capazes de capturar movimentos mais finos e complexos.

Além disso, a construção do dataset a partir da concatenação de múltiplos conjuntos de dados independentes permitiu reduzir riscos de *overfitting*, tornando o modelo robusto mesmo quando treinado com uma fração relativamente pequena dos dados disponíveis. Isso demonstra que a metodologia adotada é consistente e confiável para futuras aplicações em tempo real.

O trabalho, portanto, atingiu um ponto significativo no desenvolvimento da prótese, indo além da simples construção de hardware: permitiu compreender profundamente a dinâmica do sinal EMG, otimizar a captação e classificação de movimentos e propor métodos robustos de aprendizado supervisionado e não supervisionado. Os resultados obtidos servem como base sólida para etapas futuras, incluindo a implementação em dispositivos multicanais, integração com sistemas embarcados e expansão para classificação multiclasse de movimentos finos da mão.

Em suma, este projeto fornece não apenas a fundamentação teórica e prática para o desenvolvimento da prótese, mas também evidencia a importância do estudo integrado entre fisiologia muscular, engenharia de sensores e inteligência artificial aplicada a sinais biomédicos. Ele representa um passo relevante para soluções de interface homem-máquina mais precisas e confiáveis, abrindo caminho para futuras pesquisas e aplicações em reabilitação e próteses robóticas.

## 7.1 Trabalhos Futuros

Para a continuidade deste estudo, algumas vertentes podem ser exploradas, dependendo do objetivo do desenvolvimento.

### 7.1.1 Modelo simplificado para abertura e fechamento da mão

Caso o objetivo seja apenas embarcar um modelo simples para executar movimentos de abrir e fechar a mão, um único canal de aquisição de sinal é suficiente. Esse modelo, já desenvolvido, é facilmente embarcável e permite a manipulação de objetos básicos, mantendo a simplicidade computacional e de implementação.

### 7.1.2 Testes com Sensor Projetado

Uma vertente importante deste trabalho consiste na avaliação do sensor desenvolvido especificamente para esta aplicação, cuja descrição e projeto encontram-se apresentados no Anexo A. A partir dessa etapa, seria possível analisar o sinal adquirido por meio do sensor próprio e compará-lo com os dados obtidos utilizando o módulo comercial.

Eventuais ajustes e otimizações nos pontos de atenção identificados durante o projeto poderiam então ser implementados, visando garantir que o sensor desenvolvido produza sinais com qualidade adequada para a etapa de classificação de movimentos.

### 7.1.3 Aquisição multicanal e multiclasse

Outra linha de trabalho seria a aquisição de sinais multicanal, utilizando o mesmo método de captura e processamento desenvolvido. Os sinais poderiam alternar períodos de movimento de interesse e relaxamento, com durações de 5 s e 10 s, permitindo a

construção de um modelo multicanais e multiclassificadas, utilizando o pipeline já implementado neste trabalho. Essa abordagem permitiria identificar movimentos mais finos e complexos, ampliando a capacidade de controle da prótese.

#### 7.1.4 Implementação em sistema embarcado

Para o embarque do modelo supervisionado, seria necessário otimizar a quantidade de *features*, priorizando aquelas no domínio do tempo e de baixo custo computacional, evitando cálculos como FFT que demandam maior processamento. Um microcontrolador robusto, como o ESP32, seria adequado, pois oferece dois núcleos e um clock relativamente alto, possibilitando a aquisição de múltiplos canais, execução do modelo de classificação e acionamento de motores simultaneamente.

A implementação deveria considerar o uso de um núcleo para o controle em tempo real via FreeRTOS, garantindo a sincronização entre aquisição, classificação e controle do atuador. Testes em tempo real seriam necessários para validar a resposta do sistema embarcado e compará-la com os resultados obtidos offline. Após essa validação, seria possível integrar os motores *servo* para executar os movimentos da prótese com efetividade e precisão.

#### 7.1.5 Desenvolvimento da prótese mecânica

O próximo passo natural seria o desenvolvimento da prótese mecânica em si, integrando o sistema de aquisição, classificação e controle. A construção da prótese deve considerar a distribuição anatômica dos dedos, a robustez dos atuadores e a precisão dos movimentos, de forma a garantir que os sinais classificados pelo modelo supervisionado resultem em movimentos coerentes e funcionalmente úteis.

Essa etapa envolve projetar e testar o mecanismo de articulação dos dedos, a transmissão de movimento e a integração com o microcontrolador embarcado. A experiência obtida no estudo do sinal EMG e na classificação dos movimentos fornece uma base sólida para definir quais movimentos devem ser priorizados, como abertura e fechamento da mão, pinça ou movimentos mais finos, e como cada configuração de eletrodos deve ser mapeada para os atuadores mecânicos.

## REFERÊNCIAS

- 1 NeuroLaunch Editorial Team. *Transistors and Brain Neurons: Unveiling the Striking Similarities*. NeuroLaunch, setembro 2024.
- 2 S. Shilaskar, S. Bhatlawande, R. Chavare, A. Ingale, R. Joshi, A. Vaishale. Human Hand Movement Classification based on EMG Signal using different Feature Extractor. *Biomedical & Pharmacology Journal*, vol. 17, no. 1, 2024.
- 3 K. H. Lee, J. Y. Min, S. Byun. Electromyogram-Based Classification of Hand and Finger Gestures Using Artificial Neural Networks. *Sensors*, vol. 22, no. 1, art. 225, 2021. doi:10.3390/s22010225.
- 4 R. H. Chowdhury, M. B. I. Reaz, M. A. B. M. Ali, A. A. A. Bakar, K. Chellappan, T. G. Chang. Surface Electromyography Signal Processing and Classification Techniques. *Sensors*, vol. 13, no. 9, pp. 12431–12466, 2013. doi:10.3390/s130912431.
- 5 D. A. Neumann. Kinesiology of the Musculoskeletal System: Foundations for Rehabilitation. 3rd ed., Elsevier, St. Louis, 2017.
- 6 K. L. Moore, A. F. Dalley, A. M. R. Agur. Clinically Oriented Anatomy. 8th ed., Wolters Kluwer, Philadelphia, 2018.
- 7 C. J. De Luca. The Use of Surface Electromyography in Biomechanics. *Journal of Applied Biomechanics*, vol. 13, no. 2, pp. 135–163, 1997.
- 8 V. Zschorlich. Digital filtering of EMG-signals. *Electromyography and Clinical Neurophysiology*, vol. 29, no. 2, pp. 81–86, 1989.
- 9 P. C. Bhaskar, M. D. Uplane. High Frequency Electromyogram Noise Removal from Electrocardiogram Using FIR Low Pass Filter Based on FPGA. *Procedia Computer Science*, 2016.
- 10 M. B. I. Raez, M. S. Hussain, F. Mohd-Yasin. Techniques of EMG signal analysis: detection, processing, classification and applications. *Biology Procedures Online*, vol. 8, pp. 11–35, 2006. doi:10.1251/bpo115.
- 11 H. Tankisi et al. Standards of instrumentation of EMG. *Clinical Neurophysiology*, 2019.
- 12 CY Vigor. *Anatomia e Cinesiologia Aplicadas à Educação Física*. Disponível em: <https://cylvigor.com/>. Acesso em: 2025.
- 13 F. H. Netter. *Atlas of Human Anatomy*. 2<sup>a</sup> ed. Philadelphia: Elsevier, 2014.
- 14 S. D. Waldman. *Atlas of Pain Management Injection Techniques*. 4<sup>a</sup> ed. Philadelphia: Elsevier, 2023.
- 15 J. E. Muscolino. *The Muscle and Bone Palpation Manual: With Trigger Points, Referral Patterns and Stretching*. St. Louis: Elsevier, 2016.
- 16 M. Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Cham: Springer, 2015.

- 17 D. Farina, R. Merletti, R. M. Enoka, “The extraction of neural strategies from the surface EMG,” *Journal of Applied Physiology*, vol. 96, no. 4, pp. 1486–1495, 2004.
- 18 Professor Dave Explains, “Professor Dave Explains – Educational Science Channel,” Disponível em: <https://www.youtube.com/@ProfessorDaveExplains>. Acesso em: 2026.
- 19 S. M. Nishida, *Curso de Fisiologia – Ciclo de Neurofisiologia*, Departamento de Fisiologia, Instituto de Biociências, UNESP – Botucatu, 2013.
- 20 R. Hasan, “Eletroencefalograma (EEG): entenda como é feito o exame e quando ele é indicado,” Alta Diagnósticos, artigo informativo em neurologia.
- 21 The Manual’s Editorial Staff, “Eletromiografia (EMG) e estudos de condução nervosa,” *The Manuals*, revisado em jul. 2024.
- 22 D. de Castro, “Eletromiografia – O que esperar do exame? Como se preparar?” 22 set. 2025.
- 23 J. Fernandes, “Como funciona a contração muscular?” artigo de divulgação científica, 10 dez. 2019.
- 24 J. Fernandes, “Qual a diferença entre o músculo estriado e o músculo liso na microscopia óptica?” artigo de divulgação científica, 2 set. 2019.
- 25 KidsHealth Medical Experts, “Bones, Muscles, and Joints,” Nemours Children’s Health, revisado em set. 2023.
- 26 R. L. Ortolan. *Estudo e avaliação de técnicas de processamento de sinal mioelétrico para o controle de sistemas de reabilitação*. Tese (Doutorado) — Escola Politécnica da Universidade de São Paulo (USP), São Paulo, 2002.
- 27 Brasil Escola. *Potencial de ação*. Disponível em: <https://brasilescola.uol.com.br>. Acesso em: 2026.
- 28 IESPE. *Sistema Nervoso e Contração Muscular*. Disponível em: <https://www.iespe.com.br>. Acesso em: 2026.
- 29 A. J. Fridlund, J. T. Cacioppo, “Guidelines for human electromyographic research,” *Psychophysiology*, vol. 23, no. 5, pp. 567–589, 1986.
- 30 J. V. Basmajian, C. J. De Luca, *Muscles Alive: Their Functions Revealed by Electromyography*, 5<sup>a</sup> ed., Baltimore: Williams & Wilkins, 1985.
- 31 T. V. [Sobrenome]. *Desenvolvimento de uma Placa Eletrônica para Aquisição de Sinais Eletromiográficos*. Trabalho de Conclusão de Curso (Graduação em Engenharia Elétrica) — Universidade Federal de Juiz de Fora (UFJF), Juiz de Fora, 2021.
- 32 J. J. A. M. Júnior. *Desenvolvimento de uma armband para captura de sinais eletromiográficos para reconhecimento de movimentos*. Dissertação (Mestrado em Engenharia Elétrica) — Universidade Tecnológica Federal do Paraná (UTFPR), Departamento Acadêmico de Eletrônica, 2016.

- 33 V. Velardo. *Audio Signal Processing for Machine Learning*. Curso online. Canal *The Sound of AI*, YouTube, 2019. Disponível em:  
<https://www.youtube.com/@ValerioVelardoTheSoundofAI>. Acesso em: ano.

## A Projeto do Sensor EMG

### A.1 Desenvolvimento do Sensor

Para a aquisição do sinal eletromiográfico (EMG), faz-se necessária a utilização de um sistema capaz de medir a atividade elétrica associada à contração muscular e convertê-la em um sinal elétrico adequado para posterior processamento. A fundamentação teórica e metodológica deste capítulo foi desenvolvida com base em trabalhos amplamente consolidados na literatura, com destaque para o artigo de revisão “*Techniques of EMG signal analysis: detection, processing, classification and applications*” [10], que aborda os principais aspectos relacionados à detecção, ao processamento e à análise de sinais EMG, bem como para as diretrizes de instrumentação descritas por Tankisi et al. [11].

Adicionalmente, foram consideradas referências de caráter aplicado, incluindo um trabalho de conclusão de curso desenvolvido na Universidade Federal de Juiz de Fora, voltado ao desenvolvimento de uma placa eletrônica para aquisição de sinais eletromiográficos. Esse trabalho contribuiu de forma significativa para a definição prática da arquitetura do sistema de aquisição adotado neste projeto, servindo como importante referência para a escolha dos circuitos integrados utilizados, bem como para o desenvolvimento e a validação dos cálculos envolvidos [31].

O princípio deste capítulo consiste no desenvolvimento de um módulo dedicado à aquisição de sinais eletromiográficos, visando proporcionar maior flexibilidade para futuras etapas de evolução do sistema, especialmente no contexto do desenvolvimento da prótese. Essa abordagem permite, por exemplo, a integração de múltiplos canais de aquisição em uma única placa, sendo cada canal composto por um par de eletrodos responsável pela captação de um sinal EMG. Dessa forma, torna-se possível a obtenção simultânea de sinais provenientes de diferentes músculos ou configurações, o que representa uma limitação relevante em módulos comerciais disponíveis no mercado.

Além disso, parte dos módulos comerciais apresenta documentação técnica limitada, o que dificulta sua utilização em projetos acadêmicos e o detalhamento do funcionamento do sistema final. O desenvolvimento de um módulo próprio permite não apenas maior controle sobre o projeto, mas também a apresentação completa de sua arquitetura e funcionamento no contexto da prótese desenvolvida.

O módulo proposto será projetado para utilização com um microcontrolador de escolha livre, de forma que sua arquitetura não fique restrita a um único dispositivo específico. Essa característica possibilita a adaptação do sistema a diferentes microcontroladores, conforme as necessidades do projeto, aspecto que será detalhado nas seções subsequentes.

Com base nos conceitos apresentados no Capítulo de Embasamento Biológico,

dispõe-se agora de fundamentação suficiente para o projeto do módulo de aquisição. A arquitetura do sistema proposto segue o diagrama de blocos apresentado na Figura 25.

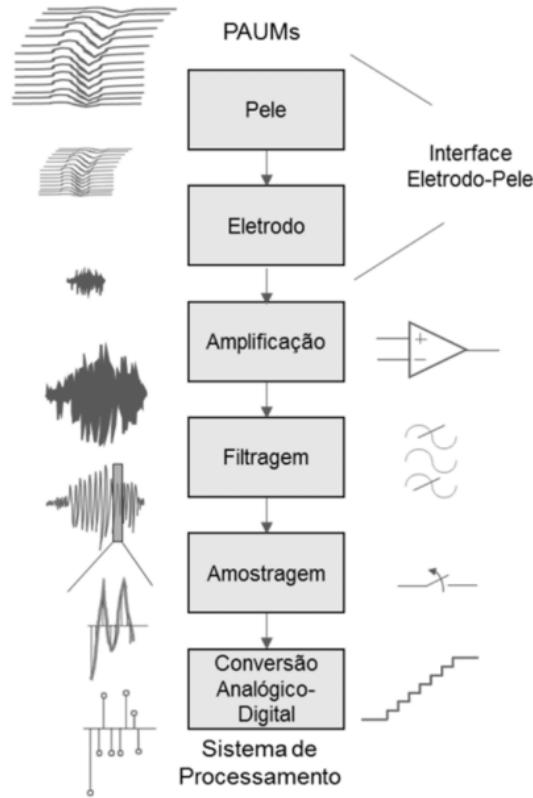


Figura 25: Processo de aquisição dos sinais EMG. Fonte: [32].

O estudo e o desenvolvimento do módulo de aquisição serão conduzidos com base nesse diagrama de blocos, o qual indica as principais etapas de processamento e condicionamento do sinal EMG a serem implementadas.

#### A.1.1 Eletrodos

Para a captação não invasiva do sinal eletromiográfico de superfície (sEMG), é necessária a utilização de eletrodos, responsáveis por realizar a interface entre o tecido biológico e o sistema de aquisição. De forma geral, esses eletrodos consistem em contatos metálicos associados a um adesivo condutivo à base de hidrogel, cuja função é reduzir a impedância de contato pele–eletrodo e melhorar a qualidade do sinal captado [11, 21].

Embora existam eletrodos específicos para aplicações em eletromiografia, sua disponibilidade pode ser limitada. Dessa forma, uma estratégia amplamente adotada em ambientes acadêmicos e experimentais consiste na utilização de eletrodos descartáveis originalmente projetados para eletrocardiografia (ECG), preferencialmente modelos pediátricos, em função de seu menor tamanho. Esses eletrodos apresentam características adequadas para a aquisição de sinais de EMG de superfície, como boa aderência à pele, material

condutivo apropriado e baixo custo, sendo compatíveis com os requisitos de captação do sinal mioelétrico [10].

Além disso, a escolha adequada do eletrodo, aliada ao correto preparo da pele, influencia diretamente a relação sinal-ruído do sistema de aquisição, minimizando interferências e artefatos associados à impedância de contato e ao movimento [11].

### A.1.2 Amplificação

Conforme discutido anteriormente, a amplificação do sinal eletromiográfico é realizada inicialmente por meio de uma configuração diferencial, responsável pelo primeiro estágio do bloco de amplificação. Essa etapa é crítica no sistema de aquisição, uma vez que o sinal EMG apresenta baixa amplitude e está sujeito a interferências externas e ruídos em modo comum. Dessa forma, torna-se indispensável a utilização de um amplificador de instrumentação com elevado índice de rejeição de modo comum (CMRR), garantindo maior fidelidade ao sinal de interesse.

Para este projeto, foi escolhido o amplificador de instrumentação INA128P, um circuito integrado de baixo consumo e uso geral, amplamente empregado em aplicações biomédicas. Esse dispositivo apresenta elevada precisão, alta estabilidade e uma arquitetura interna baseada em três amplificadores operacionais, o que o torna adequado para sistemas de aquisição de sinais de baixa amplitude. Além disso, segundo o datasheet do fabricante, o INA128P mantém larga largura de banda mesmo em ganhos elevados, atingindo aproximadamente 200 kHz para ganho unitário de 100, característica importante para preservar o conteúdo espectral do sinal EMG.

A Figura 26 apresenta o encapsulamento e a identificação do circuito integrado utilizado.

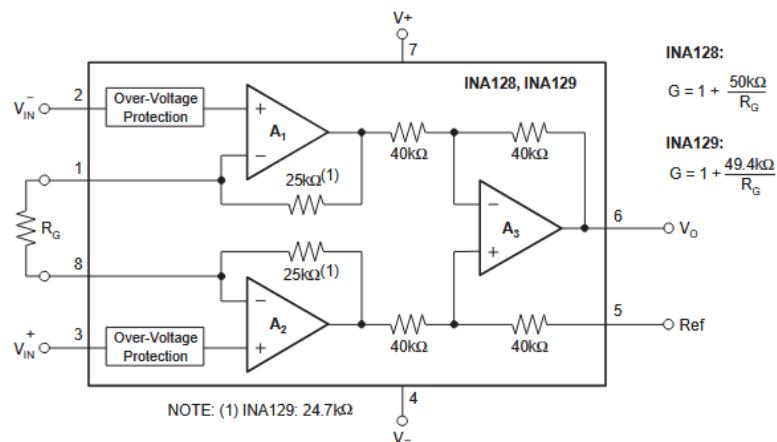


Figura 26: Amplificador de instrumentação INA128P. Fonte: Datasheet do fabricante.

O INA128P possui entradas diferenciais denominadas  $V_{in+}$  e  $V_{in-}$ , além de alimentação simétrica. O dispositivo opera com tensões de alimentação tão baixas quanto

$\pm 2,25$  V, apresentando corrente de repouso da ordem de  $700 \mu\text{A}$ , o que o torna adequado para sistemas alimentados por bateria. O circuito também conta com proteção interna nas entradas, capaz de suportar tensões de até  $\pm 40$  V sem danos permanentes, aumentando a robustez do sistema.

Outro parâmetro relevante é o elevado índice de rejeição de modo comum, que pode atingir aproximadamente 120 dB para ganhos superiores a 100, valor particularmente vantajoso em aplicações de eletromiografia de superfície, nas quais interferências provenientes da rede elétrica e de acoplamentos capacitivos são frequentes. Adicionalmente, o amplificador apresenta elevada impedância de entrada, da ordem de centenas de megaohms, significativamente superior à impedância da interface pele–eletrodo, reduzindo distorções e contribuindo para maior fidelidade do sinal adquirido. O baixo nível de ruído interno e a proteção contra sobrecargas elétricas também são características desejáveis para esse tipo de aplicação.

A amplitude do sinal EMG de superfície situa-se tipicamente entre 0 e 10 mV pico a pico antes da amplificação. Dessa forma, torna-se necessário projetar o ganho do estágio de instrumentação de modo a adequar o sinal à faixa de entrada do conversor analógico-digital (ADC) utilizado. No INA128P, o ganho é definido externamente por meio de um resistor  $R_G$ , de acordo com a relação:

$$G = 1 + \frac{50 \text{ k}\Omega}{R_G}$$

Considerando que este projeto encontra-se em fase inicial de desenvolvimento da placa eletrônica, optou-se pela utilização de um potenciômetro no lugar do resistor  $R_G$ , permitindo o ajuste fino do ganho durante a fase experimental. Essa abordagem reduz o risco de saturação ou subamplificação do sinal, possibilitando a posterior substituição do potenciômetro por um resistor de valor fixo após a validação do circuito.

O sinal amplificado será posteriormente digitalizado pelo conversor analógico-digital (ADC) do microcontrolador ESP32, ilustrado na Figura 27. Utilizando a configuração de maior faixa de tensão disponível (`ADC_ATTEN_DB_11`), o ADC opera com uma faixa aproximada de 2,3 V pico a pico. Dessa forma, considerando uma amplitude máxima do sinal EMG da ordem de 10 mV pico a pico, obtém-se um ganho máximo teórico de aproximadamente 230 V/V, valor que serve como referência para a definição inicial do ganho do estágio de amplificação.

Attenuation	Measurable input voltage range
ADC_ATTEN_DB_0	100 mV ~ 950 mV
ADC_ATTEN_DB_2_5	100 mV ~ 1250 mV
ADC_ATTEN_DB_6	150 mV ~ 1750 mV
ADC_ATTEN_DB_11	150 mV ~ 2450 mV

Figura 27: Características do conversor analógico-digital do ESP32. Fonte: Espressif.

Assim, para um ganho aproximado de 230 V/V, obtém-se um valor teórico de

$$R_g \approx \frac{50 \text{ k}\Omega}{229} \approx 218 \text{ }\Omega.$$

Entretanto, valores tão baixos de  $R_g$  tornam o ganho altamente sensível a pequenas variações de resistência, tolerâncias dos componentes e ruídos elétricos. Além disso, variações fisiológicas do sinal EMG e diferenças na impedância da interface eletrodo-pele podem alterar significativamente a amplitude efetiva do sinal medido.

Por esse motivo, na prática, é comum empregar um potenciômetro (por exemplo, de 500  $\Omega$  ou 1 k $\Omega$ ) em série com um resistor fixo, de modo a limitar o ganho máximo e permitir um ajuste fino durante a fase inicial de testes e calibração do sistema.

Além disso, uma abordagem amplamente adotada em sistemas de aquisição de sinais EMG consiste em trabalhar com ganhos iniciais mais moderados, tipicamente na faixa de 100 a 200 V/V, complementando a amplificação em estágios posteriores do circuito. Esses estágios adicionais podem empregar amplificadores operacionais convencionais, uma vez que, após o primeiro estágio de instrumentação, o sinal já apresenta amplitude suficiente e não exige, necessariamente, as características de alto CMRR típicas de amplificadores de instrumentação. Dessa forma, a utilização do potenciômetro no estágio inicial mostra-se particularmente interessante durante os testes preliminares do módulo, conferindo maior flexibilidade ao processo de ajuste e validação do sistema.

Por fim, o terminal de referência do amplificador de instrumentação é conectado ao potencial de terra do circuito (0 V). Como possibilidade de aprimoramento futuro, destaca-se a implementação de um eletrodo de referência adicional, posicionado em uma região de baixa atividade muscular, como uma proeminência óssea. Essa técnica é amplamente utilizada em módulos comerciais de EMG e contribui para a redução adicional de ruídos e interferências no sinal adquirido.

### A.1.3 Filtragem Analógica

A faixa de frequência típica do sinal EMG encontra-se entre 50 e 500 Hz. Dessa forma, faz-se necessária a implementação de um filtro passa-faixa, que pode ser obtido pela combinação de um filtro passa-alta e um filtro passa-baixa. Para ambos os filtros, foi adotada a topologia Sallen-Key de segunda ordem, ilustrada na Figura 28.

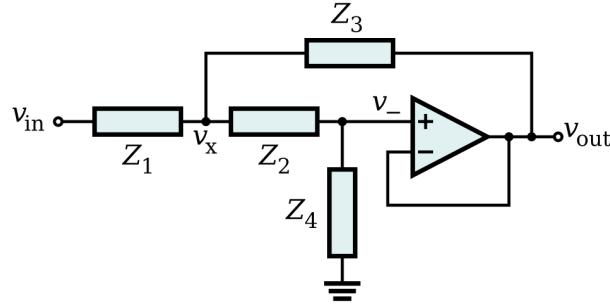


Figura 28: Topologia básica do filtro Sallen-Key. Fonte: Wikipedia.

Conforme discutido, os parâmetros dos filtros dependem da aplicação e foram definidos com base no trabalho de Tawan [31]. Para ambos os filtros, utilizou-se o amplificador operacional TL084CN, que também atua como buffer de saída. O circuito completo de filtragem é apresentado na Figura 29.

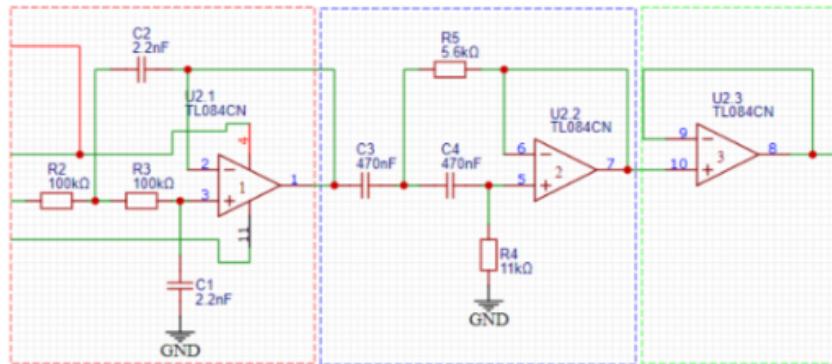


Figura 29: Circuito de filtragem completo. Fonte: [31].

Os valores de componentes foram calculados no trabalho citado, sendo apenas resumidos aqui. O filtro passa-baixa de segunda ordem foi projetado para uma frequência de corte de  $f_c = 500$  Hz, utilizando resistores  $R_1 = R_2 = 100$  k $\Omega$  e capacitores  $C_1 = 2.2$  nF e  $C_2 = 4.7$  nF, considerando um fator de qualidade  $Q = 0.707$  (Butterworth).

O filtro passa-alta de segunda ordem foi projetado para uma frequência de corte de  $f_c = 40$  Hz, com capacitores  $C_1 = C_2 = 470$  nF e resistores  $R_1 = 11$  k $\Omega$  e  $R_2 = 6.2$  k $\Omega$ , também considerando  $Q = 0.707$ .

A partir desses valores, as funções de transferência simbólicas e numéricas dos filtros podem ser expressas da seguinte forma:

$$H_{LP}(s) = \frac{1}{R_1 R_2 C_1 C_2 s^2 + C_1 (R_1 + R_2) s + 1} \quad (\text{A.1})$$

$$H_{LP}(s) = \frac{1}{1.034 \times 10^{-8} s^2 + 4.4 \times 10^{-4} s + 1} \quad (\text{A.2})$$

$$H_{HP}(s) = \frac{s^2}{s^2 + \frac{C_3+C_4}{C_3C_4R_3}s + \frac{1}{C_3C_4R_3R_4}} \quad (\text{A.3})$$

$$H_{HP}(s) = \frac{s^2}{s^2 + 1.82 \times 10^5 s + 1.69 \times 10^4} \quad (\text{A.4})$$

$$H_{total}(s) = H_{HP}(s) \cdot H_{LP}(s) = \frac{s^2}{(s^2 + 1.82 \times 10^5 s + 1.69 \times 10^4) \cdot (1.034 \times 10^{-8}s^2 + 4.4 \times 10^{-4}s + 1)} \quad (\text{A.5})$$

Dessa forma, obtém-se um filtro passa-faixa adequado à faixa de interesse do sinal EMG, com frequência de corte inferior em 40 Hz e superior em 500 Hz, garantindo a preservação das informações do sinal e a rejeição de ruídos indesejáveis.

Foi realizada a simulação do filtro passa-faixa tanto em Python, a partir da função de transferência calculada, quanto no LTSpice, utilizando o circuito implementado. Observou-se que as respostas obtidas foram semelhantes em ambos os métodos. Para evitar redundância, serão apresentados apenas os resultados obtidos em Python, conforme mostrado nas Figuras 30 e 31.

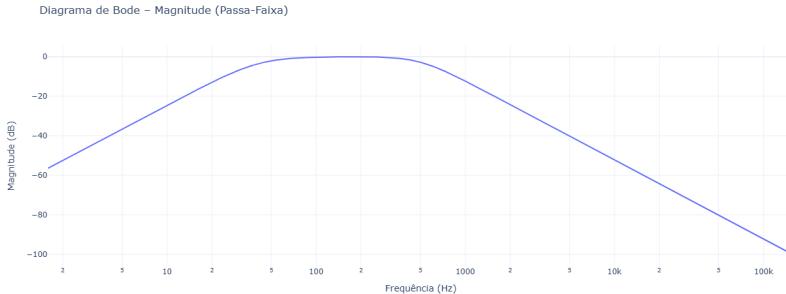


Figura 30: Resposta em magnitude do filtro passa-faixa (simulação em Python). Fonte: autoria própria.

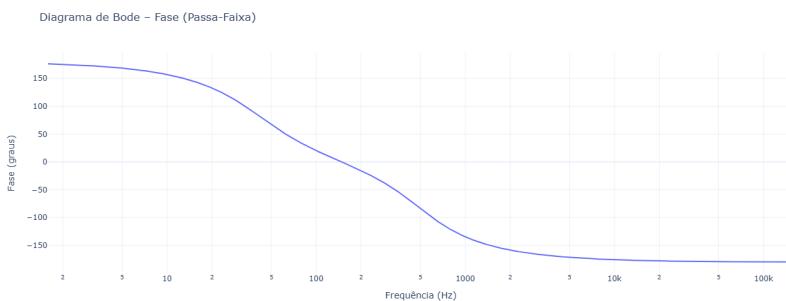


Figura 31: Resposta em fase do filtro passa-faixa (simulação em Python). Fonte: autoria própria.

Se mostrando um filtro efetivo para o projeto, capaz de rejeitar adequadamente as componentes de frequência fora da faixa de passagem. Vale ressaltar, entretanto, que

por se tratarem de dois filtros de segunda ordem, a atenuação na região de rejeição é de aproximadamente 40 dB/decada, podendo ainda existir algumas componentes fora da faixa desejada. No entanto, essas componentes residuais não são suficientemente significativas e podem ser facilmente eliminadas posteriormente por um filtro digital, o que se mostra mais simples e prático do que aumentar a ordem dos filtros analógicos projetados.

#### A.1.4 Offset - Somador

O último ponto importante para o projeto do circuito de aquisição de sinal é a implementação de um circuito somador. Isso é necessário porque o sinal proveniente do par diferencial contém componentes negativas, o que não é compatível com a entrada de microcontroladores. Para resolver esse problema, utilizou-se o modelo de somador mostrado na Figura 32.

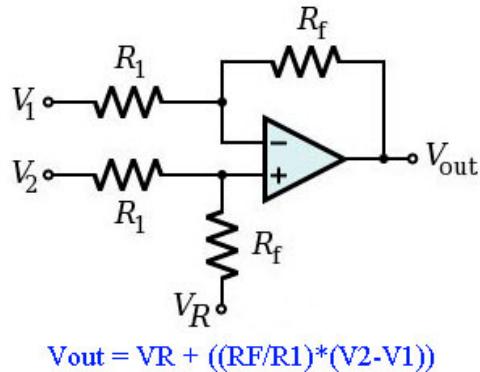


Figura 32: Exemplo de circuito somador. Fonte: electronics.stackexchange.com.

A saída do somador é dada por:

$$V_{\text{out}} = V_r + \frac{R_f}{R_1} \cdot V_2$$

Inicialmente, pretende-se utilizar apenas circuito como um somador, configurando  $R_f = R_1$ , ambos de aproximadamente 10 kΩ. Tal configuração garante que o somador funcione como um somador simples com ganho unitário. Como discutido na seção de amplificação, esse estágio também pode ser utilizado posteriormente para amplificar o sinal, se necessário. Neste projeto inicial, optou-se por manter  $R_f = R_1$  para simplificação, deixando ajustes finos para etapas futuras.

Para centralizar o sinal no ADC do ESP32, considerando a configuração de maior faixa de tensão (ADC\_ATTEN\_DB\_11), temos:

$$\text{Faixa total do ADC} = 2450 \text{ mV} - 150 \text{ mV} = 2300 \text{ mV}$$

A tensão de referência  $V_r$  deve então ser posicionada no ponto médio desta faixa, somando o offset inferior:

$$V_r = \frac{2300 \text{ mV}}{2} + 150 \text{ mV} = 1300 \text{ mV} \approx 1,3 \text{ V}$$

Neste projeto inicial, o valor de  $V_r$  será aplicado externamente, permitindo maior flexibilidade durante os testes experimentais.

Para a implementação do somador, foi utilizado o amplificador operacional MCP6002 Rail-to-Rail Input/Output, adequado à aplicação devido a suas características: baixa tensão de alimentação (1,8 V a 5,5 V), compatibilidade com entradas e saídas rail-to-rail, e operação em faixas industriais e estendidas de temperatura. Como o estágio de instrumentação utiliza normalmente tensões maiores ( $\pm 9$  V), um regulador de tensão LM7805 foi empregado para fornecer 5 V ao somador, conectando  $V_{DD} = 5$  V e  $V_{SS} = 0$  V. As entradas do somador seguem o diagrama previamente apresentado, garantindo que o sinal esteja centralizado e pronto para ser lido por microcontroladores, como ilustrado na Figura 33.

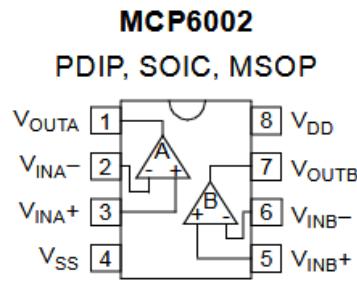


Figura 33: Amplificador operacional MCP6002 utilizado como somador. Fonte: Datasheet.

Dessa forma, o circuito de somador permite que o sinal EMG, previamente amplificado, seja deslocado para a faixa de operação do ADC do microcontrolador, garantindo compatibilidade e flexibilidade para ajustes futuros. Além disso, esse estágio possibilita pequenas correções de ganho e offset antes da digitalização, aumentando a fidelidade do sinal processado.

#### A.1.5 Placa de Circuito Impresso – PCB

Neste momento, todos os blocos construtivos apresentados anteriormente foram integrados para o desenvolvimento do projeto do sensor. A placa de circuito impresso (PCB) foi projetada utilizando o software *KiCad*.

Para a entrada do sinal, ou seja, a conexão dos eletrodos, é considerada uma boa prática a utilização de cabos do tipo P02, amplamente empregados em aplicações biomédicas de baixo custo. Um exemplo desse tipo de cabo é apresentado na Figura 34.



Figura 34: Cabo P02. Fonte: eletrogate.com.

Normalmente, esse tipo de cabo é conectado à placa por meio de um conector Jack P02, que pode ser soldado diretamente na PCB. Um exemplo desse conector é mostrado na Figura 35.



Figura 35: Conector Jack P02. Fonte: eletrogate.com.

Entretanto, no contexto de sinais EMG, não existe um padrão rígido para esses cabos de conexão, uma vez que muitos deles são originalmente projetados para ECG, utilizando convenções como *Right Leg* (R), *Left Leg* (L) e *Right Arm* (R), além de variações nas cores dos condutores. Dessa forma, visando maior flexibilidade no desenvolvimento e nos testes do projeto, optou-se pela utilização de um módulo adaptador P02, apresentado na Figura 36.

Esse módulo permite identificar com precisão os pontos de conexão do conector P02 — *sleeve*, *ring2*, *ring1* e *tip*. No par diferencial de entrada do circuito, foram utilizados os terminais *RING2* e *TIP*. A identificação desses terminais pode ser realizada de forma simples por meio de um multímetro em modo de continuidade.

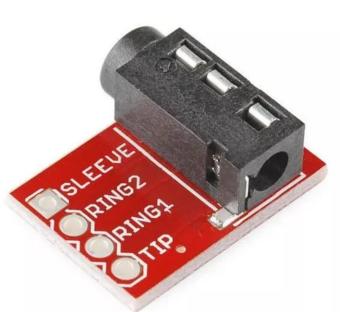


Figura 36: Módulo adaptador P02. Fonte: eletrogate.com.

Todos os blocos do circuito foram integrados em uma única placa. A organização do sistema seguiu a seguinte sequência: filtro passa-altas, somador, filtro passa-baixas e, por fim, um buffer de saída. O somador foi inserido entre o filtro passa-altas e o filtro passa-baixas com o objetivo de garantir o correto deslocamento de nível DC do sinal e evitar a propagação de ruídos de alta frequência que poderiam causar problemas de *aliasing*. O esquemático completo do circuito é apresentado na Figura 37.

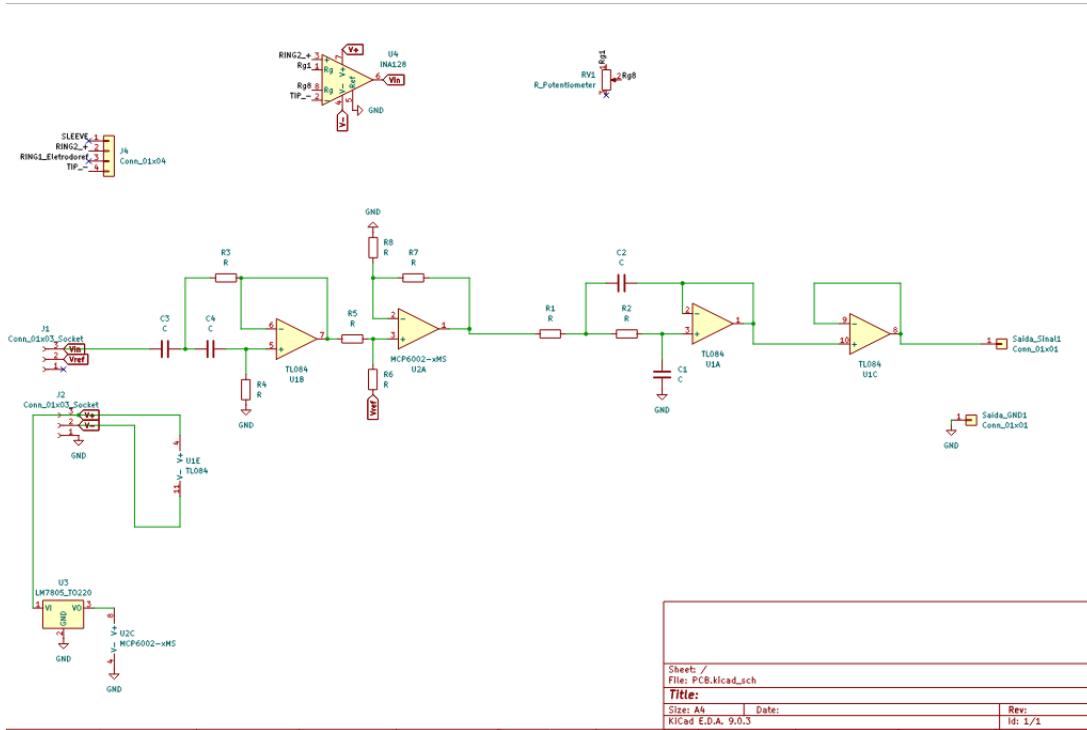


Figura 37: Esquemático do circuito. Fonte: autoria própria.

As entradas do circuito foram desenvolvidas utilizando sockets e conectores, facilitando testes e modificações. Na saída, o sinal condicionado é disponibilizado em um conector destinado à entrada do microcontrolador, além de um terminal de referência de terra comum ao sistema. Também está disponível o sinal  $V_{\text{ref}}$ , que corresponde ao valor de referência  $V_r$  do somador, responsável pelo deslocamento de nível DC do sinal, conforme discutido anteriormente.

A alimentação do circuito foi realizada por meio de duas baterias de 9 V, de modo a obter uma alimentação simétrica, criando-se o ponto de terra pela conexão do terminal positivo de uma bateria com o terminal negativo da outra. Embora essa solução seja prática para a fase inicial do projeto, ela não é a mais eficiente. Isso ocorre porque, apesar das tensões serem simétricas, as correntes drenadas não o são, o que pode resultar em descargas desbalanceadas entre as baterias ao longo do tempo, ocasionando diferenças de tensão que podem comprometer o funcionamento do circuito. Em versões futuras do projeto, outras soluções de alimentação poderão ser exploradas.

Para a regulação da tensão utilizada nos circuitos auxiliares, foi empregado o

regulador linear LM7805, garantindo uma tensão estável de 5 V para os blocos que necessitam dessa alimentação.

O projeto da PCB foi desenvolvido em uma única camada, devido às limitações do ambiente de fabricação disponível. Nesse cenário, e considerando a quantidade significativa de conexões, foi necessário adotar algumas soluções alternativas no roteamento das trilhas. Embora a placa seja de camada única, algumas conexões foram implementadas por meio de *jumpers* soldados externamente, funcionando como uma segunda camada funcional. Alternativamente, em um cenário com maior disponibilidade de recursos, o uso de múltiplas camadas poderia simplificar significativamente o layout. O projeto final da PCB é apresentado na Figura 38.

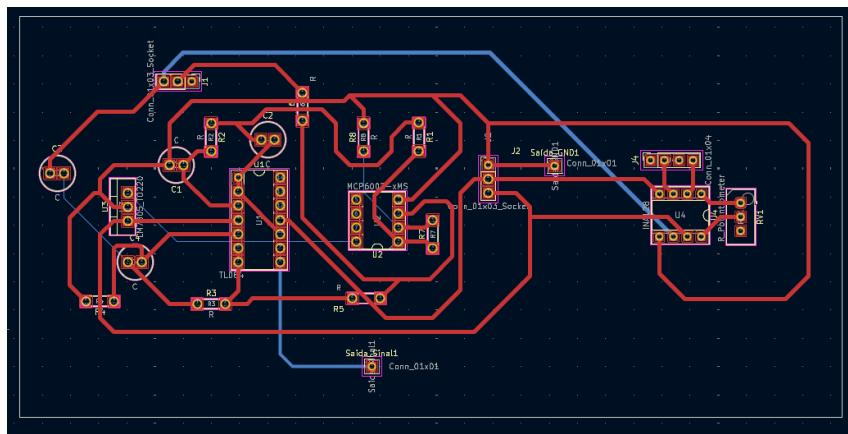


Figura 38: Projeto da PCB. Fonte: autoria própria.

Dessa forma, foi possível desenvolver um projeto inicial funcional para a placa de aquisição de sinais EMG. Devido às características do sinal e à complexidade envolvida, trata-se de um circuito desafiador de ser testado sem uma referência comparativa. Por esse motivo, decidiu-se utilizar, paralelamente, um módulo comercial disponível no mercado, que será discutido posteriormente, servindo como base para validação e comparação dos sinais obtidos.

Essa abordagem permite que os testes, o entendimento do comportamento do sinal e as etapas de análise de dados e aprendizado de máquina sejam realizadas de forma consistente. Ressalta-se que os princípios de processamento e classificação dos sinais são equivalentes tanto para o módulo comercial quanto para a placa desenvolvida neste projeto, reforçando a escolha dessa estratégia. O uso de técnicas de *machine learning* constitui o núcleo do desenvolvimento da prótese proposta.

Ainda assim, o desenvolvimento da PCB contribui significativamente para o entendimento dos circuitos de instrumentação utilizados, inclusive daqueles presentes nos módulos comerciais, que frequentemente possuem documentação limitada. Dessa forma, o projeto da placa pode servir como base para futuras melhorias e para a integração

completa do sistema da prótese. Os arquivos do projeto desenvolvidos no *KiCad* estão disponíveis no repositório GitHub associado a este trabalho.